







中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生数学建模竞赛

学　　校		武汉大学
参赛队号		26104860281
队员姓名	1.	韩禹帆
	2.	冯雨晨
	3.	姚泽鑫

中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生数学建模竞赛

题　目： 复杂场景下多模态情感预测的数学建模与算法设计

摘　要：

多模态情感预测通过联合分析文本语义、语音韵律与视觉表情，为人机交互中的情感理解提供重要支撑。然而，不同模态在采样频率、时间粒度与表达方式上的异质性，增加了时序对齐与互补信息建模的难度，局部连续缺失进一步削弱情感线索的完整性，非线性融合过程则使预测依据难以解释。本文基于 CMU-MOSEI 数据，围绕多模态特征提取与时序对齐、模态缺失条件下的鲁棒情感预测及可解释情感预测三个方面开展研究。

针对问题一，构建基于**词级时序对齐与时间交叠加权聚合**的异构特征表征方法。利用 DistilBERT、openSMILE 和 MediaPipe 分别提取 768 维文本语义、25 维声学低层描述量与 52 维面部表情系数。通过 **CTC 强制对齐**估计候选词区间，结合音视频实际时间戳，按**有效交叠时长归一化加权**，将声学与视觉特征聚合至统一词位置。最终完成 100 条样本、1932 个词位置的三模态特征构建，并建立原始素材映射。经观测有效性核验与对齐质量筛选，全部词位置中，**79.97%** 通过对齐质量筛选，**71.79%** 进一步满足三模态可观测条件。

针对问题二，构建基于**连续遮挡增强**与**缺失感知门控**的情感极性与强度联合预测模型。对三模态对齐特征进行标准化，以**观测掩码**表征信息可用状态，通过连续片段遮挡构造增强样本。利用**时序卷积**与**掩码池化**提取模态表示，依据模态内容及缺失统计计算门控权重，实现三模态信息的自适应加权融合，通过分类与回归双输出头联合预测情感极性与强度。在 727 条测试样本上，完整输入条件下的分类准确率为 **64.92%**。当三模态在随机位置同步连续遮挡 50% 的有效位置时，相较于仅使用完整输入训练的等权融合基线，Macro-F1 由 0.4328 提高至 **0.5316**，MAE 由 0.7936 降低至 **0.7304**，表明整体方案能够改善局部连续缺失条件下的分类与回归表现。

针对问题三，在问题二缺失感知多模态融合模型的基础上，引入**模态组合增强**，构建“模态贡献—局部证据—原始素材”分层可解释性方法。采用 **Shapley 值**量化三模态贡献，结合**积分梯度**定位关键片段，并通过文本—语音强制对齐关联原始音视频材料。验证结果表明，文本的平均绝对贡献占比为 **61.22%**，**模型总体更依赖文本**。积分梯度用于解释模型预测所依赖的关键片段，所选积分梯度证据窗口在**删除与保留检验**中总体优于等长随机窗口，仅保留指定模态的证据窗口并移除其余模态时，原预测类别保持率为 **85.16%**，高于随机窗口的 **61.84%**，支持所选片段能够保留模型判断所依赖的关键信息。

综上所述，本文围绕时序对齐、缺失鲁棒预测与决策解释构建多模态情感分析框架，将观测质量评价、缺失状态建模与分层归因相结合。在改善局部连续缺失条件下预测表现的同时，实现模态贡献量化与局部证据追溯，为复杂场景下兼顾预测性能与可解释性的情感分析提供方法参考。

关键词： 多模态情感预测；词级时序对齐；缺失感知门控融合；Shapley 值；积分梯度

目录

1 研究背景及问题重述 4

1.1 研究背景 4

1.2 问题重述 4

2 模型假设与符号说明 6

2.1 模型假设 6

2.2 符号说明 6

3 问题一 多模态情感特征提取与时序对齐 7

3.1 问题分析与总体思路 7

3.2 附件 1 数据分析与预处理 7

3.3 多模态特征提取 10

3.3.1 基于 DistilBERT 的文本特征提取 10

3.3.2 基于 openSMILE 的声学特征提取 11

3.3.3 基于 MediaPipe 的视觉特征提取 14

3.4 三模态特征的词级时序对齐 16

3.4.1 基于 CTC 的文本与音频词级强制对齐 16

3.4.2 基于词时间区间的声学与视觉特征加权聚合 18

3.5 实验结果分析 19

3.5.1 样本覆盖完整性与特征有效性 20

3.5.2 时序对齐质量评估与人工审核 21

3.5.3 典型样本的跨模态时序对齐验证 25

3.5.4 三模态特征文件说明与 100 条样本结果汇总 26

3.5.5 方案可复现性说明 30

3.6 本问小结 30

4 问题二 局部模态缺失下的鲁棒性情感预测 32

4.1 问题分析与总体思路 32

4.2 多模态数据分析与预处理 33

4.2.1 数据分布与特征标准化 33

4.2.2 有效观测识别与掩码构建 34

4.2.3 连续遮挡与样本增强 35

4.3 缺失感知门控模型构建 36

4.3.1 时序编码与缺失状态表征 36

4.3.2 缺失感知的模态门控融合 37

4.3.3 情感极性与强度的联合预测 38

4.3.4 模型训练与评价准则 39

4.3.5 模块消融与作用分析 41

4.4 多框架对比与模型选择 42

4.4.1 框架一：动态缺失增强与辅助学习 43

4.4.2 框架二：任务专属门控与决策层融合 44

4.4.3 框架三：模态内自注意力与跨模态注意力 46

4.4.4 综合性能比较与选型依据 47
4.5 局部缺失下的鲁棒性分析 50
4.5.1 实验设置与完整输入基准 50
4.5.2 缺失模态类型与比例的影响 50
4.5.3 缺失位置与分布模式的影响 53
4.5.4 类别混淆与强度偏差分析 56
4.6 附件 3 预测结果与置信度分析 58
4.6.1 观测状态分析与集成预测 58
4.6.2 情感极性与强度预测结果 58
4.6.3 预测置信度与稳定性分析 59
4.7 本问小结 60
5 问题三 可解释性多模态情感预测 61
5.1 问题分析与总体思路 61
5.2 模型建立与求解 62
5.2.1 情感预测模型与训练策略 62
5.2.2 基于 Shapley 的模态贡献分析 63
5.2.3 基于积分梯度的局部证据定位与原始素材映射 65
5.3 模型验证与结果分析 66
5.3.1 预测性能与错误分析 66
5.3.2 解释忠实性与充分性检验 67
5.3.3 解释稳定性与敏感性分析 69
5.4 附件 4 预测与解释结果 70
5.4.1 全量结果汇总 71
5.4.2 典型样本解释与证据展示 72
5.5 本问小结 74
6 模型评价与推广 75
6.1 模型的优点 75
6.2 模型的局限性 75
6.3 改进方向与应用推广 75
7 总结 76
参考文献 77
附录 A 附件说明 78
附录 B 人工智能软件辅助答题说明 80

1 研究背景及问题重述

1.1 研究背景

情感分析是具身智能、自然人机交互等领域的关键支撑技术之一，其目标是使机器能够准确感知和理解人类在交互过程中表达的情绪状态。随着大语言模型及相关技术的发展，人机交互正从简单的文本问答转向持续协作与复杂任务求解 [1]，交互系统对人类情绪的理解能力也因此面临更高要求。在真实交互场景中，人类情绪并非仅通过言语传递，而是同时经由语气、音调等语音信号以及面部表情、肢体动作等视觉信号协同表达。因此，仅依赖单一模态难以全面、稳定地刻画情感，且易受环境噪声与个体表达差异的影响。多模态联合建模则能够通过跨模态信息的互补与相互印证，突破单模态识别的局限，提升复杂场景下情感理解的准确性与稳定性，基于多模态的情感预测已成为人机交互领域理解人类情感表达的重要研究方向 [2, 3]。

尽管多模态情感预测具备跨模态信息互补与相互印证的优势，但其从科学研究走向实际应用仍面临诸多困难与挑战，主要体现在以下三个方面：一是模态异构性带来的时序对齐难题。文本通常按词语或词元组织，语音与视觉信号则各有不同的采样频率，三者在特征维度、序列长度与时间尺度上均不一致，致使跨模态时序关系难以精确对应，而特征提取与时序对齐的质量直接决定了模型性能的上限；二是模型对完整模态数据的过度依赖。实际采集过程中，画面遮挡、环境噪声、转写失败等情况难以避免，常导致模态信息的局部缺失。面对此类不完整数据，常规融合模型容易因信息缺失而产生误判，且难以依据当前可用模态动态调整，预测稳定性不足；三是预测结果缺乏可解释性。现有多数模型在接收多模态特征后仅输出预测结果，无法说明判断究竟依据的是语言内容、语音变化还是某一表情片段，也难以区分真实情感线索与背景干扰。已有研究表明，注意力权重与输入对模型输出的实际影响并不总是一致 [4]，这进一步削弱了人们对模型结果的信任。

上述三方面挑战相互关联，共同制约着多模态情感预测在复杂场景中的落地应用。为此，本文围绕多模态特征提取与时序对齐、模态缺失条件下的鲁棒预测、可解释性情感预测三个层级开展系统性建模研究。

1.2 问题重述

本文以 CMU-MOSEI 多模态情感数据集为基础，围绕复杂场景下多模态情感预测的落地需求，构建“多模态特征提取与时序对齐—缺失条件鲁棒预测—可解释性预测”层层递进的建模框架，并将研究内容分解为以下三个问题：

问题一：多模态情感特征提取与时序对齐建模。本问题以附件 1 中 100 条原始视频片段为输入，建立文本、语音、视觉三模态情感特征的提取模型，明确原始样本的处理流程、各模态特征的数学定义与提取方法。并针对三模态在采样频率与时间尺度上的差异，建立跨模态时序对齐的规则与实现逻辑。最终需输出覆盖全部样本、时序组织可核验、处理流程可复现的标准化三模态时序特征，并通过典型样本验证文本、语音、视觉信号在统一时间轴上的对应关系，为后续问题提供统一的数据基础。

问题二：模态信息缺失条件下的鲁棒情感预测建模。本问题以附件 2 提供的标准化多模态特征为数据基础（在 aligned_50.pkl 与 unaligned_50.pkl 中择一，并在训练、验证与测试中保持同一版本与输入接口），在训练集上学习模型参数，在验证集上选择模型结构、超参数与决策阈值。针对画面遮挡、环境噪声、转写失败等导致的模态局部缺失，即单个模态中存在随机连续的零值区间而非整个模态不可用，构建鲁棒的多模态融合预测模型，使其在信息不完整条件下仍能稳定输出情感极性分类与情感强度回归结果，并系统分析缺失模态类型、缺失位置与缺失时长对预测性能的影响规律。最终利用该模型对附件 3 的无标签测试样本完成推理，并以准确率、F1 值评价分类性能，以平均绝对误差、皮尔逊相关系数评价回归性能。

问题三：可解释性多模态情感预测建模。针对三模态信息完整但决策过程难以追溯的

场景，在附件 2 数据上构建可解释的多模态预测模型，使其在输出情感极性与情感强度的同时，以可量化、可复核的方式给出主要参考模态、各模态作用程度以及模态内部关键证据片段的时间位置，并能将证据回溯至原始文本片段、语音时段或视觉关键帧。最终对附件 4 的测试样本完成预测与解释，通过典型样本解释卡及模态作用、片段重要性的可视化验证解释结果的可靠性，提升模型输出的可信度。

2 模型假设与符号说明

2.1 模型假设

- 假设给定情感标签可表征片段整体情感倾向与强度。
- 假设短时声学记录和抽样帧能够代表其附近时间段的局部状态。
- 假设附件特征的相同有效槽位具有跨模态对应关系，可用于融合建模。
- 假设人工遮挡仅改变片段的可观测信息，不改变原片段对应的情感标签。

2.2 符号说明

本文使用的主要符号及其含义见表 2.1，其余符号在相应位置进行相关说明。

表 2.1　主要符号说明

符号	含义
$T, A, V;\ \mathcal{M}$	文本、语音、视觉模态及其组成的集合 $\mathcal{M} = \{T, A, V\}$
$X_i^{(m)}, d_m$	样本 i 在模态 m 下的输入特征矩阵及特征维度
L	原文词数
L_i	样本 i 的有效词元槽位数
I_k	第 k 个原文词的候选时间区间，起止时间以秒计
$w_{kj}^{(M)}$	模态 $M \in \{A, V\}$ 的第 j 条原生记录聚合至第 k 个词的归一化权重
P_{it}	样本 i 在位置 t 的有效位置掩码
$O_{it}^{(m)}, \widetilde{O}_{it}^{(m)}$	人工干预前、后的模态观测掩码
$q_i^{(m)}$	样本 i 的模态 m 缺失状态特征向量
$\beta_i^{(m)}$	样本 i 的模态 m 门控融合权重
$c_i, \hat{c}_i$	样本 i 的真实情感类别与预测情感类别
$y_i, \hat{y}_i$	样本 i 的真实情感强度与预测情感强度
p_i	样本 i 的情感类别预测概率向量
J	兼顾完整与缺失场景的综合验证指标
Y	完整验证输入下的综合选型指标
F_c, F_y	分别为固定原预测类别的概率解释目标与情感强度解释目标
ϕ_{im}, a_{im}	样本 i 的模态 m 的有符号 Shapley 贡献及绝对贡献占比
$\mathrm{IG}_j(x)$	输入表示 x 的第 j 维特征相对于参考表示的积分梯度归因
I_{im}^*	根据积分梯度分数选取的模态局部候选证据窗口
Δ_{imI}	删除样本 i 的模态 m 中窗口 I 后，原预测类别概率的下降量

3 问题一　多模态情感特征提取与时序对齐

3.1 问题分析与总体思路

问题一要求将附件 1 中的 100 条原始视频及表 label-100 中的英文转写文本转化为具有明确时间对应关系的文本、语音和视觉特征，并保留样本编号、有效位置及其与原始素材的映射。该任务的关键在于三类信息的组织粒度不同：文本按英文单词组织，声学特征对应短时分析窗口，视觉特征对应离散视频帧，三者的序列位置并不天然具有一一对应的时间关系。若直接按序列位置拼接，难以保证同一位置描述的是同一时段；若统一按固定长度切分，又可能将一个完整词对应的视听信息分散到多个窗口。因此，需要建立文本语义单元与视听时间区间之间的显式对应关系。已有研究将模态对齐与融合方法作为多模态学习中的重要技术环节 [5]。本问侧重建立三类序列之间可核验的时间对应，为后续特征组织提供依据。

英文单词既是文本的基本语义组成单位，也可通过其在语音中的发音区间与视听观测建立联系。因此，本文以词为基本对齐单位，在估计词级时间边界的基础上，将对应时段的声学和视觉特征汇总到同一词位置。整体处理流程包括模态特征提取、词级时序对齐和样本质量核验三个阶段，如图3.1所示。

首先，核对视频、转写文本与标签的样本对应关系，分别提取三种模态的特征。文本经子词编码后汇总为词级语义表示，并保留词与子词之间的映射。声学与视觉特征分别从短时分析窗口和抽样视频帧中提取，同时记录各自的时间信息，为后续对齐提供依据。

其次，以给定英文转写和解码音频为输入，通过强制对齐估计每个词的候选起止时间。根据词区间与声学窗口、视觉帧支持区间的时间交叠关系，对有效视听特征进行加权聚合，形成统一词位置的三模态表示，并保留其与原始观测之间的映射。

最后，检查样本是否完整、各模态特征是否有效，以及词与视听的时间对应是否合理，并标记缺失观测和低置信度对齐结果。通过计算复核和典型样本展示，检验特征聚合及时间对应关系。最终输出覆盖全部 100 条样本的三模态时序特征文件与汇总表，记录序列位置、有效长度及其与原始素材的对应关系，并附工具参数和运行说明，以满足题目对样本覆盖完整性、时序组织可核验性及方法可复现性的要求。

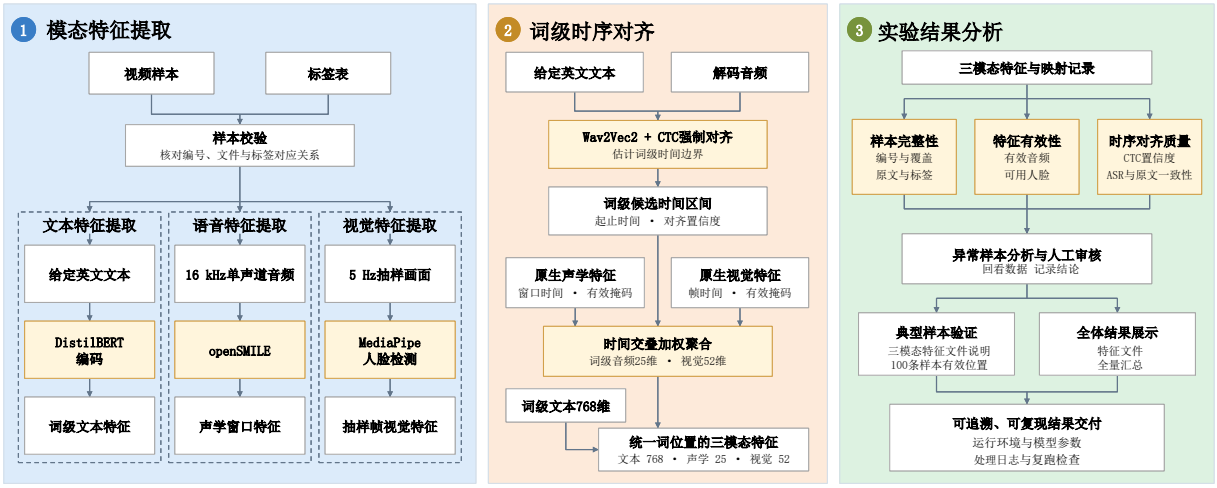


图 3.1　问题一总体思路图

3.2 附件 1 数据分析与预处理

附件 1 包含 100 条视频片段，分布于 37 个以原始视频编号命名的子文件夹中。本文以视频编号与片段编号的组合作为样本标识，将视频与标签表 label-100 中的英文转写、情

感分值及类别标注对应。经检查，100 条视频均可正常读取，且具有对应的转写记录。在此基础上，从视频时长、转写长度和画面内容三个方面考察数据特点，为后续预处理与特征提取提供依据。

视频片段的时长分布如图 3.2所示。按实际解码记录统计，视频片段时长为 2.257–29.288 s，与题干提供的视频片段时长不一致，可能与视频解码器的选择不同有关，本文将按照实际时间统计记录进行后续处理。平均时长为 7.880 s，中位数为 6.722 s。其中，71 条片段的时长位于 $3\,\mathrm{s} \le T < 9\,\mathrm{s}$ 的范围内，占全部样本的 71%，说明数据主要由较短片段构成，同时包含少量较长片段。

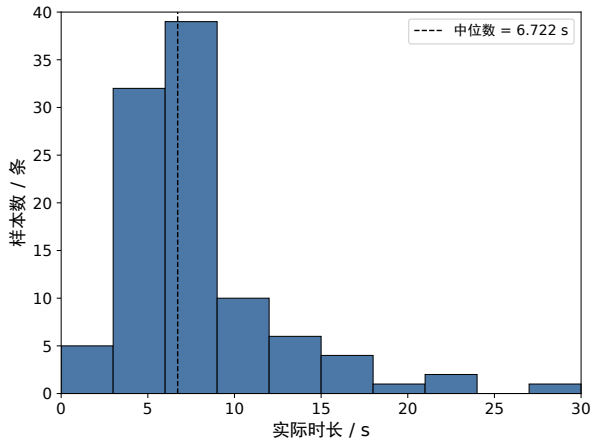


图 3.2　原始视频片段的时长分布

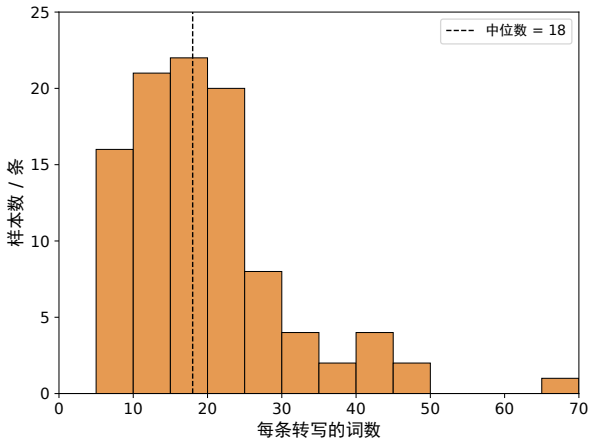


图 3.3　给定英文转写的词数分布

给定转写的词数分布如图 3.3所示。以英文字母词和数字串为计数单位，词数统计将含撇号的英文缩写或所有格形式（如 don’t、teacher’s）视为一个词，数字串单独计为一个词，其他标点不计入词数。100 条转写共包含 1932 个词，单条转写的词数为 5–65，平均值为 19.32，中位数为 18。其中，63 条转写包含 10–24 个词。这些统计反映了不同样本在文本长度上的差异，为保留各样本的实际序列长度提供依据。两幅分布图中的虚线分别表示时长与词数的中位数，这里的词数按原始转写统计，而非模型分词后得到的子词数量。

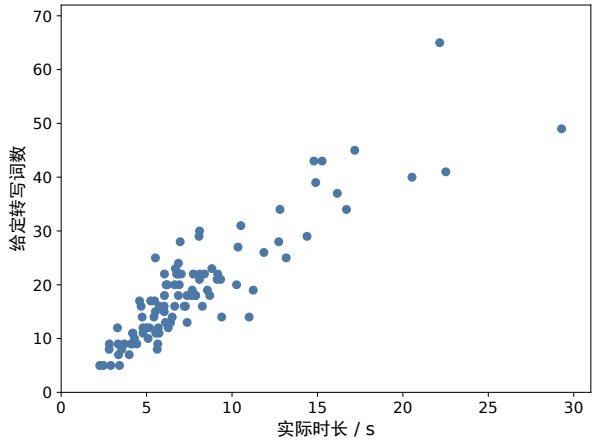


图 3.4　片段时长与转写词数的联合分布

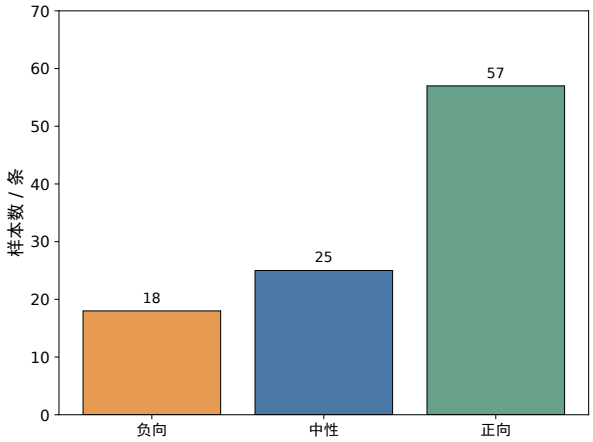


图 3.5　样本情感类别构成

图 3.4进一步展示了片段时长与转写词数的联合分布，每个点对应一条视频片段。图中可见，相近时长的片段仍可能包含不同数量的词，因此不能仅根据视频时长确定文本序

列长度。本文按各样本的实际词数保存变长序列，并保留其位置记录，以避免统一截断造成的信息损失。

原始类别标注的构成如图 3.5所示，按标签表原始 annotation 字段统计，正向、中性和负向样本分别为 57 条、25 条和 18 条，柱上标注对应样本数及占比。

原始画面的观察进一步表明，视频并非始终呈现清晰的人物面部。图 3.6展示了从附件一样本片段中选取的六个实例，涵盖人物近景、人物与板书、文字卡、器材、山体景观及图形画面。各画面取自片段时长中点处或其后的首个实际视频帧，并标注实际帧时刻、片段时长和样本编号，给定转写按标签表原文节选，省略处以省略号表示。

这些实例说明，视频帧的存在并不意味着能够提取有效的面部表情特征，因此后续需要分别记录帧的时间位置与面部观测有效性。上述画面仅反映所展示时刻的内容，不用于判断整段视频是否包含人脸或推断全体数据的场景分布，画面与转写的并列展示也不表示二者已建立词级时间对应。

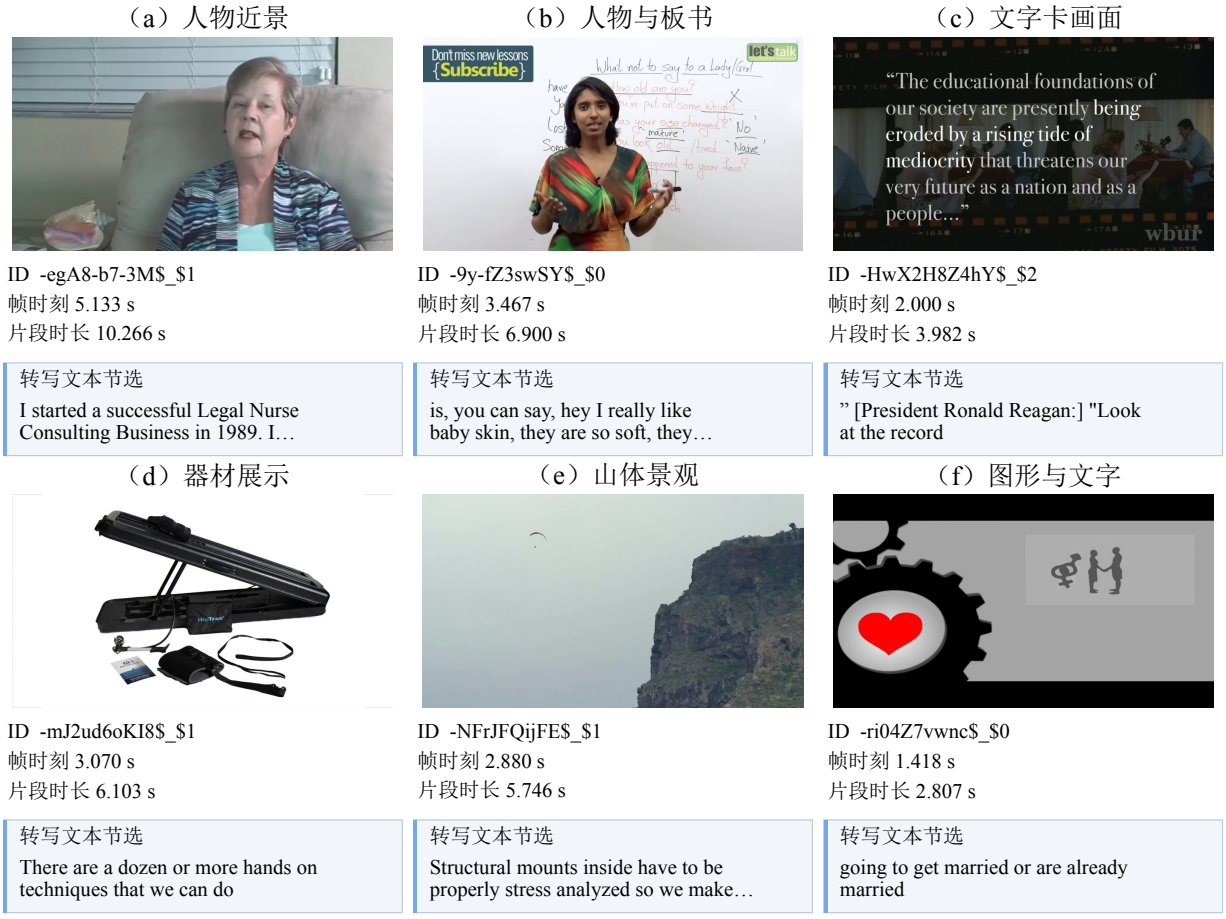


图 3.6　原始视频画面与给定转写示例

根据上述数据特点，本文分别对文本、音频和视频进行预处理，使三类输入具备明确的位置或时间记录。

在文本方面，保留标签表中的完整英文转写及其标点，并记录每个词在原文中的起止字符位置，以便后续将模型生成的子词表示对应回原始单词。考虑到声学对齐模型使用的字符形式与原始文本可能不同，另行构建用于对齐的文本副本：将字母统一为大写，将弯撇号转换为直撇号，并将数字展开为英文表达。例如，数字串 1989 在原始转写中保持不变，仅在对齐副本中转换为英文形式。规范化后的字符仍与原词对应，从而使后续估计的时间区间能够映射回原始文本。

在音频方面，首先从视频文件中解码声轨，再通过声道转换与重采样，得到采样率为 16 kHz 的单声道信号，以满足后续声学对齐模型的输入要求。为保持音频与视频的时间对应，以视频起点作为共同的时间原点，并保留音频相对于该原点的起始偏移。设音频起始时刻为 t_a，则转换后第 n 个采样点的时刻为 $t_a + n/f_s$，其中 $f_s = 16000\,\text{Hz}$，n 从 0 开始。由此，音频采样位置能够转换为明确的时间位置，为记录声学分析窗口的起止时间提供依据。

在视频方面，为控制后续逐帧人脸分析的计算量，以约 5 Hz 的目标频率抽取画面，即按约 0.2 s 的间隔选择视频帧。由于原视频中的帧时刻不一定恰好落在目标抽样时刻上，本文依据解码得到的实际显示时间戳选择帧，并同时保存其时间戳和原始帧索引。其中，时间戳用于确定画面在片段中的实际时刻，帧索引用于定位对应的原始画面。因此，后续时间计算采用实际帧时间，而不直接将抽样序号乘以 0.2 s 作为帧时刻。

经过预处理，每条样本被整理为三类输入：保留原文及词位置记录的转写文本、保留起始偏移的单声道音频，以及带有实际时间戳和原始帧索引的抽样画面。各样本保留自身的实际长度，不进行统一长度的裁剪或截断。

3.3 多模态特征提取

经过上一节的数据观察与预处理，本文已建立视频、转写文本与标签之间的对应关系，并获得保留时间信息的音频信号与抽样视频帧。文本、语音与视觉分别提供语言内容、发声方式和面部变化等信息，利用不同模态的互补性是多模态情感识别的重要研究思路 [6]。据此，本节分别构建文本语义、语音声学和面部表情特征。考虑到本问仅包含 100 条视频，且任务目标是特征提取与时间对齐，本文使用已有预训练模型完成表示构建，不利用本问情感标签训练或微调特征提取模型。

为便于说明，以下以单条视频为例，设其原始转写包含 L 个词，声学特征序列包含 N_a 个窗口，视觉特征序列包含 N_v 个抽样帧。

3.3.1 基于 DistilBERT 的文本特征提取

文本特征需要描述词在具体语境中的含义。例如，同一词在否定、转折或程度修饰的作用下，可能表达不同的语义倾向，因此仅用词的出现次数难以满足表示需求。本文采用英文预训练模型 DistilBERT[7] 提取上下文相关的词表示。该模型通过知识蒸馏获得较紧凑的 Transformer 编码结构，能够在控制计算开销的同时利用上下文信息，适合本问以冻结模型进行特征提取的处理方式。

具体而言，模型首先通过 WordPiece 将转写文本划分为子词序列，并结合子词嵌入与位置嵌入构成输入表示。子词划分允许一个词由多个已有词片段表示，而位置嵌入用于保留序列顺序。模型随后通过多层自注意力计算，使每个子词的表示吸收同一输入序列中其他位置的信息。

设某一编码层的输入表示为 $Z \in \mathbb{R}^{M\times d}$，其中 M 为该次输入的序列长度，$d = 768$ 为隐藏表示维度。对于一个注意力头，分别通过线性映射得到查询、键和值矩阵：

$$Q = ZW_Q, \qquad K = ZW_K, \qquad U = ZW_U, \tag{3.1}$$

其中 W_Q、W_K 和 W_U 为预训练模型的参数。该注意力头的输出为

$$\text{Att}(Z) = \text{softmax}\left(\frac{QK^{\mathsf{T}}}{\sqrt{d_h}}\right)U, \tag{3.2}$$

其中 d_h 为单个注意力头的查询与键维度，softmax 按行归一化。矩阵 QK^{T} 描述不同位置之间的匹配程度，归一化后的权重决定当前位置从其他位置吸收多少信息。多个注意力头的输出经拼接和线性变换后，再经过残差连接、层归一化及前馈网络，逐层形成上下文表示。

为保留文本的局部语义及其序列位置，本文采用不带分类头的预训练 DistilBERT，读取最后一层中各子词对应的 768 维隐藏向量。由于一个原词可能被划分为多个子词，随后依据原文字符区间建立词与子词的对应关系，将属于同一词的子词向量聚合为词级文本特征，为后续与声学、视觉特征进行词级时序对齐提供语义表示。

具体而言，设第 k 个词对应的子词索引集合为 $\mathcal{S}_k$，第 j 个子词的隐藏向量为 $\boldsymbol{h}_j$，则该词的文本特征定义为

$$\boldsymbol{x}_k^{(T)} = \frac{1}{|\mathcal{S}_k|} \sum_{j \in \mathcal{S}_k} \boldsymbol{h}_j, \qquad k = 1, \ldots, L. \tag{3.3}$$

采用平均聚合可以综合一个词所包含的各个子词表示，并避免直接求和使表示的尺度随子词数量增加。原始标点参与上下文编码，但不被单独赋予发音时间。最终得到 $X^{(T)} \in \mathbb{R}^{L \times 768}$，同时保留词、子词和原文字符位置之间的映射。

图 3.7以样本-3g5yACwYnA$_$3 中的原词 adhesives 为例，展示子词表示向词级表示的聚合过程。该词在原文中的字符区间为 $[21, 30)$，划分区间规则左闭右开。经 WordPiece 划分为 ad、##hesive 和 ##s，对应区间分别为 $[21, 23)$、$[23, 29)$ 和 $[29, 30)$。## 表示续接子词，不属于原文字符。完整转写参与上下文编码后，取这三个子词的最后一层隐藏向量进行平均，最终聚合得到该词对应的 768 维文本表示。

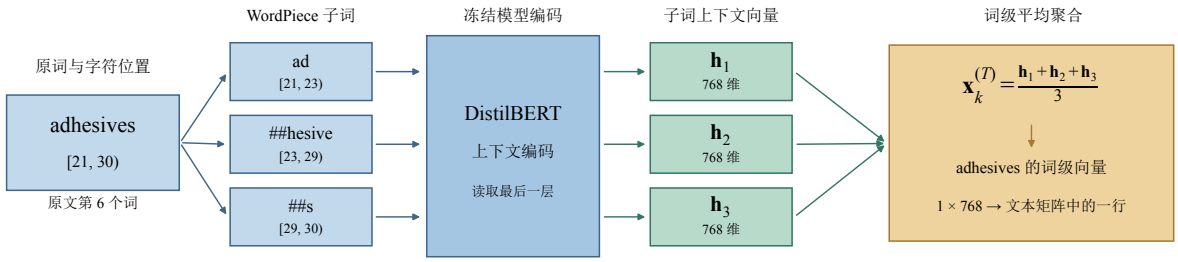


图 3.7　基于字符位置的子词映射与词级语义表示构建流程

3.3.2 基于 openSMILE 的声学特征提取

前述文本特征刻画了各词在上下文中的语义，而同一段话还可以通过不同的音高、响度和发声方式表达。为补充这些信息，本文在预处理后的音频上提取声学特征。由于后续需要将声学观测与各词对应的时间区间联系起来，本阶段保留随时间变化的局部特征序列，而不将整段语音提前压缩为一个统计向量。基于这一需求，采用 openSMILE 提取 eGeMAPSv02 的 25 维低层描述量，其组成与主要含义见表 3.1。

表 3.1　25 维声学特征的组成及含义

类别	描述量	主要描述内容	维度
响度	听觉加权与压缩后的 Loudness	感知强弱	1
基频	相对于 27.5 Hz 的半音基频	音高变化	1
频谱结构	Alpha 比、Hammarberg 指数、两项谱斜率、谱通量	频谱形状及其变化	5
倒谱	第 1 至第 4 阶 MFCC	谱包络的低阶表示	4
音质	Jitter、Shimmer 的分贝表示、基于自相关估计的 HNR、H1–H2、H1–A3	周期稳定性与谐波结构	5
共振峰	前三阶共振峰的频率、带宽及相对于基频谐波的对数幅度	声道共振特性	9
合计			25

本文采用工具既有实现提取上述描述量，以下公式用于说明代表性特征的计算原理，具体输出沿用 eGeMAPSv02 的参数与后处理规则。各描述量首先依赖对语音的短时分析：在局部窗口内分析频率组成和周期性，再通过滑动窗口描述其变化。设音频信号为 $x[n]$，采样率为 $f_s = 16000\,\mathrm{Hz}$。实际配置中，频谱分析采用 20 ms 的 Hamming 窗，基频分析采用 60 ms 的 Gaussian 窗，步长均为 10 ms，分别侧重局部谱形变化与多个振动周期的观察。

设某分析支路的窗长为 N，第 m 帧的起点为 n_m，窗函数为 $w[r]$。加窗后进行离散傅里叶变换，得到

$$S_m(\ell) = \sum_{r=0}^{N-1} x[n_m + r] w[r] \exp\left(-\mathrm{i}\frac{2\pi \ell r}{K}\right), \qquad P_m(\ell) = |S_m(\ell)|^2, \tag{3.4}$$

其中 $K \geq N$ 为傅里叶变换长度，$\ell = 0, \ldots, K-1$，不足部分补零，i 为虚数单位。本文采用的 10 ms 步长在该采样率下对应 160 个采样点。非负频率索引集合为 $\Omega_+ = \{0, \ldots, \lfloor K/2 \rfloor\}$，对应频率为 $f_\ell = \ell f_s / K$。加窗减弱了片段截断的边界影响，$P_m(\ell)$ 用于描述局部功率谱。

为描述声音的感知强弱与整体谱形，将非负频率分量汇总到 26 个梅尔频带。梅尔三角滤波器在低频处划分较细，在高频处划分较粗，第 m 帧在第 b 个频带上的能量汇总可写为

$$E_{m,b} = \sum_{\ell \in \Omega_+} H_b(\ell) P_m(\ell), \qquad b = 1, \ldots, B, \quad B = 26, \tag{3.5}$$

其中 $H_b(\ell)$ 为滤波器权重。响度与梅尔频率倒谱系数（MFCC）采用相同的频带划分思路，但分别沿用各自的输入标度设置。为区分两条支路，记其实际使用的频带能量为 $E^{(L)}_{m,b}$ 和 $E^{(C)}_{m,b}$，二者均基于上述频带汇总，不能不加区分地视为同一组数值。

响度在频带能量的基础上引入等响度加权和幂律压缩，其核心关系为

$$\mathcal{L}_m \propto \sum_{b=1}^{B} \left(q_b E^{(L)}_{m,b}\right)^{0.33}, \tag{3.6}$$

其中 q_b 为等响度权重。加权反映人耳对不同频率的敏感程度，幂律压缩描述能量与感知强弱之间的非线性关系，因此该特征的含义不同于波形均方根或声压级分贝值。

MFCC 则侧重描述能量在各频带间的分布形状。对频带能量取对数后，使用离散余弦变换提取低阶谱形分量，其核心计算为

$$\widetilde{c}_{m,k} = \sqrt{\frac{2}{B}} \sum_{b=1}^{B} \log\left(\max\left(E^{(C)}_{m,b}, \varepsilon\right)\right) \cos\left[\frac{\pi k}{B}\left(b - \frac{1}{2}\right)\right], \quad k = 1, \ldots, 4, \tag{3.7}$$

其中 ε 为数值下限，$\widetilde{c}_{m,k}$ 表示倒谱提升与时间平滑前的系数。本文保留第 1 至第 4 阶系数，并沿用工具中的倒谱提升与平滑操作。对数变换压缩动态范围，低阶余弦分量则以较少的维度概括谱包络，由于系数是投影结果，其值可以为正或负。

语音的音高起伏由基频进一步描述。基频 F_0 表示有声段的基本重复频率，对应周期为 $T_0 = 1/F_0$。实际配置采用次谐波方法综合 15 个谐波的信息，压缩因子为 0.85，并结合有声判定与 Viterbi 轨迹平滑形成基频输出。对于得到有声估计的位置，将基频转换为相对于 27.5 Hz 的半音表示：

$$p_m = 12 \log_2 \left(\frac{F_{0,m}}{27.5\,\mathrm{Hz}} \right). \tag{3.8}$$

这一变换将频率比转换为音高差，例如 220 Hz 对应 36 个半音，基频翻倍则增加 12 个半音。对于未获得有声基频输出的位置，工具保留零标记，该标记不表示整条声学记录缺失。

各描述量沿用配置中的标度、有效周期筛选及三帧轮廓平滑规则，其中部分特征采用非零值平滑，本文直接读取处理后的 25 维序列。为观察这些描述量如何反映实际声音的变化，选取样本-egA8-b7-3M$_$1 在 1.00–3.20 s 内的语音，将波形与响度、半音基频和第一阶 MFCC 置于同一时间轴上，如图 3.8所示。

图中特征曲线直接取自已保存结果，以工具返回区间的中点标示记录时刻，基频零标记以断线显示。虚线标出记录中心为 1.50 s 和 2.00 s 的两组观测，各纵轴保留相应描述量的原始标度，不同曲线的数值大小不作直接比较。

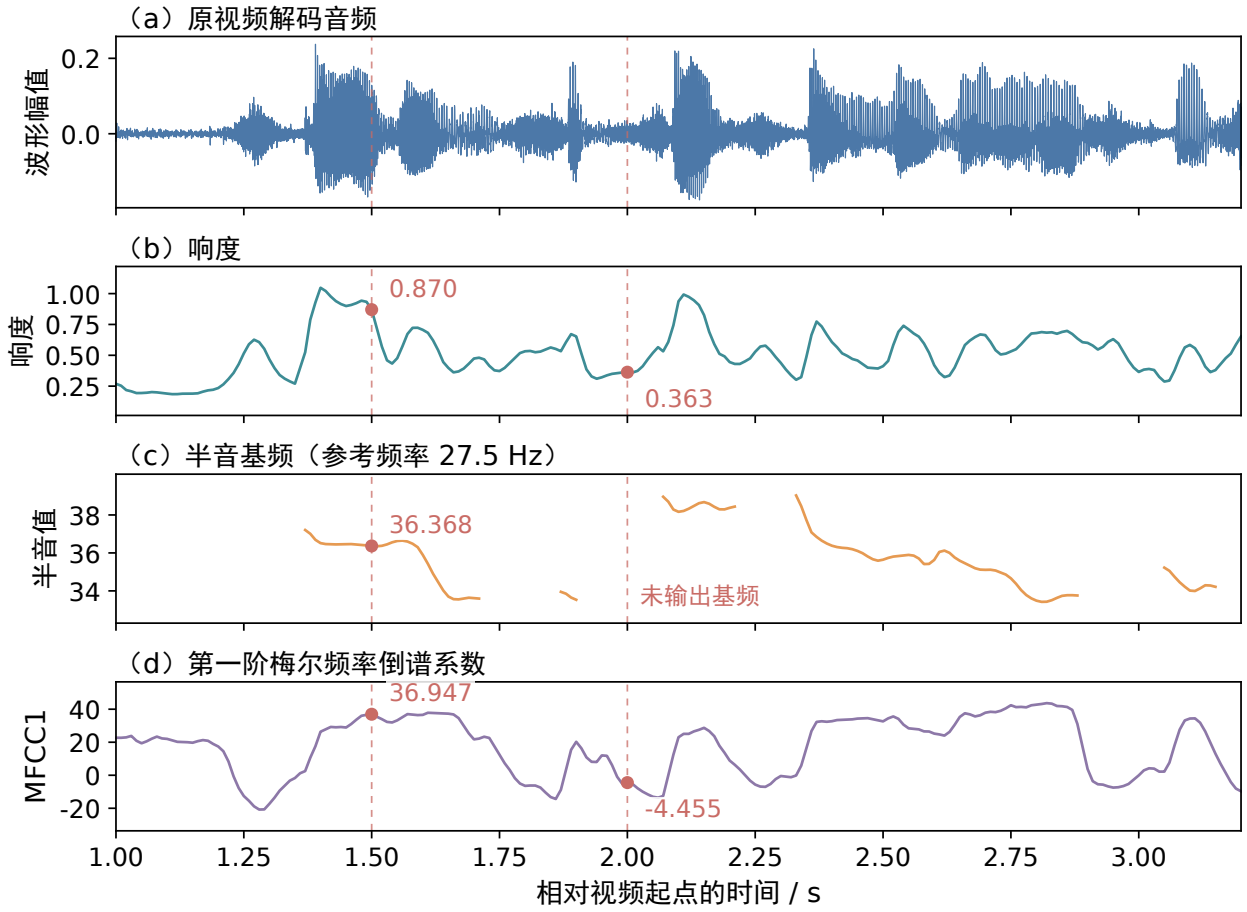


图 3.8　同一语音片段的波形与声学特征

表 3.2列出了图中两组观测的具体数值。两条记录均具有有效音频观测，但第二条没有基频输出，说明声学记录的有效性与某一描述量是否得到估计应分别判断。该区间的响

度和 MFCC 仍提供可用声学信息，MFCC 的负值属于正常的投影结果，不能解释为能量为负。

表 3.2　两组声学观测的数值与有效性对照

记录区间/s	中心时刻/s	响度	半音基频	MFCC1	记录有效
$[1.49, 1.51]$	1.50	0.870	36.368	36.947	是
$[1.99, 2.01]$	2.00	0.363	0^*	-4.455	是

注：0^* 表示未输出有声基频时保留的零标记，不作为实际音高解释。

为使局部声学观测进一步参与词级对齐，按输出顺序保存各时刻的 25 维向量。设第 m 个声学向量为 $\boldsymbol{a}_m \in \mathbb{R}^{25}$，共有 N_a 条记录，则原生声学特征矩阵为

$$A = \begin{bmatrix} \boldsymbol{a}_1^{\mathsf{T}} \\ \boldsymbol{a}_2^{\mathsf{T}} \\ \vdots \\ \boldsymbol{a}_{N_a}^{\mathsf{T}} \end{bmatrix} \in \mathbb{R}^{N_a \times 25}. \tag{3.9}$$

每行特征另关联工具返回的起止时间与观测有效标记，时间和标记均不计入 25 维特征。输出时间区间用于组织特征记录，而不同描述量内部采用的分析窗长并不相同，部分描述量还经过时间平滑。因此，后续将返回区间作为声学记录的时间支持近似，而不将其解释为所有描述量共同依赖的完整波形范围。

此时，矩阵 A 的每行对应一条声学记录，尚未与文本中的词一一对应。在后续词级时序对齐阶段，本文将根据候选词区间与声学记录区间的时间交叠关系进行加权聚合，形成与词级文本特征对应的声学表示。

3.3.3 基于 MediaPipe 的视觉特征提取

视觉特征侧重提取面部变化线索。眉部运动、眼睑开合和嘴部形态等变化能够补充文本语义与发声方式，因此本文采用 MediaPipe Face Landmarker 输出的面部 blendshape 系数作为视觉表示。该表示具有固定的维度与字段名称，便于逐帧记录并按时间聚合，其描述范围主要是面部形态与表情变化，不覆盖画面中的全部场景信息或肢体动作。按输出字段分组，52 维系数的组成及代表性含义见表 3.3。

表 3.3　52 维面部系数的分组及代表性含义

分组	代表性输出	主要描述内容	维度
额眉部	压眉、内侧抬眉、外侧抬眉	眉部位置与形态	5
眼部	眨眼、睁大、眯眼及视线方向	眼睑状态与眼部运动	14
面颊与鼻部	鼓腮、面颊收紧、鼻部牵动	面中部形态	5
嘴部	嘴角上扬或下压、噘嘴、嘴唇收紧等	嘴唇及嘴角形态	23
下颌	张嘴、下颌前伸及左右移动	下颌位置与开合	4
其他输出项	_neutral	官方建议忽略，本文保留	1
合计			52

其中，_neutral 为工具输出中官方建议忽略的字段。本文为保持原始输出结构而保留该维，不赋予其中性情感含义。因此，52 维表示包含 51 个具体面部形态相关分量及 1 个不作语义解释的输出项。

本文采用预训练模型提取面部表情特征，处理过程包括人脸检测、面部关键点估计和表情系数预测。对于第 m 个抽样画面，先检测人脸并估计面部关键点，再根据选定人脸的关键点信息预测 52 维表情系数，记为 $\boldsymbol{c}_m \in \mathbb{R}^{52}$。

向量 $\boldsymbol{c}_m$ 的各分量描述相应面部形态的激活程度，多个分量可以同时取较高值，因此该向量不表示互斥情感类别的概率分布。

本文保留各系数的连续输出，而不将其转换为单一表情类别，以记录多个面部部位的共同变化及其随时间的变化幅度。对于具有左右侧区分的分量，分别保留对应输出，以记录可能存在的面部运动不对称性。所有帧均采用相同的字段顺序，使同一列始终对应同一种面部描述量，为后续按词区间聚合提供一致的特征含义。

对预处理得到的抽样帧逐帧进行检测，不在帧间额外引入跟踪或平滑。当同一画面检测到多张人脸时，根据关键点包围区域的面积选择最大人脸作为当前帧的特征来源。这是一项统一的选择规则，并不保证所选人脸一定属于说话者。对于没有获得可用面部特征的画面，保留该帧位置，以零向量占位并设置无效标记，避免将观测缺失解释为中性表情。设视觉观测有效标记为 $o_m^{(V)} \in \{0, 1\}$，保存的视觉特征为

$$\boldsymbol{v}_m = \begin{cases} \boldsymbol{c}_m, & o_m^{(V)} = 1, \\ \boldsymbol{0}, & o_m^{(V)} = 0. \end{cases} \tag{3.10}$$

有效帧中某个系数较低，表示该分量的模型输出较低。无效帧中的全零向量仅用于占位，不能作为实际面部观测参与聚合。

为区分面部系数变化与观测缺失，选取样本-wny0OAz3g8$_$9，将实际抽样画面与张嘴、左右嘴角上扬及左右眼睑闭合系数置于同一时间轴上，如图 3.9所示。该样本共包含 31 个抽样帧，其中 29 帧获得可用面部特征。

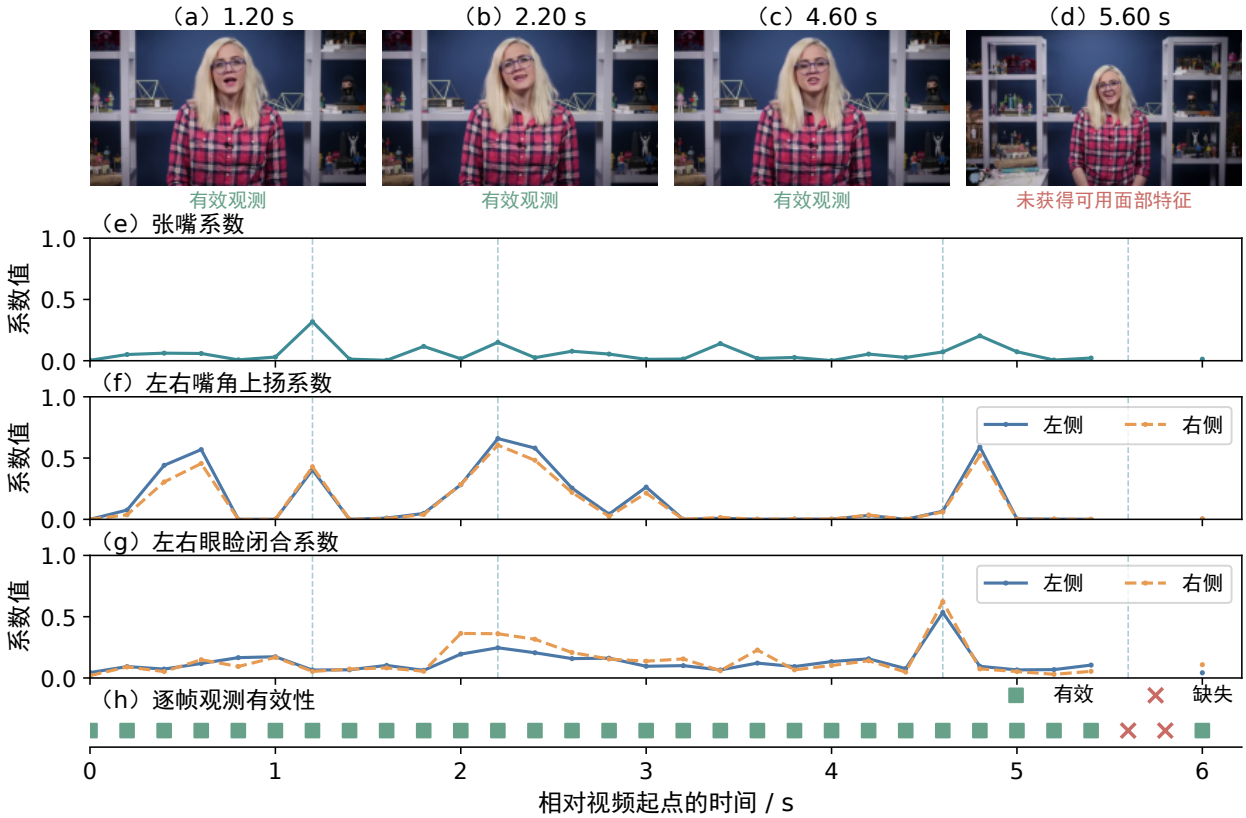


图 3.9　面部系数变化与观测有效性示例

图中曲线直接读取已有输出，各数据点对应抽样帧，连线仅辅助观察变化，缺失位置以断线表示。竖向虚线标示上方四帧的实际时刻，底部标记显示各抽样时刻的观测有效性。该例仅用于说明特征含义与缺失处理，不代表全体样本的检测表现。

在 1.20 s 处，张嘴系数为 0.318，对应画面中可见的张口形态；在 2.20 s 处，左右嘴角上扬系数分别为 0.659 和 0.605；在 4.60 s 处，左右眼睑闭合系数分别升至 0.535 和 0.623。不同系数在不同位置呈现变化，说明保留多维连续表示能够分别记录各面部部位的运动线索。这些数值描述模型对面部形态的输出，不能直接解释为某种情感的概率。

在 5.60 s 和 5.80 s 处，工具未获得可用面部特征，因而对应位置的观测标记为 0。图中 5.60 s 的画面仍可见人物，表明“未获得可用面部特征”不能直接等同于“画面无人”。这两帧的占位零向量不作为表情变化绘入曲线，也不参与后续有效特征的加权聚合。

按抽样顺序排列后，得到原生视觉特征矩阵 $V \in \mathbb{R}^{N_v \times 52}$，其中 N_v 为抽样帧数。每行特征另关联实际时间戳 $t_m^{(V)}$、原视频帧索引和观测有效标记，使各行能够回溯至具体画面。时间及有效标记均不计入 52 维特征，后续聚合时与特征矩阵共同使用。

综合三条特征提取支路，每条视频形成词级文本表示、窗口级声学表示和帧级视觉表示：

$$X^{(T)} \in \mathbb{R}^{L \times 768}, \qquad A \in \mathbb{R}^{N_a \times 25}, \qquad V \in \mathbb{R}^{N_v \times 52}. \tag{3.11}$$

其中 L、N_a 和 N_v 分别为词数、声学记录数和抽样视频帧数。三个矩阵的行具有不同的组织单位，尚不能直接按序列位置对应。下一节将结合给定转写与音频估计词级时间边界，再依据时间交叠关系聚合有效声学与视觉特征，建立统一词位置的三模态表示。

3.4 三模态特征的词级时序对齐

上一节分别获得了词级文本特征、窗口级声学特征和帧级视觉特征。然而，三类特征的行索引具有不同含义：文本特征按原文词序排列，声学特征对应短时音频记录，视觉特征对应抽样视频帧。因此，即使属于同一条视频，三个特征矩阵中相同行号的记录也未必对应同一时间段，尚不能直接按行建立三模态对应关系。

为此，本文以原始转写中的词为共同组织单位，分两步完成时序对齐。首先，利用给定转写与音频进行基于 CTC 的强制对齐，估计每个词在音频中的起止时间。该步骤建立文本词与音频时间之间的联系，为后续特征聚合提供词级时间区间。其次，由于声学记录与视频帧均保留了相对于视频起点的时间信息，可将它们与词级时间区间置于同一时间轴上，并依据时间交叠关系及观测有效性，对声学和视觉特征分别进行加权聚合。

经过上述处理，每个词均关联其文本表示及对应时间区间内的声学、视觉表示，三类特征由不同粒度的序列转化为具有相同词序的特征矩阵。对于缺少有效声学或视觉观测的词位置，保留相应的无效标记。词级时间边界的可靠性则在后续样本质量核验中进一步评估。

3.4.1 基于 CTC 的文本与音频词级强制对齐

给定转写提供了词的内容及排列顺序，但没有说明每个词在音频中的出现时间。因此，本节的任务是在已知文本的条件下，确定各词对应的起止时间。本文首先利用预训练的 Wav2Vec2 模型 [8] 估计音频各输出时刻的字符概率，再通过连接时序分类（Connectionist Temporal Classification，CTC）[9] 约束下的强制对齐，建立文本字符与音频时间之间的对应关系，最后将字符时间位置合并为词级时间区间。

本文采用第 3.2 节构建的规范化转写文本作为对齐目标，并保留其中字符与原文词之间的映射关系。由此，后续获得的字符时间位置能够合并回对应的原文词，使词级时间区间与已有文本特征保持一致的词索引。

将预处理后的单声道音频输入 Wav2Vec2，得到各输出时刻对应的字符概率。记 $p_r(c)$ 为第 r 个输出时刻对应字符 c 的概率，其中候选符号除文字字符和词界符外，还包括 CTC 空白符 $\varnothing$。空白符表示该时刻不输出目标字符，不直接等同于音频中的静音。模型在此过

程中保持参数固定，仅用于提供字符概率。

由于一个字符可能持续多个输出时刻，文本字符与模型输出之间并非一一对应。CTC 允许同一字符连续重复出现，也允许路径中包含空白符。如图 3.10所示，给定词 HELLO 对应的示例路径可以多次输出 H 或 L。先合并连续重复符号，再删除空白符，即可还原字符序列。其中，两组 L 由空白符分隔，因此在折叠后仍保留为两个字母，最终得到 HELLO。

保留字符在原始路径中的时间位置，可确定图示词的候选时间区间 $[t_1, t_{13}]$。图中字符位置与时间刻度均为示例，仅用于说明路径折叠与时间定位过程。

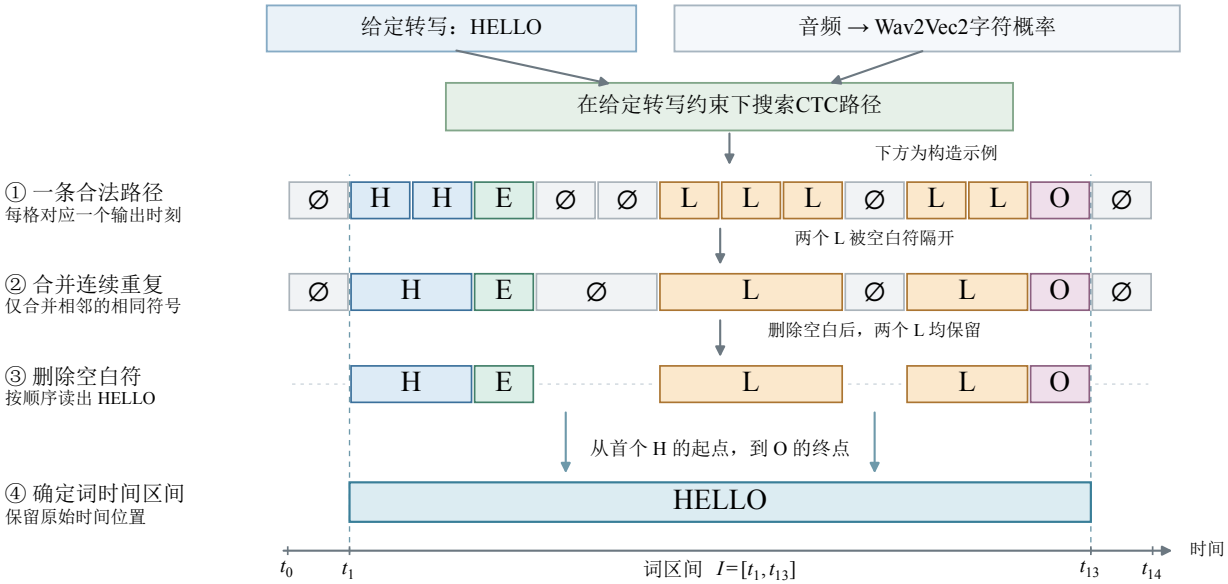


图 3.10　CTC 路径折叠与词级时间定位示意

上述合并与删除操作用于判断一条路径是否与给定文本一致，并不丢弃字符原先对应的时间位置。对于同一段转写，通常存在多条满足条件的路径。本文根据音频的字符概率，从中选择整体概率最大的一条。设规范化后的目标字符序列为 $\boldsymbol{y}$，模型共有 R 个输出时刻，路径为 $\boldsymbol{\pi} = (\pi_1, \ldots, \pi_R)$，并用 $\mathcal{B}$ 表示先合并连续重复符号、再删除空白符的操作，则最优路径为

$$\boldsymbol{\pi}^* = \arg\max_{\boldsymbol{\pi}:\, \mathcal{B}(\boldsymbol{\pi})=\boldsymbol{y}} \sum_{r=1}^{R} \log p_r(\pi_r). \tag{3.12}$$

其中，约束 $\mathcal{B}(\boldsymbol{\pi}) = \boldsymbol{y}$ 保证路径还原后的字符内容与顺序符合给定转写，目标函数则用于比较这些合法路径对音频的匹配程度。本文采用动态规划求解，并通过回溯获得各目标字符对应的输出时刻。

得到字符位置后，依据模型输出的时间步长及音频起点偏移，将这些位置统一转换到以视频起点为原点的时间轴上。随后，根据字符与原文词之间的映射，取每个词首个文字字符的起点与末个文字字符的终点，形成该词的候选时间区间。

具体地，设 $\mathcal{R}_k$ 为最优路径中分配给第 k 个原文词所属文字字符的输出时刻索引集合，不包含空白符与词界符，第 r 个输出时刻对应的时间区间为 $[a_r, b_r]$。当 $\mathcal{R}_k$ 非空时，定义

$$I_k = [s_k, e_k], \qquad s_k = \min_{r \in \mathcal{R}_k} a_r, \qquad e_k = \max_{r \in \mathcal{R}_k} b_r. \tag{3.13}$$

例如，图 3.10中，HELLO 的时间区间从首个 H 的起点延伸至 O 的终点。词内部的空白位置包含在该区间内，首尾之外的空白位置则不纳入。因此，相邻词的区间不必首尾相接。

在保存词时间区间的同时，本文记录相应的对齐置信度，供后续质量核验使用。若无法获得覆盖给定转写的合法路径，或某个词没有对应的字符时刻，则标记对齐失败，不以均匀分配时间的方式补造词边界。

经过上述处理，原文中的词获得了候选时间区间，并保持与词级文本特征相同的词索引。下一步将以这些区间为共同参照，根据时间交叠关系聚合声学与视觉特征，使三种模态在同一词位置上建立对应关系。

3.4.2 基于词时间区间的声学与视觉特征加权聚合

上一节获得了各词的候选时间区间，但声学特征仍按短时记录排列，视觉特征仍对应离散视频帧。为使它们与词级文本特征逐行对应，本文以词时间区间为共同参照，将与该区间存在时间交叠的有效声学和视觉观测分别进行加权聚合。交叠时间越长，表示该条观测在时间上与当前词的关联范围越大，因此赋予其更高的聚合权重。

首先，需要明确每条声学与视觉记录所代表的时间区间。对于声学特征，采用提取工具返回的起止时间，并统一到以视频起点为原点的时间轴上。由于不同声学描述量内部采用的分析窗长及平滑方式不完全相同，该区间作为声学记录的时间支持近似，不将其解释为全部描述量共同依赖的完整波形范围。

对于视觉特征，抽样帧本身仅具有时间戳，需要进一步构造其代表的时间区间。本文以相邻抽样帧时间戳的中点作为分界，使每帧代表时间上距离它最近的一段画面。设抽样帧时间戳依次为 $t_1^{(V)}, \ldots, t_{N_v}^{(V)}$，片段总时长为 T，定义区间边界

$$b_0 = 0, \qquad b_j = \frac{t_j^{(V)} + t_{j+1}^{(V)}}{2}, \quad j = 1, \ldots, N_v - 1, \qquad b_{N_v} = T, \tag{3.14}$$

则第 j 帧的代表区间为 $J_j^{(V)} = [b_{j-1}, b_j]$。这一处理将离散帧转换为可计算时间交叠的区间，是对帧间视觉状态的近似表示，并不意味着表情在整个区间内完全不变。

为直观说明加权过程，图 3.11 以三条视觉记录为例。假设某词的候选时间区间为 $[1.00, 1.45]$（图中虚线范围），与三帧代表区间的交叠时长分别为 0.10 s、0.20 s 和 0.15 s。其中第二帧（图中灰色斜线区域）没有可用面部特征，因此不参与聚合。将其余两条有效观测记录（图中草绿色区域）的交叠时长归一化，得到权重 0.4 和 0.6，该词的视觉特征即为 $\widehat{\boldsymbol{v}} = 0.4\boldsymbol{v}_1 + 0.6\boldsymbol{v}_3$。声学特征采用相同规则单独聚合，已有的词级文本特征保持不变。

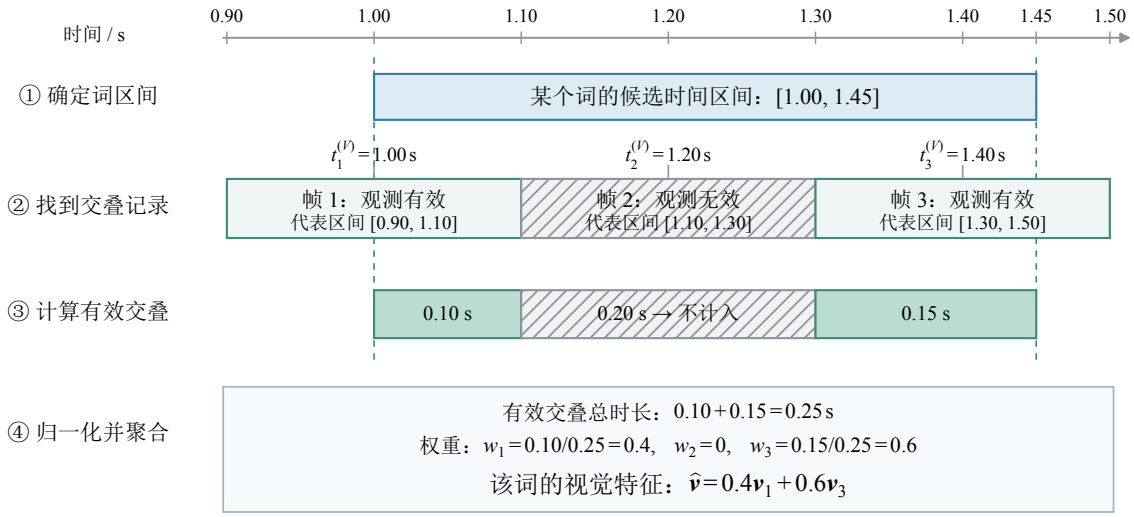


图 3.11　基于词时间区间的加权聚合示意图

为统一描述两种模态，记 $M \in \{A, V\}$ 分别表示声学与视觉模态，$\boldsymbol{x}_j^{(M)}$ 为第 j 条原生

特征，$J_j^{(M)} = [u_j^{(M)}, v_j^{(M)}]$ 为其对应时间区间，$o_j^{(M)} \in \{0,1\}$ 为观测有效标记。对于第 k 个词的时间区间 $I_k = [s_k, e_k]$，其与第 j 条记录的有效交叠时长定义为

$$d_{kj}^{(M)} = o_j^{(M)} \max\left\{0,\, \min\left(e_k, v_j^{(M)}\right) - \max\left(s_k, u_j^{(M)}\right)\right\}. \tag{3.15}$$

当两个区间不相交，或该条观测无效时，$d_{kj}^{(M)} = 0$，相应特征不参与聚合。例如，没有获得可用人脸特征的视频帧即使落在词区间内，也不会将其占位零向量计入有效观测的平均值。

将同一词对应的有效交叠时长归一化，得到聚合权重：

$$D_k^{(M)} = \sum_{j=1}^{N_M} d_{kj}^{(M)}, \qquad w_{kj}^{(M)} = \begin{cases} \dfrac{d_{kj}^{(M)}}{D_k^{(M)}}, & D_k^{(M)} > 0, \\ 0, & D_k^{(M)} = 0, \end{cases} \tag{3.16}$$

其中，$N_A = N_a$、$N_V = N_v$，分别为声学记录数与抽样帧数。当存在有效交叠时，同一词在同一模态下的聚合权重之和为 1。例如，若某词仅与两条有效视觉记录发生交叠，交叠时长分别为 0.06 s 和 0.14 s，则归一化后的权重分别为 0.3 和 0.7。

据此，第 k 个词对应的聚合特征及观测有效标记为

$$\widehat{\boldsymbol{x}}_k^{(M)} = \sum_{j=1}^{N_M} w_{kj}^{(M)} \boldsymbol{x}_j^{(M)}, \qquad \widehat{o}_k^{(M)} = \begin{cases} 1, & D_k^{(M)} > 0, \\ 0, & D_k^{(M)} = 0. \end{cases} \tag{3.17}$$

若某词区间内没有有效观测，则聚合结果为零向量，并设置无效标记。因此，后续使用特征时需要同时读取该标记，不能仅凭零值判断声音或面部表情的状态。对于未获得有效候选时间区间的词，也保留其原有词位置，并将相应聚合结果标记为无效。

需要说明的是，声学记录的时间区间可能相互重叠，因此 $D_k^{(A)}$ 是各条记录与词区间的交叠时长之和，可能大于词本身的持续时间。它仅用于归一化聚合权重，不等同于有效音频覆盖时长。此外，一条原生记录若与相邻两个词均有交叠，可以分别参与两个词的聚合，无须被强行划归其中一个词。

按原文词序排列聚合结果后，每条样本得到

$$X^{(T)} \in \mathbb{R}^{L\times 768}, \qquad \widehat{A} \in \mathbb{R}^{L\times 25}, \qquad \widehat{V} \in \mathbb{R}^{L\times 52}, \tag{3.18}$$

其中，L 为原文词数，词级文本特征 $X^{(T)}$ 保持不变。三个矩阵的第 k 行均对应第 k 个原文词，从而建立统一词位置的三模态表示。同时保留词时间区间、参与聚合的原生记录索引、聚合权重及观测有效标记，使词级特征能够回溯至对应的音频记录和视频帧。

上述聚合建立了三种模态在词位置上的对应关系，但观测有效并不意味着词时间边界一定可靠。例如，某词区间内可能存在可用人脸，而该词的时间定位置信度仍然较低。因此，后续样本质量核验将分别检查观测有效性与对齐时间质量，为聚合结果的使用提供依据。

3.5 实验结果分析

前文已通过三模态特征提取、CTC 强制对齐与时间交叠加权，将原始视频及给定转写转化为具有统一词位置的特征序列。本节进一步检验这些输出能否回应赛题提出的原始样本覆盖完整性、时序组织可核验性，以及方法合理性与可复现性要求。具体而言，先核对样本及模态观测的覆盖范围，再依次通过自动诊断、固定窗口对照与人工审核，考察候选对应的筛选范围、时间划分的影响及输入异常的来源。随后以典型样本验证特征与原始素材之间的映射，最后给出全部 100 条样本的结果汇总、文件读取方式和复现流程。由此，将前文的方法定义落实为能够逐样本查阅、按记录复算的特征输出。

3.5.1 样本覆盖完整性与特征有效性

为检查原始样本覆盖完整性，本文以视频编号和片段编号组成的唯一标识，核对原始视频、给定转写、标签记录与输出目录。已有全量核验结果表明，附件 1 的 100 条样本均具有对应输出，原文及标签与输入记录一致，源视频哈希核对通过。各样本分别生成 768 维文本、25 维声学和 52 维视觉词级特征，三种矩阵的行数均等于该样本的原文词数，共保留 1932 个词位置，未发生长度截断。表 3.4在样本覆盖的基础上进一步统计各模态的观测状态，其中样本比例以 100 为分母，词比例以 1932 为分母。

表 3.4　样本处理与三种模态的观测覆盖情况

统计项目	数量	占比
已处理样本	100	100.00%
与原文对应的输出词位置	1932	100.00%
文本模态可观测的词	1932	100.00%
声学模态可观测的词	1932	100.00%
视觉模态可观测的词	1595	82.56%

完整生成输出文件并不意味着每个词位置都具有同等充分的模态信息。前文原始画面观察已显示，部分时刻难以获得可用人脸；图 3.12进一步给出这一现象在全量数据中的范围。3973 帧抽样画面中，3253 帧获得面部特征，720 帧未获得可用结果；按候选词区间聚合后，1595 个词具有有效面部记录，337 个词缺少相应记录。由于一帧可以参与多个词的聚合，一个词也可以关联多帧，帧级与词级覆盖率分别以各自记录总数为分母。该结果说明，视觉缺失需要作为输出状态显式保存，不能仅根据三模态矩阵是否具有相同行数判断其信息是否完整。

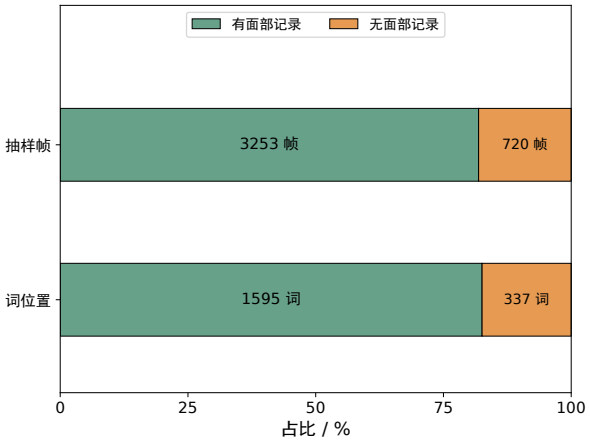


图 3.12　面部特征的帧级与词级覆盖

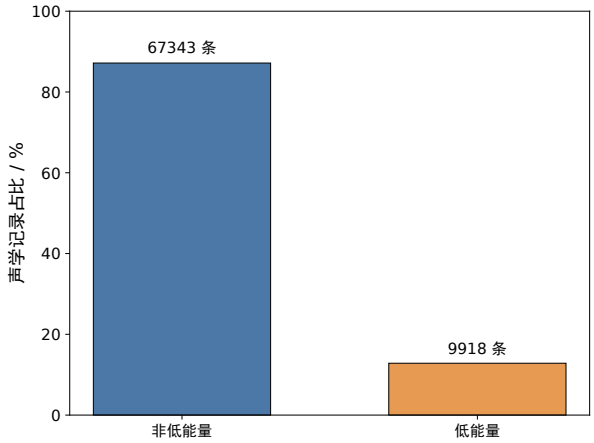


图 3.13　声学记录的低能量占比

声学模态则呈现不同的情况：所有词位置均有可计算记录，但原生声学序列的幅度状态存在明显差异。以数字音频满幅 1 为基准，将短时均方根幅度（RMS）低于 0.0031623 的记录标记为低能量，77261 条记录中共有 9918 条满足该条件，占 12.84%，如图 3.13所示。该标记用于保留低幅度状态，不作为无语音或观测缺失的直接判据，因此不会据此删除记录或改变原文词位置。

图 3.14与图 3.15以样本-iRBcNs9oI8$_$9 说明上述标记的时间分布。该样本 333 条 RMS 记录中有 147 条低于阈值，完整幅度图显示若干较强峰值，保持相同横轴的低幅值

放大图则呈现峰值之间及片段末端的低能量区间。橙色虚线为阈值，橙点为低于阈值的记录。两图表明，声学输入状态随时间变化，采用逐记录标记能够保留整段平均统计无法呈现的局部差异。

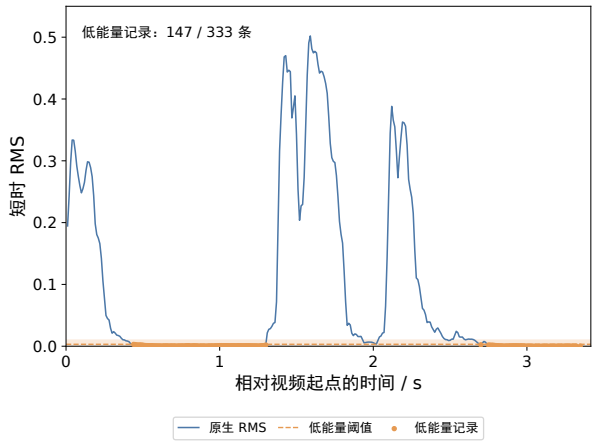


图 3.14　实例音频的短时 RMS

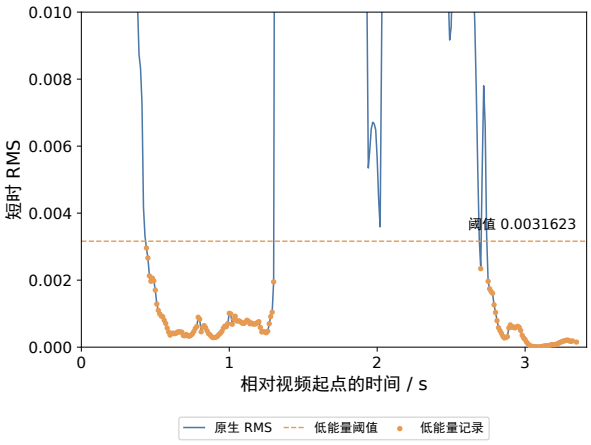


图 3.15　同一时间范围的低幅值放大

另有两条样本的解码音频波形全为零，其声学特征各维均不随时间变化。结合视觉缺失与声学低能量结果可知，样本覆盖、模态观测和转写对应关系需要分别检查。本文保留全部样本及原始词位置，对视觉缺失采用零向量占位和无效标记，对低能量记录保留幅度状态。这种处理既维持了输入与输出的一一对应，也使异常位置能够被单独识别。在此基础上，下一步需要判断候选词时间区间是否得到实际音频的支持。

3.5.2 时序对齐质量评估与人工审核

前文的词级聚合以候选时间区间为依据，其可靠性直接影响哪些声学和视觉记录被分配到同一词位置。因此，时序组织的检查不能停留在矩阵行数一致，还需要评估给定转写与实际语音的匹配情况。本次 CTC 强制对齐为 1932 个词均生成候选区间，但满足字符路径约束只能说明算法获得了合法解，不能保证真实词界准确。本文据此设置局部词匹配与整段文本差异两个诊断层次，并用人工审核解释整段异常。

词级置信度取最优 CTC 路径中属于该词的文字字符帧概率的几何平均，不含空白符和词界符，用于描述模型对局部匹配的支持程度。片段级诊断词错误率（Word Error Rate，WER）则将无转写约束的贪心识别文本与规范化转写比较，以最少词编辑数除以参考词数，反映整段文本的差异。二者分别考察局部与整体：某些词即使得分较高，也可能处于整段内容不对应的片段中。由于两项指标来自同一声学模型，以下将其用于质量筛查，而不将其视为独立的词界准确性评价。WER 包含插入操作，取值可以超过 1。

图 3.16与图 3.17显示，词级置信度与片段级 WER 均存在需要关注的异常区域。1932 个词的置信度中位数为 0.9585，1034 个词不低于 0.95，但仍有 350 个词低于 0.1。100 条片段的诊断 WER 均值为 0.4689，其中 21 条超过 0.8，9 条超过 1。图中的虚线和阴影分别标示对应阈值与关注区域。这些结果说明，整体较高的词级得分不足以支持无差别使用全部候选区间，需要进一步结合片段状态确定可用范围。

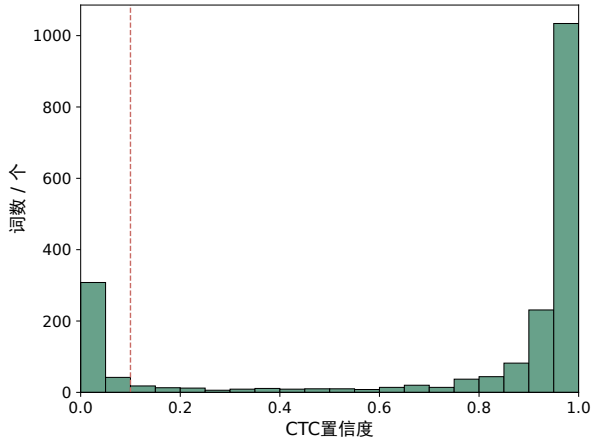


图 3.16　词级 CTC 置信度分布

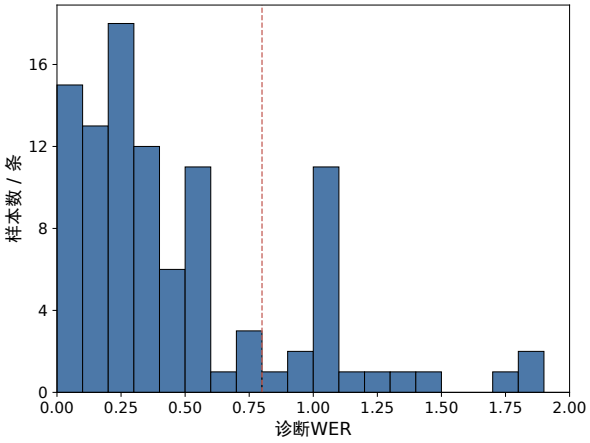


图 3.17　片段级诊断 WER 分布

本文采用片段级与逐词两层筛选，将上述诊断落实为可随特征文件保存的质量标记。首先，平均词置信度低于 0.2、置信度低于 0.1 的词超过一半、诊断 WER 大于 0.8，或无法形成完整 CTC 路径的样本均列入整段复核，暂不采用其词级时间对应。其次，在其余样本中，仅将成功获得候选起止时间且置信度不低于 0.1 的词计为通过筛选。这些阈值作为保守检查条件，未利用情感标签或人工词界标注优化，筛选改变的是词级对应的使用标记，不删除样本、词位置或原始特征。

图 3.18将两层筛选与模态观测检查串联起来。在 100 条样本中，19 条的平均词置信度低于 0.2，20 条有超过一半的词置信度低于 0.1，21 条的诊断 WER 大于 0.8，没有样本因无法形成完整 CTC 路径而被标记。这四项条件分别检查，每条样本只要满足其中任一项就进入整段复核，同一样本可能同时满足多项条件，因此各项数量不能直接相加。本次前两项标记的样本均已包含在 WER 大于 0.8 的 21 条样本中，去除重复计数后，需整段复核的仍为 21 条，共涉及 317 个词。其余 79 条样本包含 1615 个词，其中 70 个因置信度不足未通过逐词筛选，剩余 1545 个通过筛选，占全部词的 79.97%。这 1545 个词中，158 个缺少有效面部记录，1387 个同时满足对齐筛选和三模态可观测条件，占全部词的 71.79%。

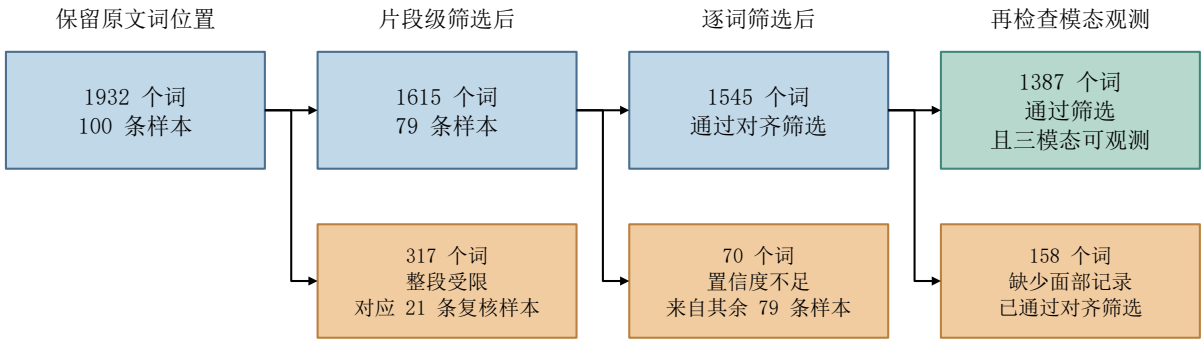


图 3.18　从全部词位置到满足不同使用条件的词位置：各分支数量可逐项核对

图中各分支均对应明确的使用条件，而非对原始数据的删减。317 个整段受限词中包含 37 个局部置信度达到阈值的词，因而未通过筛选的 387 个词多于低置信度词的 350 个。另一方面，通过时间筛选但缺少面部记录的 158 个词仍保有文本与声学信息，只是不满足三模态同时可观测的条件。因此，后续读取词级输出时需要分别使用对齐质量标记与模态观测标记，区分“存在可计算记录”和“满足当前对齐筛选条件”这两种状态。

进一步将片段平均置信度阈值取 0.1、0.2、0.3，诊断 WER 阈值取 0.6、0.8、1.0，其余条件保持不变。在三种平均置信度阈值下，待复核样本数均随 WER 阈值变化依次为 25、21、20 条，表明当前数据的复核数量主要受 WER 条件影响。该检查反映筛选范围对阈值的敏感性，不能据此确定最优阈值或计算真实对齐准确率。

上述筛选回答了候选时间对应的使用范围，但尚未说明采用何种时间单元组织特征更便于保留信息。前文以词作为共同单位，是为了使文本语义单元与相应时段的视听记录保持明确联系。为考察统一时间切分可能带来的影响，本文在相同原生特征上构造 0.2 s 和 0.5 s 固定窗口作为补充对照，窗口均从零时刻开始，末窗截取至片段终点，并沿用有效时间交叠加权规则。该实验关注平均聚合对局部变化的保留程度，以及固定边界对词区间完整性的影响，为时间组织方式的合理性分析提供依据。

固定窗口对照包含聚合与重建两个步骤：首先分别聚合两种窗口内的原生特征，再根据时间交叠关系将窗口特征映回原生记录位置，以便与原序列比较。图 3.19以响度展示重建结果，灰线为原生记录，蓝线与橙线分别对应短窗和长窗。窗口平均削弱了原曲线的局部峰谷，较长窗口的平滑范围更大，说明统一时间汇总在压缩序列的同时会改变局部特征变化。这里的重建对象是特征序列，而非原始音频波形。

图 3.20检查同一样本中的词区间是否被固定窗口切分。绿色线为 successful 的候选区间 $[1.84247, 2.40247]$ s，上、下两排分别为 0.2 s 和 0.5 s 窗口。该词分别与 4 个短窗和 2 个长窗交叠，在两种划分下均计为一个跨界词。第四个短窗的交叠仅约 0.00247 s，图中以箭头注明，统计时将大于 10^{-8} s 的交叠视为有效交叠。跨界指标只判断是否与至少两个窗口交叠，不区分交叠窗口数量及切分幅度。

上述图示采用样本-egA8-b7-3M$_$1。其选取条件为未触发整段复核、面部观测帧占比不低于 80%，且时长最接近 10 s。该样本实际时长 10.266 s，包含 20 个词，其中 18 个通过对齐筛选。

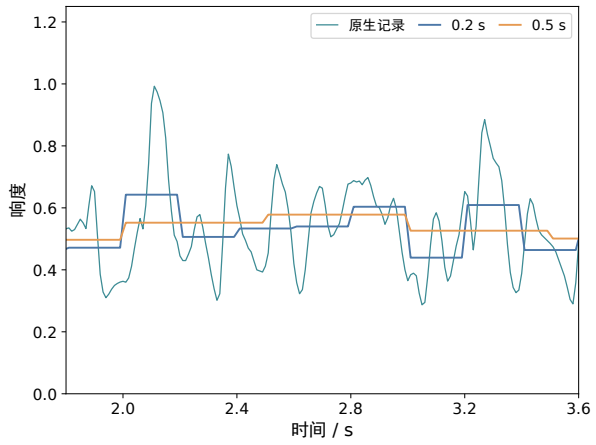


图 3.19　响度的固定窗口聚合与重建

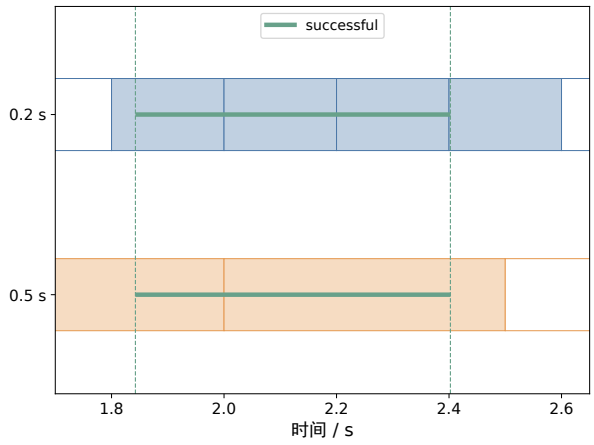


图 3.20　候选词区间与固定窗口交叠

为判断上述现象是否仅出现在个别片段，本文对全量样本分别计算标准化重建均方误差与词跨界比例。重建误差将重建特征与原生特征之差按各维原生标准差归一化，再对有效记录和维度的平方误差取平均，数值越低表示越接近原生特征。仅纳入标准差大于 10^{-6} 的维度，有记录但全部维度恒定时记 0，无有效记录时不计入模态均值。词跨界比例则在每条样本通过对齐筛选的词中，统计与至少两个窗口交叠的词所占比例，数值越高表示被切分的词越多。两类指标均先在样本内计算，再对相应有效样本等权平均，以区分特征变化的保留程度和词区间的完整性。

图 3.21至图 3.23汇总全量对照。声学与视觉重建误差图中的短窗箱体整体低于长窗箱体，声学平均重建误差由 0.7467 降至 0.5449，视觉由 0.4373 降至 0.2357，相对降幅分别

为 27.02% 和 46.10%。图 3.23则呈相反方向，平均词跨界比例由 39.50% 升至 71.33%，增加 31.83 个百分点。三幅图分别基于 100 条声学样本、87 条具有有效面部记录的样本和 79 条未触发整段复核的样本。图中菱形标出均值，箱内横线标出中位数，箱体覆盖第 25 至第 75 百分位数，须线延伸至 1.5 倍四分位距内的最远观测，箱外圆点仍参与统计。

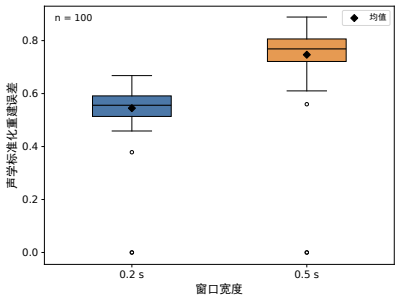


图 3.21　声学重建误差对照

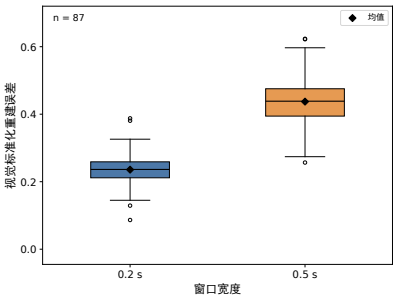


图 3.22　视觉重建误差对照

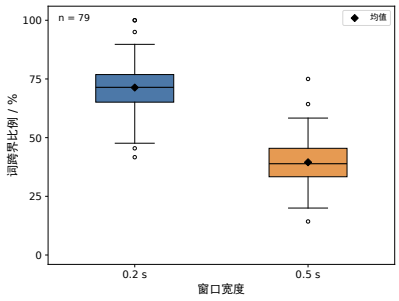


图 3.23　词跨界比例对照

逐样本比较进一步表明，98 条样本的短窗声学误差更低，另 2 条相同；87 条样本的短窗视觉误差均更低；77 条样本的短窗词跨界比例更高，另 2 条相同。两条声学误差相同的样本即前述全零音频样本，其特征不随时间变化，两种窗口的误差均按规则记 0。将这两条样本单独列出后，其余 98 条样本的短窗、长窗平均声学误差分别为 0.5560 和 0.7619，差异方向保持一致。

上述对照表明，在本次数据与窗口设置下，缩短窗口有利于保留原生特征的局部变化，却同时增加了词区间被固定边界切分的比例。因此，仅通过调整统一窗口宽度，仍需在这两个目标之间进行权衡。这一现象说明，以原文词为组织单位、再根据候选词区间聚合视听记录具有明确的任务动机：它使词级表示直接对应一个文本单元，并保留参与聚合的原生记录供回溯使用。不过，本实验未直接比较词级表示的重建误差，也未引入人工词界或情感预测任务，故不能据此断言词级表示在上述指标上优于固定窗口，其时间对应质量仍取决于候选词界及观测状态。

时间划分对照解释了聚合粒度的影响，而 21 条整段受限样本还涉及更基本的前提：给定英文转写是否具有相应的语音依据。若输入内容不对应，即使强制对齐能够生成完整路径，其候选词界也缺少真实发音支撑。为区分输入异常与一般的词界定位偏差，本文进一步对照实际音频和给定转写进行人工审核，按主要问题划分为表 3.5所列五类。各类互不重叠，共涉及 317 个原文词。

表 3.5　21 条复核样本的人工审核结果

审核发现	样本数	原文词数	主要表现
音轨与文本不对应	11	120	实际语音内容与给定转写不对应
无对应朗读	5	64	未听到对应朗读，其中 1 条为音乐
非英语语音	3	93	实际语音并非英语
分段内容不对应	1	18	前半段无朗读，后半段语音与转写不对应
音频卡顿、局部对应	1	22	音频存在卡顿，部分词语与文本一致，但未形成完整对应
合计	21	317	

审核发现，音轨与文本不对应、缺少对应朗读等情况使给定转写缺少相应的语音依据；非英语语音则与所用英语声学模型及英文对齐目标不匹配。其中，3 条非英语样本均来自

视频-yRb-Jum7EQ，两条全零音频样本归入“无对应朗读”。这些异常具有不同来源，不能统一解释为词界定位偏差。

样本-HwX2H8Z4hY$_$9 还说明了片段级检查的必要性。其平均词置信度为 0.7238，仅 9.09% 的词低于 0.1，但诊断 WER 达到 0.8636。人工审核发现音频存在卡顿，部分词语与转写一致，却没有形成完整逐词对应，说明局部得分较高不足以确认整段对应关系。

依据审核结果，本文维持这 21 条样本整体词级对应受限的标记，同时保留其原文、标签、原生特征与候选时间记录。该处理遵循题目关于保留原始样本并说明异常处理规则的要求，使内容对应异常能够被追溯，而不会通过修改转写或删除样本被隐去。由于本次审核未重建人工词界，不恢复局部词的对齐标记，前述筛选数量保持不变。审核范围仅为自动筛出的 21 条样本，不能据此认定其余 79 条均无异常，也不能计算全量词界准确率。

3.5.3 典型样本的跨模态时序对齐验证

全量统计明确了输出的使用范围，典型样本则进一步检验具体记录能否回溯到原始素材。本文继续采用样本-egA8-b7-3M$_$1，展示文本片段、语音时段、视频帧及三类特征之间的对应。该样本给定转写包含“I started a successful Legal Nurse Consulting Business in 1989.”，图 3.24选取其中 1.80–3.60 s 的局部时段，自上而下排列实际画面、候选词区间、响度及面部系数。通过共同时间轴，可以从一个原文词定位其对应的声学记录与视频帧。其中浅绿底突出 successful 的候选区间，其内约 2.11 s 处出现响度峰值。图片按标注时刻定位，图片宽度不代表持续时间，面部曲线连线仅辅助观察。

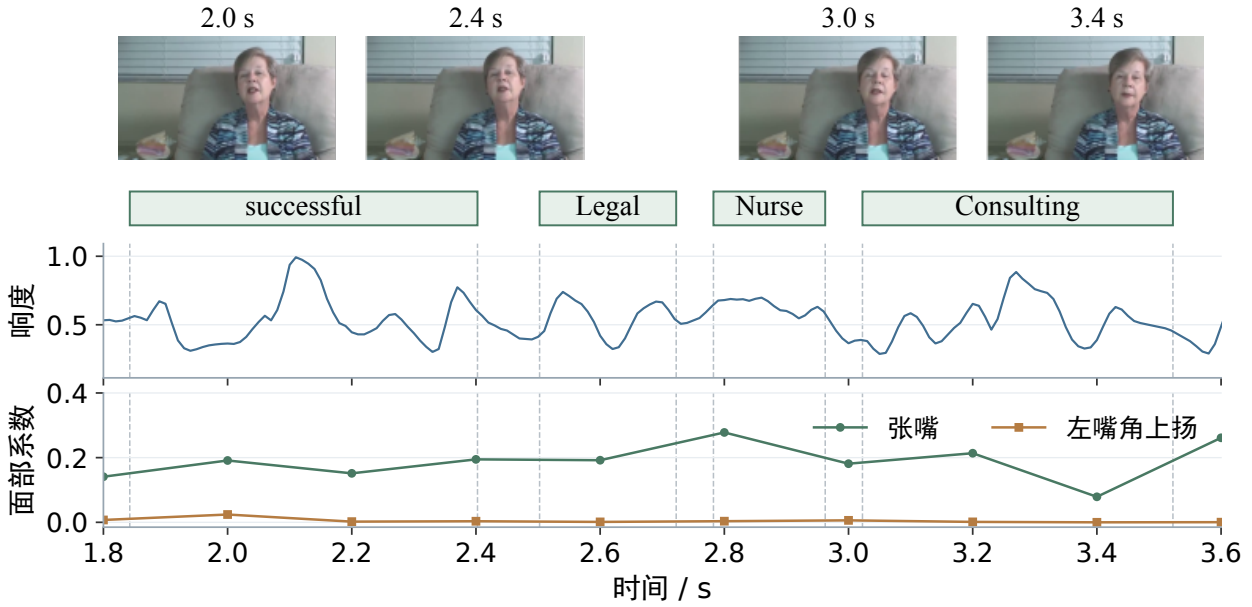


图 3.24　词级映射的回溯示例：从候选词区间定位同一时段的声音与画面

表 3.6列出部分映射记录。词 *successful* 的候选区间为 $[1.8425, 2.4025]$ s，文本表示由子词索引 3 对应的隐藏向量获得，声学表示由 183–240 号共 58 条原生记录聚合，视觉表示由 1.8、2.0、2.2、2.4 s 四帧聚合。由此，该词的 768 维文本、25 维声学与 52 维视觉向量均可回溯到各自来源。索引从 0 开始。声学索引指特征记录而非波形采样点，视觉帧依据时间支持区间参与聚合，因此帧中心可以位于词区间之外，边界帧的权重由实际交叠时长决定。

表 3.6　典型样本的部分词级映射记录

原文词	子词索引	候选区间/s	声学记录索引	视觉帧时刻/s
started	1	$[1.2825, 1.6425]$	127–164	1.2, 1.4, 1.6
successful	3	$[1.8425, 2.4025]$	183–240	1.8, 2.0, 2.2, 2.4
Consulting	6	$[3.0225, 3.5225]$	301–352	3.0, 3.2, 3.4, 3.6

典型样本图与映射表共同展示了从原文词到模型子词、声学记录和视频帧的可追溯链条，使前文的聚合规则能够在具体输出上核验。进一步对全部 100 条样本独立复算交叠权重、视听聚合值和 CTC 置信度，重新计算诊断 WER，并解码音视频核对时间记录与低能量标记，结果均在既定数值容差内与保存记录一致。这一检查验证了实现与既定计算规则的一致性，真实词界精度仍需人工时间标注评价。典型样本中的 in 和 1989 也继续保留置信度不足的标记，说明实例展示与质量筛选采用相同标准，没有因为选作典型样本而放宽使用条件。

3.5.4 三模态特征文件说明与 100 条样本结果汇总

以上统计与典型样本展示说明了输出的覆盖范围、质量状态和回溯方式。为进一步满足题目对自生成特征文件规范及全部 100 条样本结果汇总的要求，本文采用“统一模态规格＋逐样本明细”的组织方式：表 3.7列出每条样本共有的模态类型、特征维数、矩阵形状与对齐粒度，表 3.8列出全部样本的编号、原始媒体时长及有效位置统计。两表结合，可确定任一样本三种模态的输出规格及使用范围，具体高维数值由相应样本目录中的特征文件提供。

表 3.7　三种模态的词级特征规格

模态	特征维数	样本矩阵形状	对齐粒度
文本	768	$L \times 768$	原文词
声学	25	$L \times 25$	原文词
视觉（面部）	52	$L \times 52$	原文词

在时序组织上，每条样本按实际原文词数 L 保存变长序列，不进行统一长度填充或截断。L 表示保留的词位置总数，模态观测有效位置数与通过对齐筛选的位置数另由掩码统计，这些位置不必连续，因此不能仅保存一个长度数值而省略逐位置标记。视觉无效位置的零向量用于在原词位置上占位，含义不同于在序列末尾追加的长度填充。

全量表中，“原文词数”对应三个矩阵的行数，“视觉可观测词数”统计能聚合有效面部记录的位置，“通过对齐筛选词数”依据前述两层筛选条件，最后一列为通过筛选且三种模态均可观测的词数。由于文本与声学在全部词位置均有可计算记录，最后一列等于对齐筛选与视觉可观测两个条件的交集。片段时长与音频时长均按前文的实际解码口径记录，用于定位原始媒体的时间范围，不将其解释为有效发声或面部可观测的累计时长。

例如，样本-s9qJ7ATP7w$_$7 共有 28 个词，其中 14 个视觉可观测，24 个通过对齐筛选，同时满足两项条件的有 12 个。交集数量不能取前两项数量的较小值代替。

按上述口径，32 条样本的全部词通过筛选且三种模态均可观测，46 条样本仅部分词满足两项条件，1 条样本的全部词通过对齐筛选但视觉模态不可观测，另 21 条样本经人工审核后整体词级对应仍受限。全量表按这四类依次排列，已审核的 21 条样本统一归入最后一类，各组互不重叠。

表 3.8　附件 1 全部样本的特征输出与有效位置统计

样本编号	片段时长/s	音频时长/s	原文词数	视觉可观测词数	通过对齐筛选词数	其中三种模态都可观测词数
1. 全部词通过筛选且三种模态都可观测（32 条）						
-3g5yACwYnA$_$3	14.389	14.328	29	29	29	29
-3nNcZdcdvU$_$5	7.868	7.789	18	18	18	18
-6rXp3zJ3kc$_$8	12.805	12.738	34	34	34	34
-I_e4mIh0yE$_$1	7.622	7.444	18	18	18	18
-I_e4mIh0yE$_$3	9.163	8.994	22	22	22	22
-MeTTeMJBNc$_$0	9.333	9.218	21	21	21	21
-MeTTeMJBNc$_$13	5.430	5.255	14	14	14	14
-RfYyzHpjk4$_$11	5.239	5.075	17	17	17	17
-RfYyzHpjk4$_$8	4.589	4.532	17	17	17	17
-UUCSKoHeMA$_$0	7.867	7.732	18	18	18	18
-UacrmKiTn4$_$10	7.362	7.242	18	18	18	18
-UacrmKiTn4$_$4	4.741	4.682	14	14	14	14
-aNfi7CP8vM$_$7	8.695	8.538	18	18	18	18
-aqamKhZ1Ec$_$0	11.000	10.890	14	14	14	14
-dxfTGcXJoc$_$1	16.161	16.018	37	37	37	37
-egA8-b7-3M$_$16	5.538	5.483	11	11	11	11
-egA8-b7-3M$_$17	7.271	7.095	16	16	16	16
-egA8-b7-3M$_$18	8.386	8.266	22	22	22	22
-egA8-b7-3M$_$20	6.645	6.474	20	20	20	20
-egA8-b7-3M$_$26	6.031	5.921	15	15	15	15
-egA8-b7-3M$_$6	6.265	6.183	12	12	12	12
-egA8-b7-3M$_$9	5.090	4.936	10	10	10	10
-mqbVkbCndg$_$0	6.500	6.386	14	14	14	14
-s9qJ7ATP7w$_$6	2.475	2.315	5	5	5	5
-s9qJ7ATP7w$_$8	3.295	3.184	12	12	12	12
-t217m2on-s$_$7	17.183	17.026	45	45	45	45
-tPCytz4rww$_$10	4.789	4.679	12	12	12	12
-tPCytz4rww$_$11	5.467	5.379	17	17	17	17
-tPCytz4rww$_$18	6.645	6.569	16	16	16	16
-uywlfIYOS8$_$4	6.045	5.881	18	18	18	18
-wny0OAz3g8$_$0	3.333	3.274	9	9	9	9
-wny0OAz3g8$_$2	6.687	6.523	23	23	23	23
2. 部分词通过筛选且三种模态都可观测（46 条）						
-3g5yACwYnA$_$13	5.514	5.399	15	15	14	14
-3g5yACwYnA$_$2	9.394	9.231	14	14	13	13
-3g5yACwYnA$_$9	8.817	8.696	23	23	21	21
-571d8cVauQ$_$0	5.167	4.992	12	12	10	10
-571d8cVauQ$_$5	15.273	15.115	43	43	42	42
-9y-fZ3swSY$_$0	6.900	6.757	22	22	19	19
-9y-fZ3swSY$_$4	2.821	2.665	9	9	6	6

续下页

表 3.8　特征输出与有效位置统计（续）

样本编号	片段时长/s	音频时长/s	原文词数	视觉可观测词数	通过对齐筛选词数	其中三种模态都可观测词数
-9y-fZ3swSY$_$8	4.989	4.917	12	3	11	2
-AUZQgSxyPQ$_$2	22.511	22.405	41	41	39	39
-HeZS2-Prhc$_$2	8.262	8.151	16	16	15	15
-HwX2H8Z4hY$_$2	3.982	3.916	7	1	4	1
-HwX2H8Z4hY$_$5	5.653	5.544	9	2	8	2
-HwX2H8Z4hY$_$6	3.358	3.256	7	5	6	5
-MeTTeMJBNc$_$7	10.517	10.411	31	31	29	29
-RfYyzHpjk4$_$2	5.516	5.392	25	24	21	21
-THoVjtIkeU$_$12	14.896	14.806	39	39	38	38
-THoVjtIkeU$_$2	4.292	4.231	10	10	9	9
-THoVjtIkeU$_$6	8.097	7.983	30	30	27	27
-UuX1xuaiiE$_$0	3.700	3.576	9	6	8	5
-UuX1xuaiiE$_$1	10.350	10.268	27	1	27	1
-UuX1xuaiiE$_$3	4.130	4.038	9	9	8	8
-UuX1xuaiiE$_$6	8.114	7.944	22	22	20	20
-a55Q6RWvTA$_$3	22.154	22.083	65	60	63	58
-dxfTGcXJoc$_$0	20.533	20.410	40	33	39	32
-dxfTGcXJoc$_$2	16.698	16.633	34	34	33	33
-dxfTGcXJoc$_$6	12.735	12.628	28	28	27	27
-egA8-b7-3M$_$1	10.266	10.156	20	20	18	18
-egA8-b7-3M$_$13	4.184	4.024	11	11	10	10
-lzEya4AM_4$_$5	7.675	7.570	19	19	18	18
-lzEya4AM_4$_$6	14.792	14.740	43	43	42	42
-qDkUB0GgYY$_$6	4.678	4.615	16	16	12	12
-s9qJ7ATP7w$_$0	6.867	6.711	24	24	23	23
-s9qJ7ATP7w$_$1	4.792	4.644	11	11	10	10
-s9qJ7ATP7w$_$4	4.427	4.247	9	6	8	5
-s9qJ7ATP7w$_$5	8.561	8.398	19	19	18	18
-s9qJ7ATP7w$_$7	6.966	6.839	28	14	24	12
-t217m2on-s$_$2	5.686	5.630	12	12	11	11
-tANM6ETl_M$_$3	6.758	6.604	22	22	21	21
-tPCytz4rww$_$12	11.864	11.736	26	26	24	24
-tPCytz4rww$_$16	7.206	7.139	16	16	14	14
-vxjVxOeScU$_$4	9.127	9.037	21	21	18	18
-wMB_hJL-3o$_$7	6.044	5.976	22	22	21	21
-wny0OAz3g8$_$3	6.146	6.100	20	1	20	1
-wny0OAz3g8$_$5	6.912	6.741	20	1	20	1
-wny0OAz3g8$_$7	8.068	7.910	29	6	29	6
-wny0OAz3g8$_$9	6.213	6.043	20	20	19	19
3. 全部词通过对齐筛选，但视觉模态不可观测（1 条）						
-wny0OAz3g8$_$1	6.844	6.777	22	0	22	0

续下页

表 3.8　特征输出与有效位置统计（续）

样本编号	片段时长/s	音频时长/s	原文词数	视觉可观测词数	通过对齐筛选词数	其中三种模态都可观测词数
4. 整段对齐受限（已完成人工审核）（21 条）						
-HwX2H8Z4hY$_$9	7.734	7.636	22	0	0	0
-NFrJFQijFE$_$1	5.746	5.659	16	0	0	0
-NFrJFQijFE$_$2	6.856	6.698	18	0	0	0
-hnBHBN8p5A$_$6	6.401	6.333	13	0	0	0
-hnBHBN8p5A$_$7	7.372	7.309	13	0	0	0
-iRBcNs9oI8$_$3	5.621	5.538	8	0	0	0
-iRBcNs9oI8$_$6	2.903	2.820	5	0	0	0
-iRBcNs9oI8$_$7	4.104	4.006	9	0	0	0
-iRBcNs9oI8$_$8	8.093	8.026	21	0	0	0
-iRBcNs9oI8$_$9	3.416	3.374	5	0	0	0
-mJ2ud6oKI8$_$1	6.103	6.054	13	0	0	0
-mJ2ud6oKI8$_$2	5.731	5.702	11	0	0	0
-mJ2ud6oKI8$_$6	2.257	2.228	5	5	0	0
-mJ2ud6oKI8$_$8	4.192	4.171	11	11	0	0
-mJ2ud6oKI8$_$9	7.033	6.909	22	22	0	0
-ri04Z7vwnc$_$0	2.807	2.763	8	0	0	0
-ri04Z7vwnc$_$2	6.027	5.913	16	8	0	0
-ri04Z7vwnc$_$5	3.545	3.440	8	8	0	0
-yRb-Jum7EQ$_$1	29.288	29.110	49	48	0	0
-yRb-Jum7EQ$_$5	13.169	13.045	25	25	0	0
-yRb-Jum7EQ$_$6	11.243	11.243	19	19	0	0

为使全量汇总能够落实到具体文件，本文按样本编号建立目录，采用 npz 格式文件保存数值数组，采用 JSON 保存原文、标签、特征定义和处理信息，并以 CSV 分别汇总样本、模态及词级记录。各文件内容见表 3.9。这种组织方式将高维特征与其解释信息共同保存，使查询某条样本时能够同时取得特征值、原始来源和质量状态，而不是仅得到脱离时间记录的向量。

表 3.9　特征结果文件及其内容

文件	内容
features.npz	词级三模态矩阵、候选词区间、观测标记，以及原生视听特征和聚合权重。
metadata.json	原文、标签、词与子词位置、各维特征名称及处理参数。
quality_masks.npz、quality.json	对齐质量筛选结果、结合观测状态的有效位置标记及自动筛选原因。
windows_0.2s.npz、windows_0.5s.npz	固定窗口边界、视听特征及文本聚合权重。
人工审核 _21 条样本.csv	21 条样本的人工审核状态、问题分类与原始说明。
三份 CSV 汇总表	sample_summary.csv、modality_summary.csv 和word_alignment.csv 分别对应 100 条样本、300 条样本–模态记录及 1932 个词的明细。

读取时，先通过样本编号定位目录，从features.npz 载入text、audio 和vision 数组，相同行均对应同一原文词。再读取word_bounds 中的候选起止时间，并结合metadata.json 中的原文、词与子词记录解释该位置。用于词级视听分析时，还需读取quality_masks.npz 中的模态有效位置标记，例如vision_aligned_usable 取 1 表示该词通过对齐筛选且视觉可观测。保存的原生记录索引和聚合权重可用于复算词级向量，固定窗口的文本表示则由词权重与词级文本矩阵相乘获得。由此，样本编号、特征行、候选时间和原始素材之间形成可逐级核验的对应关系。

3.5.5 方案可复现性说明

为使前述处理结果能够复现，本文同时记录工具与模型版本、关键参数、配置文件、模型文件哈希及处理日志，实验环境和主要参数见表 3.10。词级与片段级质量筛选条件已在时序对齐评估中明确列出。预训练模型用于冻结特征提取及声学对齐，不使用本问情感标签训练或微调，从而使本问的复现对象集中于输入处理、特征生成、时间映射与质量标记。

表 3.10　实验环境与主要参数

项目	版本或参数
运行环境	Python 3.10.13；PyTorch 2.5.1；CUDA 12.1
音视频读取	PyAV 17.0.1；音频 16 kHz、单声道；视频目标抽样频率 5 Hz
文本编码	Transformers 4.48.3；distilbert/distilbert-base-uncased；每块最多 510 个子词，另加首尾标记
声学对齐	facebook/wav2vec2-base-960h；CTC 最大概率路径
声学特征	openSMILE 2.6.0；eGeMAPSv02 的 25 维低层描述量
面部特征	MediaPipe 0.10.21；Face Landmarker float16 版本 1；52 维表情系数；检测与存在阈值均为 0.5，最多两张脸，选择面积最大者
数值计算	NumPy 1.26.4；SciPy 1.15.3；特征采用 32 位浮点数；num2words 0.5.14；随机种子 20260923

完整运行流程如下：首先依据环境清单和模型哈希准备相同的工具与权重，核对视频、转写和标签的样本标识，并进行媒体解码检查；随后完成文本规范化、音频重采样和带实际时间戳的视频抽样，分别提取三模态特征，估计 CTC 候选词区间，并按时间交叠聚合视听记录；最后生成质量标记、固定窗口对照和全量汇总，再独立复算时间映射与聚合结果。实际执行顺序、命令及异常记录随代码说明和日志保存，21 条样本的人工审核说明单独保留，以区分程序计算结果与人工内容核查。

复现检查分别覆盖输入与实现的一致性、计算结果的一致性和重复提取的一致性。已有全量核验确认 100 条样本的源视频、处理代码、配置及模型文件哈希一致，候选路径与聚合结果符合既定规则。此外，将两条独立试跑样本与正式提取结果逐字段比较，特征的最大绝对差为 0。前者覆盖全部样本的结构和计算核验，后者验证两条样本在相同条件下的重复提取结果，不将其扩大解释为全量重复运行或跨环境完全一致。上述记录与特征文件共同构成可复核、可复现的交付材料。

3.6 本问小结

本问完成了附件 1 全部 100 条样本的文本、声学与视觉特征提取，以词为共同组织单位，分别构建 768 维、25 维和 52 维的变长词级表示。通过 CTC 强制对齐估计候选词区间，结合实际时间戳与时间交叠权重聚合有效视听观测，建立词级特征与原文、音频记录及视频帧之间的可追溯映射。全部 1932 个原文词均予以保留，其中 1545 个通过对齐质量筛选，占 79.97%，1387 个同时通过筛选且三种模态均可观测，占全部词的 71.79%。对 21 条整段

复核样本的人工审核进一步识别了内容对应异常，并据此维持其词级对应的使用限制。固定窗口对照显示，相较于 0.5 s 窗口，0.2 s 窗口的重建误差更低，但词区间被切分的比例更高，体现了局部特征变化保留与词区间完整性之间的权衡。

该方案在保留全部样本及原始词位置的同时，分别记录观测有效性与对齐质量，使模态缺失和时间对应异常能够被独立识别。当前尚缺少人工词界标注，筛选通过比例不能解释为对齐准确率，约 5 Hz 的视频抽样对快速面部变化的表征有限，所选人脸未验证为说话者，视觉特征也未覆盖场景与肢体信息。因此，使用输出时应结合质量标记，并限定对特征含义与时间对应的解释范围。此外，本问提取的特征与附件 2 提供的 768、74 和 35 维特征在定义及维度配置上不同，后续各问仍应采用题目规定的特征输入，不能与本文特征混用或替换。

4 问题二　局部模态缺失下的鲁棒性情感预测

4.1 问题分析与总体思路

问题二要求在文本、语音和视觉的局部连续片段缺失时，利用剩余观测同时预测情感极性与情感强度，并分析缺失模态、位置及长度对预测性能的影响。与整模态缺失相比，局部缺失通常仍保留部分有效信息，但会破坏时序上下文，使各模态所能提供的信息随样本及缺失方式而变化。已有研究指出，数据缺失与噪声会造成模态信息不均衡，直接采用常规多模态融合方法可能导致预测性能退化 [10]。因此，建模的关键在于准确区分有效观测与不可用位置，在提取剩余时序信息的基础上调整模态融合权重，并兼顾完整输入性能与缺失条件下的预测稳定性。

针对上述特点，本文构建缺失感知门控融合模型（下文简称主模型），按照“数据分析与预处理、主模型设计与模块消融、三类框架对比与模型选择、鲁棒性与缺失影响分析、附件 3 专项预测”的顺序展开。图4.1概括数据处理、主模型和三类对比框架之间的关系，其中消融实验检验主模型内部设计的作用，框架对比则检验采用该模型的合理性。

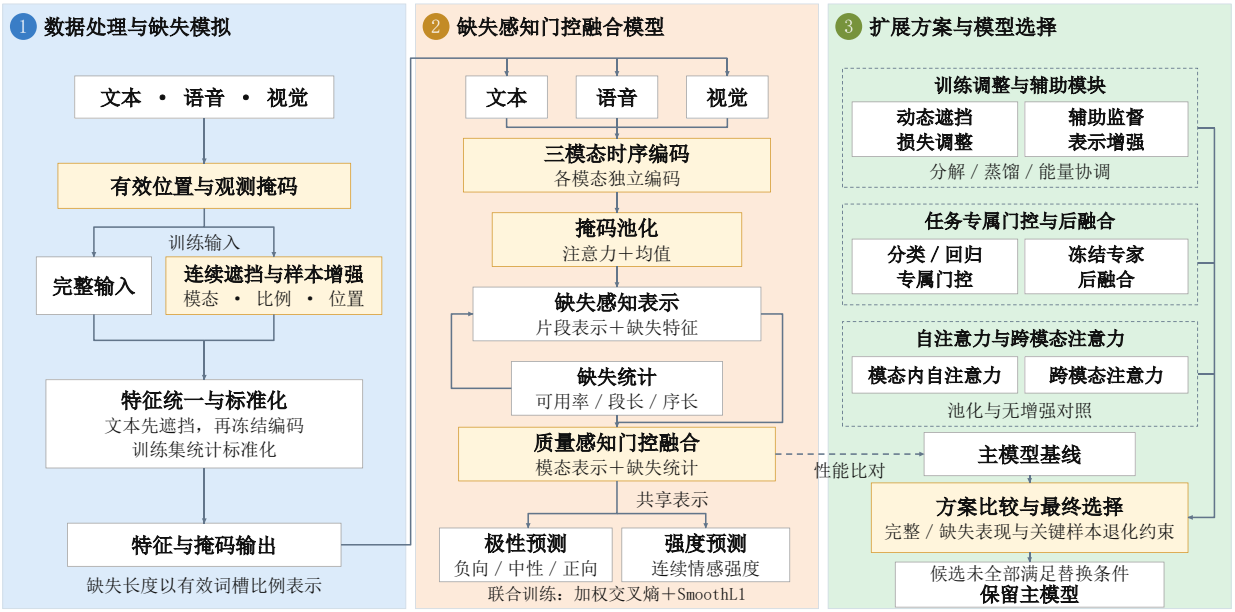


图 4.1　局部缺失预测的数据处理、主模型与对比框架

首先，分析附件 2 的数据划分、类别分布与模态观测情况，统一附件 2 与附件 3 的对齐输入接口，并分别构造有效位置掩码和模态观测掩码。标准化统计量仅由训练集估计，连续区间遮挡在有效范围内实施，文本先遮挡再编码，以避免填充位置混入缺失统计或被删除词元的信息通过上下文泄露。考虑到附件 2 的对齐特征未提供逐词时间戳，本文以连续遮挡的槽位数占有效序列长度的比例度量相对缺失长度。

其次，利用模态内时序编码、掩码池化和缺失状态表征构建主模型，通过质量感知门控融合剩余观测，由分类与回归双头同时输出情感极性与强度。在明确训练设置和评价准则后，依次比较固定融合、加入连续遮挡增强、加入缺失感知处理和加入门控的配置，检验各项设计在当前实验条件下的作用及性能取舍。

随后，从监督与表示学习、任务融合方式、时序与跨模态交互三个角度出发，构建训练调整与辅助学习、任务专属门控与后融合、自注意力与跨模态注意力三类对比框架。在统一验证口径下比较完整输入与连续缺失表现，结合既定替换条件和分组误差说明最终选型依据，不预设更复杂的框架必然优于主模型。

模型确定后，固定其结构与参数，依次考察缺失模态和比例、片段位置和形状、跨模态起点关系的影响，并通过类别混淆与强度误差说明其适用范围和主要局限。最后，沿用锁定模型及统一推理接口，对附件 3 全部 30 条样本输出情感极性与连续强度，汇总预测分布并分析输出分歧。

4.2 多模态数据分析与预处理

为使模型能够利用局部缺失后的剩余信息，需要先明确各样本包含哪些有效序列位置，以及这些位置上的文本、声学和视觉信息是否可用。本节先分析附件 2 的样本与类别分布，统一训练数据和附件 3 预测数据的输入格式，并完成特征标准化；随后分别标记有效序列位置与各模态的可用观测，在有效范围内设置连续遮挡，模拟不同模态、位置和长度的局部缺失。

4.2.1 数据分布与特征标准化

本文采用附件 2 提供的对齐特征文件 aligned_50.pkl 开展建模，并沿用其训练、验证与测试划分。数据共包含 4850 个视频片段，各划分的类别分布如表4.1所示。模型参数与标准化统计量仅由训练集估计，验证集用于模型选择，测试集用于选型后的性能评价。附件 3 的 30 个无标签样本仅用于最终专项推理。

表 4.1　附件 2 的数据划分与情感类别分布

数据划分	负向	中性	正向	合计
训练集	967	758	1670	3395
验证集	206	184	338	728
测试集	207	158	362	727
合计	1380	1100	2370	4850

情感强度记为 $y_i \in [-3, 3]$，负向、中性与正向分别对应 $y_i < 0$、$y_i = 0$ 与 $y_i > 0$，类别编码依次为 0、1、2。训练集正向样本占比为 49.19%，而中性样本相对较少，表明类别分布存在不均衡。因此，后续分类训练采用由训练集类别频数确定的加权损失，并在总体准确率之外报告 Macro-F1 及中性类别表现，以避免多数类表现掩盖其余类别的识别不足。

为保证训练与专项推理的输入一致，本文统一使用 `text_bert`、`audio` 与 `vision` 三个字段。附件 2 虽然提供预计算的文本特征 `text`，但附件 3 未提供该字段，故本文不直接使用该预计算特征，而是采用同一个冻结的 DistilBERT 编码器，为训练集、验证集、测试集及附件 3 样本生成文本表示。编码器始终保持评估状态，训练过程中不更新其参数。具体模型为 distilbert/distilbert-base-uncased。

其中，`text_bert` 中的三路数据依次为词元编号、注意力掩码与分段编号。本数据的分段编号均为 0，编码器实际使用前两路输入。经核查，全部 4850 条样本的已有词元编号均与该编码器分词器的输出一致。存在文本遮挡时，先处理词元及其注意力掩码，再重新生成上下文表示，具体规则见第4.2.3节。

原始字段与编码后进入标准化环节的特征形状如表4.2所示。记模态集合为 $\mathcal{M} = \{T, A, V\}$，第 i 个样本的模态特征为 $X_i^{(m)} \in \mathbb{R}^{50 \times d_m}$，其中 $d_T = 768$、$d_A = 74$、$d_V = 35$。本文将对齐序列中的一个存储位置称为词元槽位，其不必与一个完整的自然语言单词一一对应。50 表示统一的存储槽位数，不代表所有样本均有 50 个有效词元槽位，也不对应固定的视频时长。语音和视觉沿用附件给定的特征，不额外假定各维度具有未公开的物理含义。

数据核查还表明，在训练集有效词元槽位内，语音与视觉的可用观测比例分别约为 99.92% 和 94.47%。这说明未经人工遮挡的数据也可能包含不可用观测，不能将全部零行

表 4.2　统一输入接口与标准化前的单样本特征形状

模态	输入字段	原始字段形状	标准化前特征形状
文本 T	text_bert	3×50	50×768
语音 A	audio	50×74	50×74
视觉 V	vision	50×35	50×35

直接计为人工缺失，更不能将尾部填充纳入缺失比例的分母。为避免这些位置影响统计量估计，标准化仅使用训练集中有效且原始可观测的位置，位置判定与掩码构造在下一小节定义。

不同模态及不同特征维度的数值尺度可能不同，本文采用逐维标准化减小尺度差异。记 $\mathcal{I}_m$ 为模态 m 在未经人工遮挡的训练集中所有有效且可观测的样本–位置对集合，$n_m = |\mathcal{I}_m|$，$x_{itd}^{(m)}$ 表示第 i 个样本、第 t 个位置、第 d 维特征，则训练均值与标准差为

$$\begin{aligned} \mu_{md} &= \frac{1}{n_m} \sum_{(i,t)\in\mathcal{I}_m} x_{itd}^{(m)}, \\ \sigma_{md} &= \left[\frac{1}{n_m} \sum_{(i,t)\in\mathcal{I}_m} \left(x_{itd}^{(m)} - \mu_{md} \right)^2 \right]^{1/2}. \end{aligned} \tag{4.1}$$

这里按可观测位置汇总统计量，而非先计算每个样本的均值再等权平均。为避免低方差维度引起数值放大，设置标准差下限 $\varepsilon = 10^{-4}$，并将标准化数值截断至 $[-8, 8]$。对当前输入，采用

$$\widetilde{x}_{itd}^{(m)} = \begin{cases} \mathrm{clip}\left(\dfrac{x_{itd}^{(m)} - \mu_{md}}{\max(\sigma_{md}, \varepsilon)}, -8, 8 \right), & \text{该位置有效且可观测,} \\ 0, & \text{其他情况,} \end{cases} \tag{4.2}$$

其中 $\mathrm{clip}(u, -8, 8) = \min\{8, \max\{-8, u\}\}$。不可用位置在标准化后重新置零，并保留独立的观测掩码，以区分真实观测的零值与缺失占位值。

上述均值与标准差一经训练集估计即固定，训练增强视图、验证集、测试集及附件 3 均复用同一组参数，不针对各划分或缺失场景重新拟合。该处理保持特征维度与槽位置不变，三模态向公共隐空间的维度投影由后续时序编码网络完成。

4.2.2 有效观测识别与掩码构建

附件采用统一的 50 槽存储格式，但不同样本的实际有效长度存在差异，较短序列的末尾包含填充位置。此外，有效范围内也可能存在局部模态信息不可用的情况。填充与局部缺失均可能表现为零值，但二者具有不同含义：前者位于样本的有效范围之外，后者则对应有效范围内的观测缺失。为避免混淆，本文分别构造有效位置掩码与观测掩码，有效位置掩码区分真实序列与边界、填充位置，观测掩码进一步判断真实序列中哪些模态信息仍然可用。

有效位置掩码 P_{it} 用于判断第 i 个样本的第 t 个位置是否属于有效词元槽位，定义为

$$P_{it} = \begin{cases} 1, & \text{该位置属于有效词元槽位,} \\ 0, & \text{该位置为特殊边界标记或尾部填充.} \end{cases} \tag{4.3}$$

依据文本序列的起始标记与有效终止标记确定边界，将二者之间的位置纳入有效范围，边界标记本身不计入。由此，样本的有效长度为 $L_i = \sum_{t=1}^{50} P_{it}$。局部观测缺失不改变 P_{it}，相

应位置仍保留在原序列中，以维持三模态既有的对齐关系，并为缺失比例的计算提供统一基准。

在有效范围内，进一步定义模态观测掩码 $O_{it}^{(m)}$，其中 $m \in \{T, A, V\}$ 分别表示文本、语音和视觉：

$$O_{it}^{(m)} = \begin{cases} 1, & \text{该位置有效且模态 } m \text{ 的观测可用,} \\ 0, & \text{其他情况.} \end{cases} \tag{4.4}$$

对于文本，要求对应的注意力标记有效，且词元不属于填充、未知或其他特殊标记。对于语音和视觉，则依据标准化前的原始特征进行判定：整行特征均为零时，将该位置视为不可观测；部分维度取零不影响整行的可用性。以某一有效词元槽位为例，若其语音特征全为零，而文本与视觉观测均可用，则 $P_{it} = 1$，且 $O_{it}^{(T)} = 1$、$O_{it}^{(A)} = 0$、$O_{it}^{(V)} = 1$。该位置仍参与序列组织，但其语音特征不纳入有效观测。

为区分输入已有的不可用观测与实验施加的遮挡，另定义人工删除掩码 $D_{it}^{(m)}$，取 1 表示删除对应位置的模态观测，取 0 表示不施加删除。遮挡后的观测状态为

$$\widetilde{O}_{it}^{(m)} = O_{it}^{(m)}\big(1 - D_{it}^{(m)}\big). \tag{4.5}$$

该式表明，遮挡后的可用观测由初始观测状态与人工删除操作共同确定，而有效位置掩码 P 保持不变。对于附件 3，仅依据给定输入构造观测掩码，不由零值或未知词元推断其缺失成因。

特征与掩码分别存储，并采用一致的处理规则：标准化统计量仅由训练集中 $O_{it}^{(m)} = 1$ 的位置估计；模型输入中的不可用特征置零，同时保留相应掩码。由于标准化后的正常特征也可能取零值，后续运算以掩码作为观测可用性的判定依据，不再根据特征数值重新判定。上述处理为掩码池化及缺失程度统计提供了统一的位置与观测依据。

4.2.3 连续遮挡与样本增强

为使模型在局部信息缺失时仍能利用剩余观测进行预测，本文通过连续区间遮挡构造训练样本。与随机删除零散位置相比，连续遮挡更符合本题中某一模态在局部片段内持续不可用的情形。遮挡仅改变输入信息，情感极性与强度标签保持不变，使模型减少对局部完整信息的依赖，并学习利用其他位置和其他模态中的信息。

每次遮挡由模态组合、遮挡比例和区间位置共同确定。模态组合从 T、A、V、TA、TV、AV 和 TAV 中等概率抽取，其中 TA 表示同时遮挡文本与语音，其余组合定义类似。名义遮挡比例 r 从 $\{0.1, 0.3, 0.5, 0.7\}$ 中等概率抽取，以覆盖不同程度的局部缺失。

设样本 i 按词元对齐后的有效序列长度为 L_i。当 $L_i > 0$ 且 $r > 0$ 时，遮挡长度为

$$k_i = \min\left\{L_i, \max\left(1, \left\lfloor rL_i + \frac{1}{2} \right\rfloor\right)\right\}. \tag{4.6}$$

即四舍五入 rL_i，并将遮挡长度限制在 1 至 L_i 之间。当 $r = 0$ 或 $L_i = 0$ 时，令 $k_i = 0$。由于序列长度有限，实际遮挡比例 k_i/L_i 可能与 r 略有差异，短序列中的差异尤为明显。这里的比例以有效序列位置计量，不直接对应原视频的时长比例。

遮挡位置从开头、中间、末尾和随机位置四种情形中等概率抽取。将有效位置依次编号为 $1, \ldots, L_i$，当 $k_i > 0$ 时，遮挡区间表示为

$$\mathcal{C}_i = \{b_i, b_i + 1, \ldots, b_i + k_i - 1\}, \tag{4.7}$$

其中 b_i 为区间起点。开头、末尾和中间遮挡分别取 $b_i = 1$、$b_i = L_i - k_i + 1$ 和 $b_i = \lfloor (L_i - k_i)/2 \rfloor + 1$，随机遮挡则从 $\{1, \ldots, L_i - k_i + 1\}$ 中均匀抽取起点。将选中模态在区间 C_i 内的观测标记为缺失，其余观测保留原索引，从而维持三种模态之间的位置对应关系。

当多个模态同时受到遮挡时，以相同概率采用同步遮挡或独立起点遮挡。前者使各模态在同一区间内缺失，后者允许各模态分别确定遮挡起点，从而模拟缺失位置不一致的情况。独立起点并不要求区间互不重叠：在开头、中间和末尾遮挡中，各模态起点仍然相同。随机遮挡时，区间也可能部分或完全重合。

具体处理时，语音与视觉的被遮挡特征在标准化后置零，并通过观测掩码将其标记为不可用。文本则在送入冻结的 DistilBERT 编码器之前屏蔽被遮挡词元，使其不参与注意力计算。这样可以避免被删除内容通过上下文编码保留在其他位置，使文本遮挡更接近信息实际不可用的情形。各模态的观测掩码均按上一小节的定义同步更新。

为减少文本重复编码的计算量，本文在训练前为每个样本生成并固定保存六种遮挡版本，同时保留一个未额外遮挡的原始版本。训练时，以 25% 的概率使用原始版本，以 75% 的概率从六种遮挡版本中均匀选择一个。其中，原始版本保留数据本身已有的缺失，并不意味着所有位置均可观测。

这种训练方式同时保留原始观测与模拟缺失两类样本，既让模型学习原有数据中的情感信息，又使其接触多种局部缺失情形。预先生成遮挡版本也减少了训练中的重复计算。由于每个样本仅保留有限种遮挡版本，训练期间不再重新生成遮挡区间，不能保证覆盖全部缺失组合。因此，后续通过统一设置的缺失场景检验模型表现，并对各对照模型使用相同的评价遮挡，以保证比较的公平性。

4.3 缺失感知门控模型构建

针对局部缺失导致的模态信息不完整及可用程度差异，本文构建缺失感知门控融合模型，其结构如图4.2所示。模型首先通过三个参数独立的时序编码分支分别提取文本、语音与视觉特征，再依据观测掩码进行池化，并引入缺失统计构造模态表示。在此基础上，门控网络结合模态内容与观测状态，自适应分配融合权重，所得融合表示经共享层后分别用于情感极性分类与强度回归。由此，模型在利用剩余观测信息的同时，将缺失状态显式纳入特征表示与融合过程。本节先给出各模块与联合训练目标，再统一训练和评价准则，最后通过递进消融检验增强、缺失感知处理与门控的作用。

4.3.1 时序编码与缺失状态表征

为便于后续门控融合，本文先分别提取文本、语音与视觉的内容特征，再结合各模态的缺失情况，形成统一维度的表示。这一过程既保留剩余观测中的情感信息，也向门控网络提供观测完整程度的依据。

三模态采用结构相同、参数独立的时序编码分支。各分支先将输入投影至 64 维，再通过两层残差时序卷积提取相邻位置的上下文信息。卷积核大小均为 3，膨胀率分别为 1 和 2，以逐步扩大局部信息的覆盖范围，残差连接用于保留原有特征。编码过程中以有效位置掩码 P 屏蔽边界标记与填充位置，最终得到时序特征矩阵 $H_i^{(m)} \in \mathbb{R}^{50\times 64}$，其中 $m \in \{T, A, V\}$。

随后，将时序特征汇总为固定维度的片段表示。由于缺失位置经过卷积后也可能产生非零特征，本文仅在观测掩码 O 标记的可观测位置上进行池化。具体结合两种方式：注意力池化通过可学习的评分分配位置权重，突出与预测任务相关的信息；均值池化则保留全部可观测位置的平均特征。两者拼接后，经线性映射、GELU 激活与层归一化，得到 64 维内容表示 $\overline{\boldsymbol{h}}_i^{(m)}$。这里的注意力用于模态内部的信息汇总，模态之间的权重由下一小节的门控机制确定。

仅有内容表示，难以明确区分观测充分与严重缺失的输入。因此，本文进一步用可用观测比例、最长不可用连续段比例和相对有效长度描述缺失状态。记 $n_i^{(m)} = \sum_{t=1}^{50} \widetilde{O}_{it}^{(m)}$ 为可观测位置数，$\ell_i^{(m)}$ 为有效范围内最长不可用连续段的长度，并令 $\overline{L}_i = \max\{1, L_i\}$，则缺

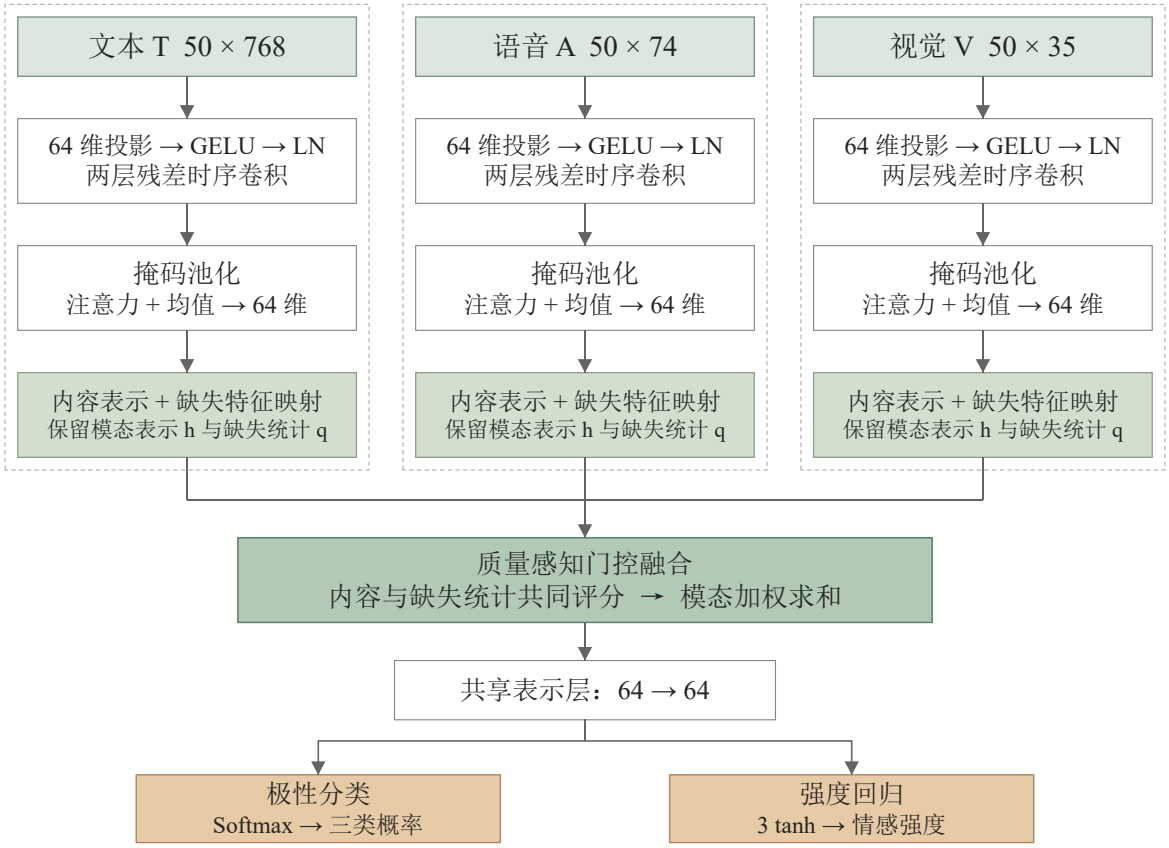


图 4.2　缺失感知门控融合模型结构

失特征为

$$\boldsymbol{q}_i^{(m)} = \left[\frac{n_i^{(m)}}{\overline{L}_i},\ \frac{\ell_i^{(m)}}{\overline{L}_i},\ \frac{\overline{L}_i}{48} \right]^{\mathsf{T}}. \tag{4.8}$$

三个分量分别反映剩余信息量、缺失的集中程度和序列长度，其中 48 为扣除起始与终止标记后的最大有效长度。这些统计仅在有效范围内计算，不将填充位置计为缺失。对 L_i 设置下限 1 用于处理空序列。因此，即使两个样本的缺失数量相同，模型也能区分集中缺失与分散缺失的情况。

最后，将缺失特征映射至 64 维并加入内容表示，得到缺失感知的模态表示：

$$\boldsymbol{h}_i^{(m)} = \begin{cases} \overline{\boldsymbol{h}}_i^{(m)} + W_q \boldsymbol{q}_i^{(m)} + \boldsymbol{b}_q, & n_i^{(m)} > 0, \\ \mathbf{0}, & n_i^{(m)} = 0. \end{cases} \tag{4.9}$$

其中，$W_q \in \mathbb{R}^{64\times 3}$ 与 $\boldsymbol{b}_q \in \mathbb{R}^{64}$ 由三模态共享。完全不可观测的模态表示置零，避免在没有观测依据时产生非零分支输出。由此，$\boldsymbol{h}_i^{(m)}$ 与 $\boldsymbol{q}_i^{(m)}$ 分别提供内容及缺失状态信息，共同用于后续门控权重的计算。

4.3.2 缺失感知的模态门控融合

局部缺失会改变各模态的可用信息量，使固定融合权重难以适应不同样本的观测状态。为此，本文构建缺失感知门控网络，根据模态内容及观测完整程度联合确定融合权重。

本节以可用观测比例、最长不可用连续段比例及相对有效长度作为观测质量描述，使融合过程能够显式利用缺失特征。

根据上一小节，每个模态已获得 64 维缺失感知表示 $\boldsymbol{h}_i^{(m)}$ 和三维缺失特征 $\boldsymbol{q}_i^{(m)}$。将二者拼接为 67 维向量，输入具有 32 维隐层的门控网络，得到模态评分

$$s_i^{(m)} = \boldsymbol{w}_g^{\mathsf{T}} \tanh\Big(W_g[\boldsymbol{h}_i^{(m)}; \boldsymbol{q}_i^{(m)}] + \boldsymbol{b}_g\Big) + c_g, \tag{4.10}$$

其中 $W_g \in \mathbb{R}^{32\times 67}$、$\boldsymbol{b}_g \in \mathbb{R}^{32}$，$\boldsymbol{w}_g \in \mathbb{R}^{32}$、$c_g \in \mathbb{R}$，隐层采用双曲正切激活函数。三模态共享同一评分网络，以一致的计算规则处理各自的内容表示与缺失统计。虽然缺失特征已参与上一小节的模态表示构造，此处仍将其显式输入门控，使评分网络能够直接利用观测完整程度。

对于完全不可观测的模态，不将其纳入可用模态之间的权重分配。记样本 i 的可用模态集合为 $\mathcal{M}_i = \{m \in \mathcal{M} : n_i^{(m)} > 0\}$。当 $\mathcal{M}_i \neq \varnothing$ 时，在该集合内对评分进行 Softmax 归一化：

$$\beta_i^{(m)} = \begin{cases} \dfrac{\exp\Big(s_i^{(m)}\Big)}{\sum_{n\in\mathcal{M}_i} \exp\Big(s_i^{(n)}\Big)}, & m \in \mathcal{M}_i, \\ 0, & m \notin \mathcal{M}_i. \end{cases} \tag{4.11}$$

由此得到的权重满足 $\beta_i^{(m)} \geq 0$ 且 $\sum_{m\in\mathcal{M}} \beta_i^{(m)} = 1$。归一化过程使可用模态的评分形成相对权重，若仅有一个模态保留观测，其权重为 1。与时间维度的注意力池化不同，此处权重作用于完整的模态片段表示，用于控制各模态在融合结果中的占比。

最终采用加权求和构造多模态融合向量：

$$\boldsymbol{z}_i = \sum_{m\in\mathcal{M}} \beta_i^{(m)} \boldsymbol{h}_i^{(m)}, \qquad \boldsymbol{z}_i \in \mathbb{R}^{64}. \tag{4.12}$$

由于三个分支具有相同的输出维度，加权融合后仍保持 64 维表示。门控参数与预测网络共同训练，融合权重随样本内容和缺失状态变化，而非使用预先设定的固定模态比例。极性分类与强度回归共享该融合结果，两项任务共同参与门控参数的学习。

当三个模态均不可观测时，上一小节已将各分支表示置为零，因此融合向量同样为零。后续共享层与预测头依据已学习参数产生有限输出，保证这一边界输入下的计算有定义。对于一般输入，融合向量 $\boldsymbol{z}_i$ 则同时包含剩余观测的内容信息及门控对各模态的权重调整，随后用于极性与强度的联合预测。

需要说明的是，观测完整程度是门控的输入之一，融合权重还取决于模态内容及训练所得参数，因此不应将其直接理解为预测正确率。权重在本模型中表示内部融合系数，其作用通过后续消融实验及不同缺失条件下的性能比较进行评价。

4.3.3 情感极性与强度的联合预测

情感极性用于区分负向、中性与正向三类情感，情感强度则以连续数值刻画情感表达的方向及程度。两项任务依赖相同的多模态信息，但输出形式与描述侧重点不同。因此，本文在缺失感知门控融合的基础上设置共享表示层，并分别构建分类头与回归头，实现极性与强度的联合预测。

将上一小节得到的融合向量 $\boldsymbol{z}_i \in \mathbb{R}^{64}$ 输入共享全连接层，经非线性变换得到预测表示

$$\boldsymbol{v}_i = \mathrm{Drop}_{0.2}[\mathrm{GELU}(W_s\boldsymbol{z}_i + \boldsymbol{b}_s)], \tag{4.13}$$

其中 $W_s \in \mathbb{R}^{64\times 64}$、$\boldsymbol{b}_s \in \mathbb{R}^{64}$，Dropout 在推理阶段关闭。共享表示层对融合后的多模态信息进行进一步变换，为两项任务提供共同的预测依据。

对于情感极性，分类头将 $\boldsymbol{v}_i$ 映射为三个类别的得分，再通过 Softmax 函数转化为类别概率：

$$\boldsymbol{p}_i = \mathrm{softmax}(W_c \boldsymbol{v}_i + \boldsymbol{b}_c), \qquad \widehat{c}_i = \arg\max_{k\in\{0,1,2\}} p_{ik}, \tag{4.14}$$

其中 $W_c \in \mathbb{R}^{3\times 64}$、$\boldsymbol{b}_c \in \mathbb{R}^3$，$p_{ik}$ 表示样本 i 属于第 k 类的预测概率，类别 0、1、2 依次对应负向、中性与正向。模型以概率最大的类别作为极性预测结果。

对于情感强度，回归头将共享表示映射为一个标量，并采用缩放后的双曲正切函数约束输出范围：

$$\widehat{y}_i = 3\tanh\left(\boldsymbol{w}_r^{\mathsf{T}} \boldsymbol{v}_i + b_r\right), \tag{4.15}$$

其中 $\boldsymbol{w}_r \in \mathbb{R}^{64}$、$b_r \in \mathbb{R}$。由于双曲正切函数的值域为 $(-1,1)$，该映射使预测值满足题目规定的 $[-3,3]$ 范围约束。预测值的正负反映情感方向，绝对值反映情感表达的强弱。

上述结构通过共享表示建立两项任务之间的信息联系，同时保留各自的输出映射。极性由分类概率确定，强度由回归头直接给出，二者之间未施加强制一致性约束。因此，分类结果与回归值符号可能出现分歧，中性类别的强度预测也不必严格等于零。本文保留两项原始预测结果，以便分别评价分类与回归性能。下面给出联合训练目标，优化器设置与评价方法在下一小节统一给出。

为同时学习极性类别与连续强度，训练目标由类别加权交叉熵和 SmoothL1 回归损失组成。记训练集样本数为 N_{tr}，其中第 k 类样本数为 N_k，类别权重取为

$$\omega_k = \frac{\sqrt{N_{\mathrm{tr}}/(3N_k)}}{\frac{1}{3}\sum_{j=0}^{2}\sqrt{N_{\mathrm{tr}}/(3N_j)}}, \qquad k = 0,1,2. \tag{4.16}$$

该权重仅由训练集标签确定，使少数类别在分类目标中获得较高的相对权重。对一个训练批次 $\mathcal{B}$，联合损失定义为

$$\mathcal{L} = -\frac{\sum_{i\in\mathcal{B}} \omega_{c_i} \log p_{i,c_i}}{\sum_{i\in\mathcal{B}} \omega_{c_i}} + \frac{1}{|\mathcal{B}|}\sum_{i\in\mathcal{B}} \ell(\widehat{y}_i - y_i), \tag{4.17}$$

式中分类损失记为 $\mathcal{L}_{\mathrm{cls}}$，回归损失记为 $\mathcal{L}_{\mathrm{reg}}$，两项系数均为 1，且

$$\ell(e) = \begin{cases} \frac{1}{2}e^2, & |e| < 1, \\ |e| - \frac{1}{2}, & |e| \geq 1. \end{cases} \tag{4.18}$$

SmoothL1 损失在小误差区间采用二次形式，在大误差区间采用线性形式，以限制大误差样本对回归损失导数的影响。分类与回归共同更新共享编码及融合网络，各预测头分别学习相应的输出映射。

4.3.4 模型训练与评价准则

在模型结构与联合损失确定后，先统一训练、评价与选型规则，再开展模块消融和框架比较。参数学习与标准化统计量估计仅使用训练集，验证集用于早停和模型选择。本文所称完整输入，是指未额外施加人工遮挡的输入，仍保留原始数据中的不可用位置。主模型按公式(4.17)训练，分类与回归损失系数均为 1，冻结文本编码器不参与参数更新。

参数优化采用 AdamW，主要设置见表4.3。增强训练沿用第4.2.3节的六个固定遮挡视图，以 25% 的概率选取完整输入，其余概率均匀分配给六个增强视图。每轮重新打乱样本顺序并抽取输入视图，遮挡视图本身不随训练轮次重新生成。实验在配备 NVIDIA GeForce RTX 4090 D 显卡的 Linux 环境下完成，使用 PyTorch 2.5.1 与 CUDA 12.1。

表 4.3　主模型训练设置

参数	设置
优化器与批量大小	AdamW，64
初始学习率与权重衰减系数	均为 10^{-3}
学习率调度	余弦退火，最低学习率 10^{-4}
最大训练轮数	35
Dropout 概率与梯度范数上限	0.2，5
早停耐心轮数与最小改善量	7，10^{-5}
训练随机种子	17、29、43

极性分类采用三分类准确率（Acc）与宏平均 F1（Macro-F1）评价，强度回归采用平均绝对误差（MAE）与 Pearson 相关系数评价。记评价集样本数为 n，第 k 类的真正例、假正例与假负例分别为 TP_k、FP_k 和 FN_k，则

$$\begin{aligned}
\mathrm{Acc} &= \frac{1}{n}\sum_{i=1}^{n}\mathbf{1}(\widehat{c}_i = c_i),\\
F^{\mathrm{macro}} &= \frac{1}{3}\sum_{k=0}^{2}\frac{2\mathrm{TP}_k}{2\mathrm{TP}_k + \mathrm{FP}_k + \mathrm{FN}_k},\\
\mathrm{MAE} &= \frac{1}{n}\sum_{i=1}^{n}|\widehat{y}_i - y_i|,\\
R_{\mathrm{neu}} &= \frac{\mathrm{TP}_1}{\mathrm{TP}_1 + \mathrm{FN}_1}.
\end{aligned} \tag{4.19}$$

Macro-F1 对三个类别赋予相同权重，避免多数类表现掩盖其他类别的识别不足，R_{neu} 为中性类别召回率，其中类别编号 1 对应中性。设真实强度与预测强度的样本均值分别为 $\bar{y}$ 和 $\overline{\widehat{y}}$，则

$$\rho = \frac{\sum_{i=1}^{n}(y_i - \bar{y})(\widehat{y}_i - \overline{\widehat{y}})}{\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}\sqrt{\sum_{i=1}^{n}(\widehat{y}_i - \overline{\widehat{y}})^2}}. \tag{4.20}$$

其中 MAE 越小越好，其余上述指标越大越好。

为兼顾完整输入性能与缺失鲁棒性，验证阶段固定设置完整输入以及五个缺失场景：文本、语音、视觉分别遮挡 30%，三模态同步遮挡 30% 和 50%。缺失位置均按固定随机种子生成，并在各轮验证中保持不变。记这五个场景的集合为 $\mathcal{S}_{\mathrm{val}}$，采用

$$\begin{aligned}
J = 0.5\,&(\mathrm{MAE}_{\mathrm{clean}} + 1 - F^{\mathrm{macro}}_{\mathrm{clean}})\\
&+ 0.1\sum_{s\in\mathcal{S}_{\mathrm{val}}}(\mathrm{MAE}_s + 1 - F^{\mathrm{macro}}_s)
\end{aligned} \tag{4.21}$$

作为训练检查点与基础消融结构的综合验证指标，J 越小越好。完整输入与五个缺失场景的总权重各为 0.5。该指标用于验证选型，不参与反向传播。当 J 较已保存的最优值下降超过 10^{-5} 时更新检查点，连续 7 轮未达到该条件则停止训练，并恢复最优参数。

三个随机种子对应的模型分别按验证指标早停。集成时，先对三个模型的分类概率和强度输出分别取算术平均，再计算评价指标，极性由平均概率最大的类别确定。下一小节的四种消融配置均采用该方式，并依据集成后的验证指标 J 选择基础结构。

不同训练种子的预测集成与不同遮挡实现的指标平均分属两个层次。评价同一遮挡实现时，各模型使用相同的删除掩码；比较随机遮挡条件时，再对重复实现的指标取均值。

框架对比中的 112 种连续缺失条件按条件等权汇总，其覆盖范围与用于早停的六场景 J 不同。各对比框架的训练调整在第4.4节分别说明，鲁棒性实验的完整遮挡矩阵在第4.5.1节给出。

4.3.5 模块消融与作用分析

为检验连续遮挡增强、缺失感知处理与质量感知门控的作用，本文在统一的三模态时序编码和双任务预测结构下构建四种逐步扩展的模型，配置见表4.4。M_0 采用完整输入训练，并对三个模态进行等权融合；M_1 在此基础上加入连续遮挡增强；M_2 进一步采用观测掩码池化并引入缺失特征；M_3 将等权融合替换为质量感知门控，即上述时序编码、掩码池化、质量感知门控与双头预测共同构成的主模型。此处“缺失感知处理”同时包含掩码池化与缺失特征，两者未在本组实验中单独拆分。

表 4.4　消融模型配置

模型	融合方式	连续遮挡增强	缺失感知处理	动态门控
M_0	等权融合	否	否	否
M_1	等权融合	是	否	否
M_2	等权融合	是	是	否
M_3	门控融合	是	是	是

四种模型使用相同的数据划分、损失函数、优化参数和训练预算，分别采用 17、29 和 43 三个随机种子训练。M_1 至 M_3 使用相同的固定增强库，评价时所有模型共享同一组遮挡掩码。各模型先平均三个种子的分类概率与回归输出，再计算集成性能，从而保持主要对比条件一致。训练和评价均遵循第4.3.4节的约定。

依据式(4.21)，以六场景验证指标 J 进行早停和基础结构选择，J 越小越好。表4.5同时列出验证选型依据与锁定后的测试表现：后四列均来自 727 条测试样本，其中缺失条件为三模态同步、随机位置、单连续段遮挡 50%，取三次遮挡实现的指标均值。验证指标决定选型，测试结果用于分析模块作用，二者在表中分别标明。

表 4.5　消融模型的验证选型指标与测试性能

模型	验证集 J	测试集完整输入		测试集遮挡 50%	
		Macro-F1	MAE	Macro-F1	MAE
M_0	1.0354	0.6007	0.6609	0.4328	0.7936
M_1	1.0111	0.5847	0.6537	0.5180	0.7384
M_2	1.0055	0.5912	0.6585	0.5280	0.7413
M_3	0.9919	0.5989	0.6512	0.5316	0.7304

从 M_0 与 M_1 的比较可见，连续遮挡增强带来了本组比较中最大幅度的缺失性能改善。引入增强后，缺失条件下的 Macro-F1 由 0.4328 提高至 0.5180，MAE 由 0.7936 降低至 0.7384，表明训练阶段接触不完整输入能够有效缓解测试时的分布变化。与此同时，完整输入下的 Macro-F1 由 0.6007 下降至 0.5847，说明增强训练具有性能权衡，其合理性需要依据完整与缺失场景的综合表现判断。

从 M_1 与 M_2 的比较可见，加入掩码池化与缺失特征后，缺失条件下的 Macro-F1 进一步提高至 0.5280，但 MAE 由 0.7384 小幅上升至 0.7413。该结果说明，显式区分可观测位置与缺失位置有助于本场景中的极性分类，却未同时改善回归误差。由于两项缺失处理在实验中共同引入，这一差异应解释为其组合效果。

从 M_2 与 M_3 的比较可见，质量感知门控在已有增强和缺失处理的基础上改善了所列指标的点估计。缺失条件下，Macro-F1 增加 0.0036，MAE 降低 0.0109；完整输入下，两项指标也分别由 0.5912、0.6585 改善至 0.5989、0.6512。门控依据样本内容与可用信息状态调整模态权重，为等权融合提供了有益补充。

图4.3进一步给出四档三模态同步随机遮挡下的性能变化。0% 对应完整输入，其余各点为三次遮挡的指标均值，误差棒为这三次实现的样本标准差。与未进行增强的 M_0 相比，三个增强模型在较高遮挡比例下均能维持更好的预测性能；尤其在 70% 遮挡时，M_0 的 Macro-F1 降至 0.3013，而主模型仍为 0.5051。

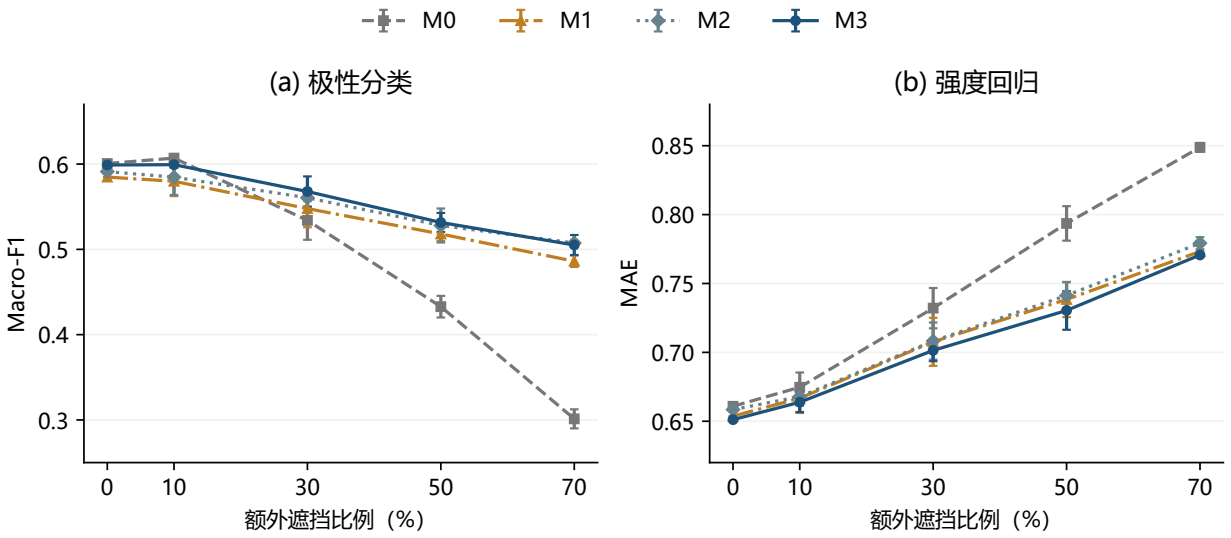


图 4.3　消融模型的缺失响应

在 10%、30%、50% 和 70% 四档遮挡中，主模型的 MAE 均为四种结构中最低，体现出较稳定的强度预测优势。其 Macro-F1 在 30% 和 50% 时最高，但在 70% 时略低于 M_2 的 0.5075。因此，门控模型的优势是综合分类与回归后的表现，而非在每个缺失比例、每项指标上均占优。

进一步检查训练随机性，在 50% 遮挡场景下，各种子先对三次遮挡取平均，再计算种子间均值与样本标准差。M_0 的 Macro-F1 为 0.4232 ± 0.0160，M_3 为 0.5246 ± 0.0036，说明整体方案的鲁棒性收益也体现在单种子模型的平均表现中。针对第一次固定遮挡实现，以 381 个源视频为单位进行 500 次配对聚类 Bootstrap，M_3 相对 M_0 的 Macro-F1 差值为 0.0800，其 95% 置信区间为 $[0.0420, 0.1187]$。MAE 差值为 -0.0648，区间为 $[-0.0967, -0.0357]$。这为该固定遮挡下的整体改善提供了统计支持。

四种基础结构中，M_3 取得最小的验证指标 $J = 0.9919$，因此选为后续框架比较的主模型。测试消融进一步表明：连续遮挡增强改善了中高比例缺失下的表现，缺失感知处理有助于所考察场景的分类，门控则在已有设计上改善了分类与回归的综合表现。这些结果支持当前模块组合的合理性。下一节将主模型与三类设计更为复杂的替代框架比较，佐证模型的选择。

4.4 多框架对比与模型选择

上一节的消融实验检验了主模型内部设计的作用，但尚不能说明其他建模框架是否更适合本题。为检验主模型的选用合理性，本节从监督与表示学习、分类与回归的融合方式、时序及跨模态交互三个角度，构建三类替代框架。各框架沿用相同的数据划分、冻结文本编码器和双任务定义，均使用 17、29 和 43 三个随机种子形成集成预测。框架内部设置相应对照，框架之间则按统一验证口径比较。

以下依次介绍训练调整与辅助学习、任务专属门控与决策层融合、自注意力与跨模态注意力三类框架，再在第4.4.4节汇总其性能与选型依据。三类框架分别回答增强监督、分离任务权重和扩大信息交互范围是否有利于预测。它们包含多种实验配置，并不等同于仅有三个候选模型，而是三套框架思路。各框架的结构与训练设置存在差异，因此统一验证比较用于评价整体方案。

4.4.1 框架一：动态缺失增强与辅助学习

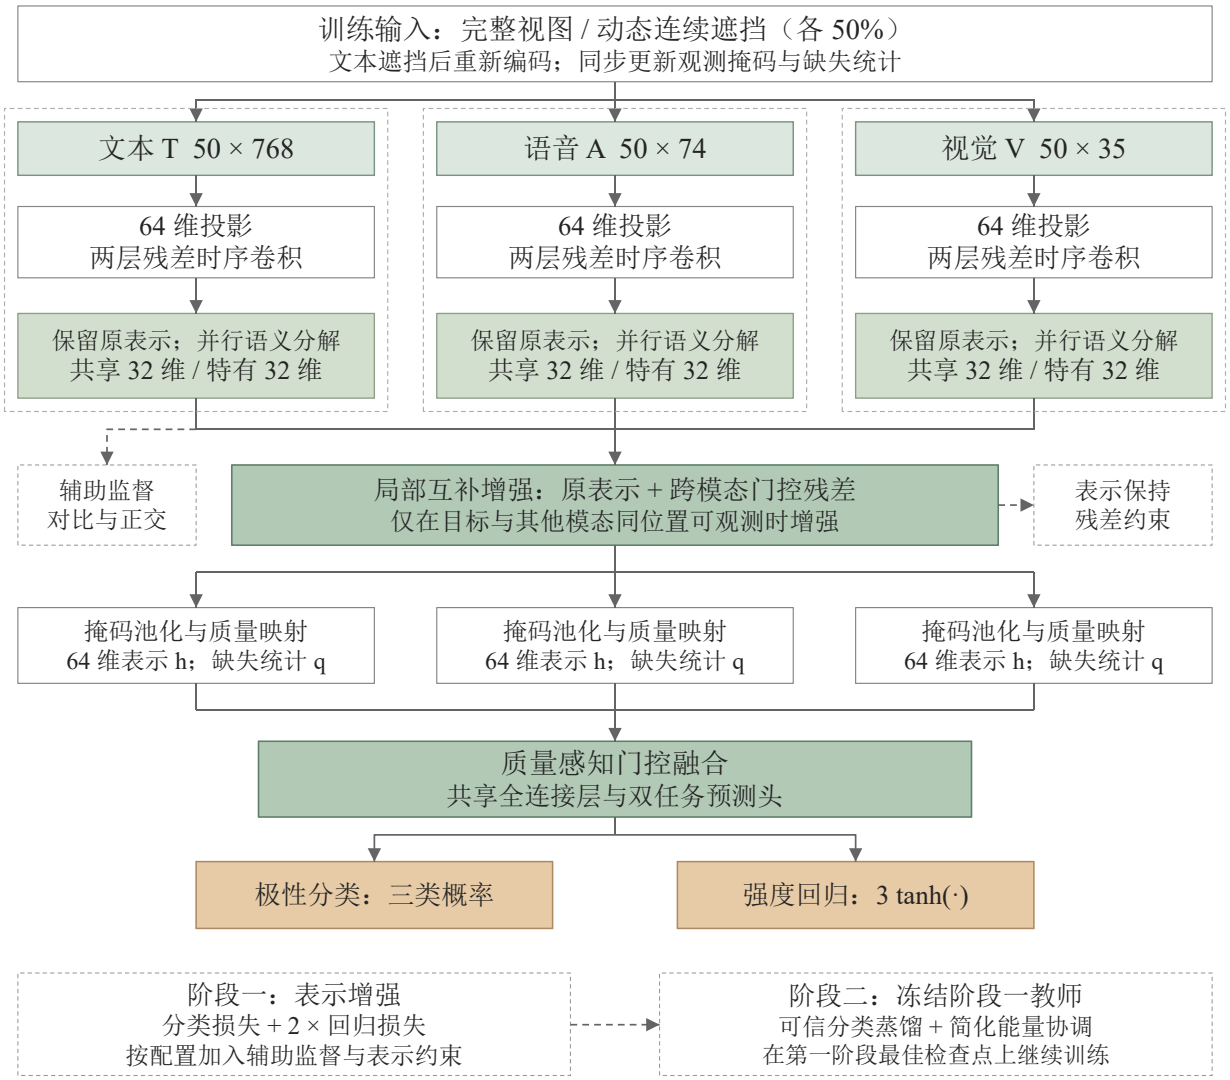


图 4.4　动态缺失增强与辅助模块框架

第一类对比框架考察训练方式与辅助学习能否改善剩余观测的利用，设计借鉴 He 等提出的 EBMC 框架 [11]。该框架采用“先增强、后平衡”的两阶段思路：先通过共享与特有语义分解及跨模态互补增强改善模态表示，再利用能量协调与样本可信度蒸馏调节模态协作。其启示在于，多模态性能的改善既取决于融合权重，也取决于各模态自身提供有效信息的能力。

为检验直接约束单模态表示及模态协作是否有益，本文据此设置辅助学习对照，并结合连续区间缺失、冻结文本编码器以及极性与强度双任务进行适配。首先，在保留时序卷

积、掩码池化与门控融合框架的基础上，调整增强方式和双任务训练目标。将六个固定遮挡视图改为按训练种子、轮次及样本编号生成动态连续遮挡，完整输入与遮挡输入的抽样概率各为 50%。同一种子下的各候选使用相同遮挡，以控制样本难度差异。回归损失系数在种子 17 下比较 0.5、1 和 2 后，依据验证指标固定为 2，即主任务损失取为

$$\mathcal{L}_{\text{task}} = \mathcal{L}_{\text{cls}} + 2\mathcal{L}_{\text{reg}}, \tag{4.22}$$

其中分类损失与 SmoothL1 回归损失的定义沿用第4.3.3节。训练分为两个阶段，轮数上限分别为 20 和 15，早停耐心均为 5 轮。第二阶段从第一阶段的最佳检查点开始，并重置优化器。最终保留两个阶段中 J 最小的检查点。同时，该框架将输入投影后的不可观测位置置零，再进行时序卷积。因此，该方案与主模型的差异包含训练设置及输入处理的共同调整，不能解释为单一超参数的作用。以下将这一训练策略与输入处理调整后的门控模型简称为“训练调整门控”。

在此基础上，依次累加五类辅助设计：单模态辅助监督、共享与特有表示分解、局部互补增强、可信分类蒸馏与能量协调。其中，单模态辅助监督、共享与特有表示分解及局部互补增强对应“先增强”的思路。单模态辅助监督为各分支设置独立分类与回归头，使单个模态获得直接的任务约束；共享与特有表示分解将特征映射为两组 32 维表示，通过跨模态对比约束对齐共享信息，并降低共享与特有表示的相关性；局部互补增强利用其他模态在同一位置的可用表示，为目标模态的可观测位置增加门控残差。该增强仅调整已有观测，不重建缺失信号。

可信分类蒸馏与能量协调对应“后平衡”的思路。可信分类蒸馏在第二阶段利用冻结的第一阶段教师，按观测覆盖率与预测熵确定蒸馏权重，并约束学生的分类概率；该权重是启发式可靠性指标，未用于回归蒸馏。能量协调则将分支表示幅度、单模态任务损失及教师分类熵组合成能量，对有效模态之间的能量差施加惩罚，并加入表示范数项的梯度正则。两种第二阶段机制均接受验证检查点选择，不预设其一定改善最终模型。

如图4.4所示，训练调整与辅助学习框架在三模态编码的基础上引入语义分解与局部互补增强，并结合辅助监督、可信分类蒸馏与能量协调，形成“先增强、后平衡”的两阶段训练方案。图中展示辅助模块逐项累加后的完整结构；实验从训练调整门控出发，依次加入前述五类模块，并保留相同训练设置下的单模态与固定融合对照。三模态连线的汇合表示汇集各分支信息，局部增强后仍保留三条模态序列；底部给出两阶段训练安排，虚线表示训练约束或阶段衔接。

各配置的验证性能、阶段检查点保留情况及模块累加效果统一在第4.4.4节比较。

4.4.2 框架二：任务专属门控与决策层融合

主模型让两项任务共享模态融合权重，第二类框架检验是否有必要为分类与回归分别分配权重。极性分类关注类别边界，强度回归关注连续幅度，两项任务可能需要不同的模态组合。为检验共享融合权重是否限制预测，在训练调整门控的基础上构建任务专属门控，并以冻结专家后融合作为另一类对照。这一设计用于检验两项任务对模态组合的需求差异，不预先假定共享融合必然造成梯度冲突。

任务专属门控的设计参考 Ma 等提出的多门控混合专家模型（MMoE）[12]。该模型在多个任务间共享专家网络，同时为各任务设置独立门控，使不同任务能够学习不同的专家组合。借鉴这一机制，本文以三模态分支表示作为共同的信息来源，分别学习分类与回归的模态权重，从而在保留共享表征的同时允许任务需求分化。这里借鉴的是任务相关加权机制，本文的模态分支与原模型的通用专家网络并不等同。

任务专属门控为分类和回归分别设置权重生成网络。记任务索引为 a，分别取 cls 与

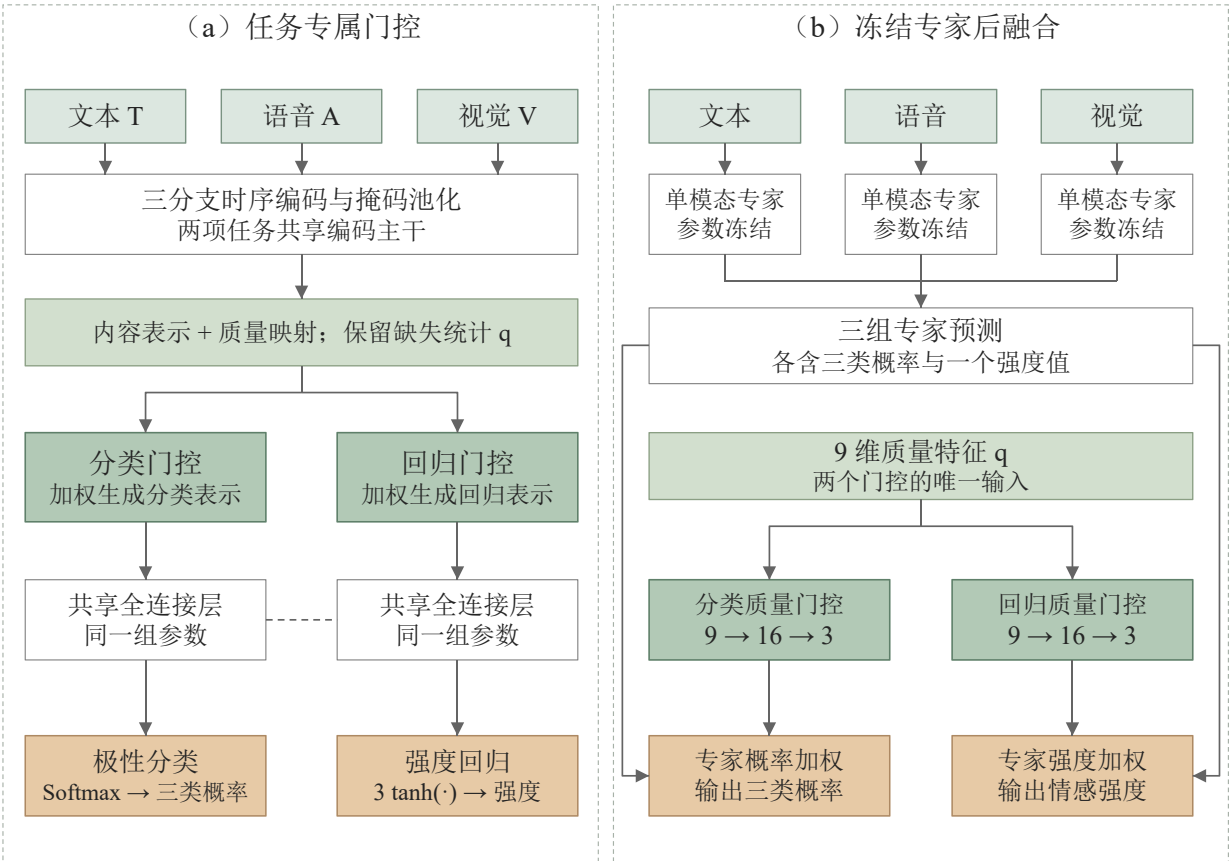


图 4.5　任务专属门控与决策层融合框架

reg，可观测模态集合为 $\mathcal{M}_i$，则对 $m \in \mathcal{M}_i$ 有

$$\begin{aligned} \beta_{i,m}^{(a)} &= \frac{\exp g_a\left(\boldsymbol{h}_i^{(m)}, \boldsymbol{q}_i^{(m)}\right)}{\sum_{j \in \mathcal{M}_i} \exp g_a\left(\boldsymbol{h}_i^{(j)}, \boldsymbol{q}_i^{(j)}\right)}, \\ \boldsymbol{z}_i^{(a)} &= \sum_{m \in \mathcal{M}_i} \beta_{i,m}^{(a)} \boldsymbol{h}_i^{(m)}. \end{aligned} \tag{4.23}$$

不可观测模态的权重置零。两项融合表示经过参数共享的全连接网络，再进入各自的预测头，时序编码与池化网络仍然共享。回归门控由分类门控复制初始化，使评估模式下的初始预测与相应共享门控基线一致。“任务专属”仅指两套门控分别生成权重，时序编码器与共享全连接层仍由两项任务共用。

后融合也称决策层融合，先由各模态独立完成预测，再组合预测结果。这一设计可由 Baltrušaitis 等关于多模态融合的分类与讨论获得依据 [13]。在本题中，冻结单模态专家使门控训练能够集中检验不同缺失条件下的预测组合效果，但这种结构不再学习底层特征之间的交互，需与特征层门控形成对照。

具体而言，后融合方案冻结已训练的文本、语音和视觉单模态专家，仅训练两个由 9 维质量特征到 16 维隐层、再到三模态权重的门控网络。三种模态均可用时，初始权重依次为 0.8、0.1 和 0.1，随后由训练数据调整。分类任务混合专家概率，回归任务混合专家强

度：

$$\begin{aligned} \boldsymbol{p}_i &= \sum_{m \in \mathcal{M}_i} \gamma_{i,m}^{(\mathrm{cls})} \boldsymbol{p}_i^{(m)}, \\ \widehat{y}_i &= \sum_{m \in \mathcal{M}_i} \gamma_{i,m}^{(\mathrm{reg})} \widehat{y}_i^{(m)}. \end{aligned} \tag{4.24}$$

其中权重非负，并在可用专家之间归一化。回归输出不再重复施加双曲正切变换，且满足

$$\min_{m \in \mathcal{M}_i} \widehat{y}_i^{(m)} \le \widehat{y}_i \le \max_{m \in \mathcal{M}_i} \widehat{y}_i^{(m)}. \tag{4.25}$$

因此，如果可用专家均低估同一方向的强情感，后融合无法通过凸组合将预测幅度扩展到专家范围之外。该方案仅有 422 个新增可训练参数，但部署还需保留三个专家，单个种子对应的任务网络总参数量为 178008，不含冻结文本编码器，其计算成本也包含专家预训练。

如图4.5所示，任务专属门控与后融合分别在表示层和预测层实现面向不同任务的模态组合。图中左侧结构为分类与回归分别生成融合权重，两条任务路径中的全连接层使用同一组参数；右侧结构冻结单模态专家，仅由质量特征生成门控权重，再分别对专家的分类概率与强度预测进行加权。

共享门控、任务专属门控与后融合的性能及配对统计统一在第4.4.4节报告。

4.4.3 框架三：模态内自注意力与跨模态注意力

第三类框架考察主模型的局部时序编码是否需要更广泛的信息交互。时序卷积通过邻域逐层提取信息，连续缺失可能使相隔较远的情感线索难以在有限感受野内建立联系。为检验更广泛的时序交互是否有益，本文参考 Vaswani 等提出的 Transformer 结构中的多头自注意力机制 [14]，使同一模态的可观测位置能够直接相互关联。在本题的掩码约束下，该机制允许跨越遮挡区间聚合剩余信息，其效果仍需通过实验评价。

跨模态注意力进一步参考 Tsai 等提出的 MulT 模型 [15]。该模型通过有方向的成对跨模态注意力建立不同模态、不同时间位置之间的联系，为利用异步情感线索提供了设计依据。本文将这一思想用于已对齐的三模态序列，在模态内交互之后增加模态间交互，以检验剩余文本、语音与视觉信息能否提供互补。

据此构建模态内自注意力与跨模态注意力两种轻量结构。各模态先投影到 64 维，加入固定正弦位置编码与可学习的模态编码，再进行四头自注意力计算，每个头的维数为 16。

以单个样本的一头注意力为例，记位置 u 的查询向量为 $\boldsymbol{Q}_u$，位置 v 的键和值向量分别为 $\boldsymbol{K}_v$ 与 $\boldsymbol{V}_v$。这些向量由层归一化后的输入线性映射得到，合法连接掩码记为 M_{uv}，则

$$a_{uv} = \frac{M_{uv} \exp\!\left(\boldsymbol{Q}_u^{\top} \boldsymbol{K}_v / \sqrt{16}\right)}{\sum_{w} M_{uw} \exp\!\left(\boldsymbol{Q}_u^{\top} \boldsymbol{K}_w / \sqrt{16}\right)}. \tag{4.26}$$

该头的聚合结果为 $\sum_v a_{uv} \boldsymbol{V}_v$。模态内自注意力仅连接同一模态中的可观测位置。跨模态方案在自注意力之后，将三条序列拼接为 150 个位置，并增加一层共享注意力，使每个查询仅访问其他模态的可观测位置。其合法连接为

$$M_{uv}^{\mathrm{cross}} = \widetilde{O}_u \widetilde{O}_v \mathbf{1}[m(u) \neq m(v)], \tag{4.27}$$

其中 $m(u)$ 表示位置 u 所属模态，$\widetilde{O}_u$ 为该位置的观测标记。当不存在合法键时，注意力权重及对应增量均置零。各注意力块均包含残差连接、层归一化和前馈网络，层输出继续屏蔽不可观测位置。

该实现以拼接序列上的共享注意力层完成模态间交互，并显式加入连续缺失掩码，属于 MulT 跨模态交互思想的轻量适配，未采用其完整的有向成对网络结构。最终对可观测

位置进行均值池化，将三模态表示与 9 维质量特征拼接后完成双任务预测。因此，注意力方案不仅改变时序编码，还调整了池化与末端融合方式，不能将其相对主模型的全部差异归因于某一注意力矩阵。

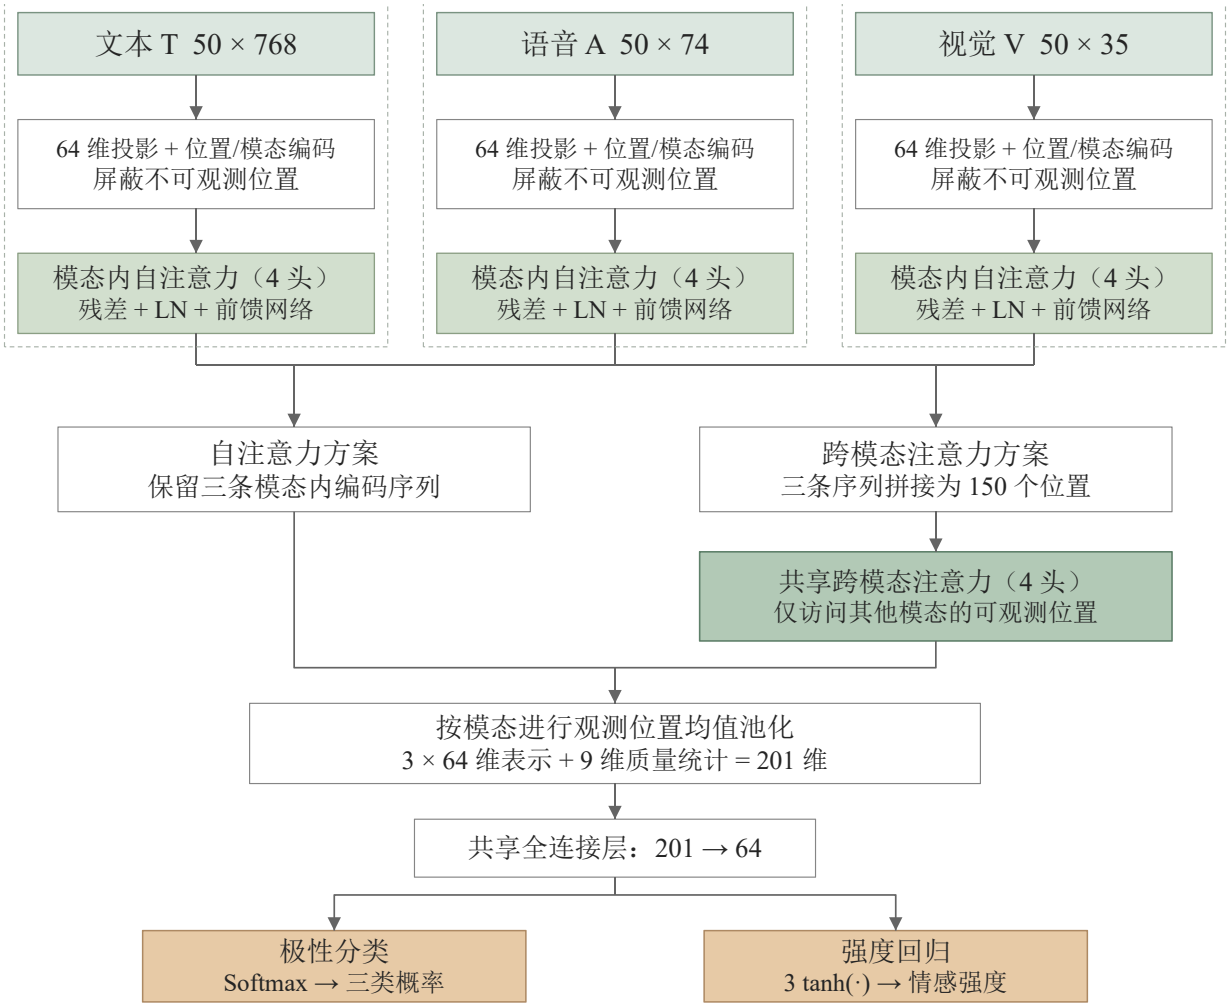


图 4.6　自注意力与跨模态注意力框架

如图4.6所示，自注意力方案通过模态内交互关联不同观测位置，跨模态注意力方案则在此基础上进一步引入异模态信息交互。图中的两条中间路径对应分别训练的候选，其后续池化与双任务输出形式一致。跨模态交互过程中，各位置的模态归属保持不变。

为形成内部对照，另设置不含任务注意力块的池化模型，以及仅以完整输入训练的跨模态注意力模型。四种结构均使用学习率 3×10^{-4}、最多 30 轮训练、早停耐心 6 轮及回归损失系数 2。除完整输入训练对照外，其余结构共用动态遮挡。池化模型仍使用冻结文本编码器，故“无任务注意力块”仅指新增预测网络。四种配置的性能与参数规模统一在第4.4.4节比较。

4.4.4 综合性能比较与选型依据

本节统一使用 728 条验证样本，报告三种子集成后的结果。“完整输入”表示未额外施加人工遮挡；“连续缺失”表示 112 种主缺失条件的等权平均，即先在每种条件内平均随机遮挡重复，再对各条件取均值。多短段及独立起点对照不计入该均值。六场景验证指标 J 仍按式(4.21)计算，用于训练检查点选择；它与 112 场景均值的覆盖范围不同，二者

不混用。

第4.3.5节已按验证指标 J 在四种基础结构中选出主模型。本节的比较进一步回答：相对于这一已确定的方案，采用替代框架是否能在连续缺失条件下获得足够且均衡的收益。前者是基础结构之间的择优，后者是替代方案的收益检验，候选的 J 较低并不自动意味着满足替换条件。

考虑问题二同时要求缺失条件下的极性与强度预测，替代框架应取得具有实际幅度的分类收益，同时不牺牲回归表现。记候选与主模型的缺失平均 Macro-F1 差值为 $\Delta\overline{F}$，缺失平均 MAE 差值为 $\Delta\overline{E}$，均按“候选减主模型”计算，采用以下两项核心要求：

$$\Delta\overline{F} \geq 0.01, \qquad \Delta\overline{E} \leq 0. \tag{4.28}$$

即缺失平均 Macro-F1 至少提高 1 个百分点，且缺失平均 MAE 不增加。这两项条件沿用既有比较协议，是原替换规则的必要条件：任一不满足，候选即不能替换主模型。原则上还约束完整输入、中性召回和强情感误差。

表4.6汇总主模型及三类框架下的 16 种替代或对照配置。训练调整与辅助模块部分按逐行累加构造，后一行包含前一行已有模块。任务融合与注意力部分分别构成独立的结构对照。单模态模型用于判断各模态的独立预测能力，不作为本题多模态模型的替换候选。

表 4.6　验证集三类框架及其对照配置的性能

方案	$J\downarrow$	连续缺失		完整输入	
		Macro-F1↑	MAE↓	Macro-F1↑	MAE↓
主模型与基础对照					
主模型	0.9926	0.5811	0.6067	0.6055	0.5784
文本对照	0.9796	0.5871	0.6032	0.6215	0.5702
语音对照	1.4629	0.3207	0.7822	0.3189	0.7800
视觉对照	1.3450	0.4051	0.7544	0.4076	0.7508
动态增强固定融合	0.9946	0.5776	0.6102	0.6054	0.5813
训练调整与辅助模块累加					
训练调整门控	**0.9697**	0.5825	**0.5934**	0.6214	**0.5579**
再加辅助监督	0.9762	0.5841	0.5958	0.6147	0.5603
再加共享/特有分解	0.9777	0.5815	0.5988	0.6133	0.5631
再加局部互补增强	0.9814	0.5840	0.6050	0.6211	0.5741
再加可信分类蒸馏	0.9814	0.5840	0.6050	0.6211	0.5741
再加能量协调	0.9814	0.5840	0.6050	0.6211	0.5741
任务融合扩展					
任务专属门控	0.9702	0.5846	0.5974	**0.6231**	0.5603
冻结专家后融合	0.9712	**0.5887**	0.5962	0.6223	0.5633
注意力结构对照					
池化对照	1.0278	0.5737	0.6326	0.6029	0.6093
自注意力	1.0181	0.5745	0.6302	0.6046	0.6030
跨模态注意力	1.0254	0.5737	0.6283	0.6016	0.6039
跨模态完整训练	1.0298	0.5699	0.6306	0.5989	0.6039

注：本表主模型对全模态不可观测输入采用训练集类别先验与强度均值回退，表 4.5 则保留网络直接输出。该边界处理差异使两表的综合验证指标分别为 0.9926 和 0.9919。

从训练调整与辅助模块比较看，训练调整门控的 $J = 0.9697$，完整输入 MAE 为 0.5579，缺失平均 MAE 为 0.5934，仅仅微弱优于主模型。继续加入辅助监督后，缺失平均 Macro-F1

由 0.5825 提高至 0.5841，但完整输入 Macro-F1 下降、MAE 增加，未形成综合改善，继续累加其他模块也没有进一步降低 J。可信分类蒸馏与能量协调的三个种子最终均保留第一阶段检查点，故与局部互补增强配置得到相同结果。这说明第二阶段训练未产生被验证准则保留的改善，不构成新增模块有效的证据，累加对照也不能解释为各模块相互独立的贡献估计。

从任务融合比较看，任务专属门控的完整输入 Macro-F1 达到 0.6231，冻结专家后融合的缺失平均 Macro-F1 达到 0.5887，分别改善了相应分类点估计。但相对于训练调整门控，二者的缺失平均 MAE 由 0.5934 分别升至 0.5974 和 0.5962，未同步改善回归。后融合相对训练调整门控的缺失平均 Macro-F1 差值约为 0.0062，源视频配对 Bootstrap 的 95% 区间为 $[-0.0121, 0.0239]$，缺乏稳定的分类优势。对共享分支与门控进行的抽样诊断还显示，分类与回归梯度大多同向，也未支持将普遍的梯度冲突视为已确认瓶颈。

从注意力结构比较看，自注意力相对池化对照的完整输入 Macro-F1 增加 0.0017、MAE 降低 0.0064，缺失平均指标也有小幅改善。继续加入跨模态注意力后，缺失平均 MAE 降低 0.0019，但 Macro-F1 下降 0.0008，未形成分类与回归的同步改善。跨模态方案相对完整输入训练对照的缺失平均 Macro-F1 增加 0.0038，仅构成本次实验中的小幅点估计收益。自注意力与跨模态注意力的 J 分别为 1.0181 和 1.0254，因此自注意力是该组内部较优的候选，但其缺失分类与回归表现仍均弱于主模型。

三类框架在部分单项指标上优于主模型，但分类与回归收益并不总是同步。表4.7进一步列出代表候选相对主模型的缺失性能变化，用于检查式(4.28)的两项必要条件。

表 4.7　代表候选相对主模型的缺失性能变化与替换条件检验

方案	Macro-F1 变化（百分点）	MAE 变化	两项要求
训练调整门控	$+0.14$	-0.0134	未达到
再加辅助监督	$+0.30$	-0.0109	未达到
任务专属门控	$+0.36$	-0.0093	未达到
冻结专家后融合	$+0.77$	-0.0105	未达到
自注意力	-0.65	$+0.0235$	未达到
跨模态注意力	-0.73	$+0.0216$	未达到

全部多模态替代配置中，冻结专家后融合的缺失平均 Macro-F1 最高，相对主模型提高约 0.0077，仍低于约定的 1 个百分点，其余配置的分类增幅更小或为负。自注意力与跨模态注意力还增加了缺失平均 MAE。因此，这些配置均未满足替换主模型的必要条件。该判断支持在既定比较准则下继续采用主模型，同时保留替代方案对部分指标的改善，不将当前采用决定表述为主模型在所有指标上最优。

为进一步解释平均指标背后的性能取舍，表4.8列出五种代表候选的强情感误差变化。按比较协议，强负向与强正向分别定义为 $y \le -1.5$ 和 $y \ge 1.5$，对应 58 条和 73 条验证样本。各候选与主模型均采用这一分组口径，表内差值可直接比较。

表 4.8　代表候选的强情感分组误差变化

方案	强负向 MAE 变化	强正向 MAE 变化
训练调整门控	-0.0481	$+0.0501$
任务专属门控	-0.0162	$+0.0877$
冻结专家后融合	$+0.0526$	$+0.1306$
自注意力	-0.0317	$+0.0503$
跨模态注意力	$+0.0513$	$+0.0338$

表 4.8显示，五种候选方案均未同时降低强负向与强正向样本的 MAE。其中，训练调整门控、任务专属门控和自注意力降低了强负向 MAE，但强正向 MAE 均有所增加，冻结专家后融合与跨模态注意力在两类强情感样本上的 MAE 均增加。总体来看，10 项分组误差变化中有 7 项增加、3 项降低，且所有候选方案的强正向 MAE 均高于主模型，增幅为 0.0338 至 0.1306。这表明，部分方案在总体平均误差上的改善伴随着强情感样本预测误差的上升。结合前述连续缺失性能比较，本文保留主模型作为后续实验与附件 3 预测的方案。主模型自身的类别边界与强度预测误差，将在第 4.5.4节结合逐样本结果进一步分析。

综合基础消融与三类框架对比，本文最终采用第4.3节构建的缺失感知门控融合模型：该结构在基础消融中取得最小验证指标 J，且替代框架均未体现出稳定优势。完成框架比较后，下一节固定主模型，分析不同缺失条件下的性能变化及错误分布，附件 3 预测采用相同模型权重与统一推理接口。

4.5 局部缺失下的鲁棒性分析

第4.3.5节与第4.4节分别完成消融实验和替代框架对比实验。本节在此基础上固定主模型，关注缺失条件本身如何影响预测：先给出完整输入性能与压力测试设置，再考察缺失模态及比例、位置及形状、跨模态起点关系，最后分析类别混淆与强度误差。各条件之间只改变输入观测状态，不重新训练或选择模型，从而将模型选型问题与缺失影响分析区分开来。

4.5.1 实验设置与完整输入基准

本节沿用第4.3.4节的评价指标与三种子集成方式，使用已保存的主模型预测分析不同缺失条件。训练参数与主模型结构均保持固定，实验只改变输入的遮挡方式。验证集完整输入结果用于说明模型的基础表现。缺失类型、比例、位置和形状的压力测试采用 727 条测试样本。测试结果不反馈到训练、阈值选择或预测修正。

表4.9给出完整输入下的基础性能，作为后续缺失实验的参照。验证集与测试集分别包含 728 条和 727 条样本，二者的指标应在各自划分内比较，不将跨划分差值解释为遮挡效果。

表 4.9　主模型在完整输入下的基础性能

数据划分	Acc	Macro-F1	MAE	Pearson 相关系数
验证集	0.6346	0.6055	0.5784	0.6827
测试集	0.6492	0.5989	0.6512	0.6546

压力测试设置七种缺失模态组合，分别为 T、A、V、TA、TV、AV 和 TAV。名义遮挡比例分为 10%、30%、50% 和 70% 四档，遮挡位置分为开头、中间、末尾和随机四种。七种模态组合与四档比例、四种位置组合，共形成 112 种主实验条件。随机位置各重复三次，其余位置执行一次，共得到 168 个遮挡实现。进一步增加 24 个多短段实现与 24 个模态独立起点实现，加上完整输入，合计 217 个输入实现。三个种子模型在同一输入实现中使用相同的遮挡掩码，先集成预测，再计算该实现的指标。除特别说明外，随机遮挡结果均为三次实现的指标均值。名义遮挡比例以有效词元槽位为分母，其取整规则与第4.2.3节一致。本节与第4.3.5节采用同一组基础测试遮挡，因此相同条件下的结果可以对应比较。

4.5.2 缺失模态类型与比例的影响

本节固定使用已选定的主模型，采用随机位置的单连续段遮挡，考察缺失模态与遮挡比例的影响。对于涉及多个模态的组合，各模态使用相同的遮挡区间，其余模态保持原始输入状态。缺失组合包括 T、A、V、TA、TV、AV 和 TAV，遮挡比例设置为 10%、30%、50% 和 70%，共形成 28 种条件。每种条件均执行三次随机遮挡，下表报告各次评价指标

的均值。

为分析局部缺失对预测性能的影响，本文以表4.9中的测试集完整输入结果为基准，比较不同缺失模态与遮挡比例下的 Macro-F1 和 MAE，分别考察情感极性分类与强度回归的性能变化，结果见表 4.10。

表 4.10　缺失模态与遮挡比例对预测性能的影响

缺失模态	Macro-F1↑				MAE↓			
	10%	30%	50%	70%	10%	30%	50%	70%
T	**0.6055**	0.5737	0.5325	0.5065	0.6634	0.7005	0.7294	0.7659
A	0.6005	0.6021	**0.6083**	0.6035	**0.6506**	**0.6497**	**0.6483**	**0.6480**
V	0.5993	0.6008	0.6037	0.6076	0.6518	0.6520	0.6517	0.6529
TA	0.5995	0.5669	0.5391	0.5029	0.6633	0.7001	0.7290	0.7677
TV	0.6038	0.5757	0.5351	0.5119	0.6639	0.7017	0.7305	0.7686
AV	0.6014	**0.6063**	0.6078	**0.6088**	0.6513	0.6506	0.6491	0.6499
TAV	0.5993	0.5678	0.5316	0.5051	0.6638	0.7014	0.7304	0.7707

表中粗体标示同一遮挡比例下各项指标的最优值。仅声学缺失时，四档比例下的 MAE 均为同列最低，30%、50% 和 70% 遮挡时，最高 Macro-F1 也均出现在保留文本的缺失组合中。为进一步解释这一分布，下面分别考察缺失模态、遮挡比例及二者的共同影响。

（1）固定比例下的缺失模态影响

固定遮挡比例为 50%，仅文本缺失时，Macro-F1 为 0.5325，MAE 为 0.7294；仅音频缺失时，两项指标为 0.6083 和 0.6483；仅视觉缺失时，为 0.6037 和 0.6517。相对于完整输入，仅文本缺失使 Macro-F1 下降 0.0665、MAE 增加 0.0783，而仅音频或视觉缺失未引起相同幅度的退化。这说明**在当前模型与特征配置下，预测结果对文本缺失更为敏感**。

同一比例下，TA、TV 和 TAV 三种组合的 Macro-F1 分别为 0.5391、0.5351 和 0.5316，均接近仅文本缺失的结果。AV 缺失时则为 0.6078，仍接近完整输入水平。因此，受遮挡模态的数量不能单独决定预测难度，更关键的是缺失组合是否包含文本。仅文本缺失时，音频和视觉仍然保留，但性能依然明显下降，表明这些**视听信息在当前模型中只能提供有限补偿**。

这一差异在其他比例下也有体现。例如，70% 遮挡时，包含文本缺失的四种组合，其 Macro-F1 介于 0.5029 与 0.5119 之间，MAE 介于 0.7659 与 0.7707 之间。不包含文本缺失的三种组合，其 Macro-F1 介于 0.6035 与 0.6088 之间，MAE 介于 0.6480 与 0.6529 之间。两组在高比例遮挡下的差距更加清晰。

（2）固定模态下的遮挡比例影响

前述比较明确了相同遮挡比例下不同缺失模态的影响，本节进一步固定缺失组合，考察遮挡范围扩大时的性能变化。

以 TAV 组合为例，遮挡比例从 10% 提高至 70% 时，Macro-F1 依次为 0.5993、0.5678、0.5316 和 0.5051，MAE 依次为 0.6638、0.7014、0.7304 和 0.7707。分类与回归在四档比例下均持续退化，两端相比，Macro-F1 下降 9.42 个百分点，MAE 增加 0.1069。这表明，在该组合下，缺失范围扩大带来的影响贯穿整个考察区间，性能下降在较低遮挡比例之间已开始出现。

T、TA 和 TV 组合也呈现相同的单调变化趋势。其中，仅文本缺失时，10% 至 70% 遮挡对应的 Macro-F1 降幅为 9.90 个百分点，MAE 增幅为 0.1025。因此，对这些组合而言，遮挡比例能够反映缺失程度加深所带来的性能损失。

对于 A、V 和 AV 组合，增加遮挡比例主要带来小幅波动。例如，仅音频缺失时，Macro-F1 在 0.6005 至 0.6083 之间变化，MAE 由 0.6506 小幅降至 0.6480；仅视觉缺失时，Macro-F1

有所提高，而 MAE 略有增加。这说明，**同一模态组合下，分类与回归对遮挡比例的响应也可能存在差异**。

图 4.7展示了上述变化过程。上排为包含文本缺失的组合，下排为仅涉及音视频缺失的组合，同一指标的上下两个子图采用相同纵轴范围。0% 对应完整输入，其余各点为三次遮挡的指标均值，误差棒表示三次实现的样本标准差。**总体来看，遮挡范围扩大时，各组合分别表现出持续退化或小幅波动**，因此应结合具体模态组合描述性能随缺失比例的变化，而非用统一的下降幅度概括所有缺失情形。

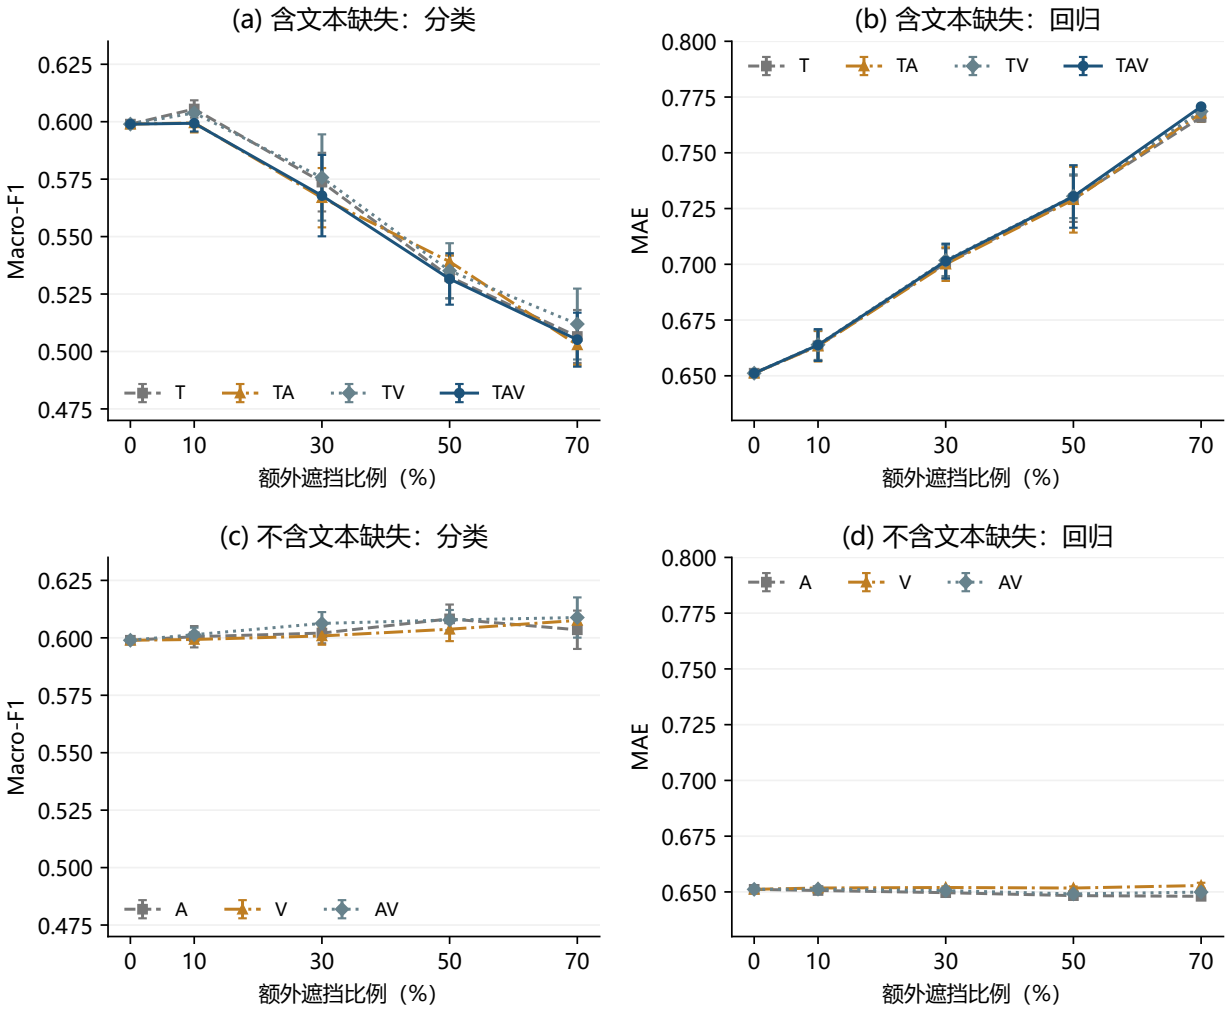


图 4.7　不同缺失模态下预测性能随遮挡比例的变化

（3）缺失模态与比例的共同影响

将比例由 10% 提高至 70% 时，T 组合的 Macro-F1 减少 0.0990、MAE 增加 0.1025，而 A 组合的 Macro-F1 增加 0.0030、MAE 降低 0.0026。相同的比例变化对应不同的性能变化，表明遮挡比例的影响取决于受遮挡模态，不能脱离模态组合单独讨论。

为概括这种条件差异，分别对包含文本缺失的四种组合和不包含文本缺失的三种组合进行等权描述性汇总。10% 遮挡时，两组平均 Macro-F1 分别为 0.6020 和 0.6004，差异较小；70% 时分别为 0.5066 和 0.6066，前者低约 0.1000。相应平均 MAE 在 10% 时为 0.6636 与 0.6512，在 70% 时为 0.7682 与 0.6503，两组差距由 0.0124 扩大至 0.1180。

另一方面，在文本已经受到遮挡时，再同步遮挡音频或视觉并不总是进一步降低分类指标。例如，50% 时 TA 的 Macro-F1 高于 T，而 70% 时 TV 高于 TAV。这说明**多个模态**

同时缺失的结果不能用单模态损失简单相加。总体上，主模型的较大幅度退化主要出现在文本缺失与较高遮挡比例共同存在的条件。在本文的局部音视频缺失范围内，性能相对稳定。

4.5.3 缺失位置与分布模式的影响

在缺失模态及总遮挡比例确定后，被删除信息在序列中的位置与分布形状仍可能改变预测结果。本节首先在 TAV 同步单连续段条件下比较相对位置，随后在随机位置条件下比较单长段与多短段，并考察跨模态同步起点和独立起点的差异。所有结果均来自同一主模型，以避免模型结构变化影响对缺失条件的判断。

(1) 单连续段的相对位置影响

为考察缺失位置的作用，本节在三模态同步遮挡条件下，比较相同遮挡比例下开头、中间、末尾及随机位置的预测表现。表 4.11列出四档比例与四种位置组合下的 16 组结果。遮挡位置按有效词元槽位的相对次序确定。开头、中间和末尾采用确定性遮挡，随机位置的结果取三次实现的均值。

表 4.11　不同遮挡位置与比例下的预测性能

遮挡位置	Macro-F1↑				MAE↓			
	10%	30%	50%	70%	10%	30%	50%	70%
开头	0.6010	**0.5849**	0.5343	0.5127	0.6642	**0.6870**	0.7302	0.7576
中间	0.5848	0.5582	**0.5425**	**0.5253**	0.6657	0.6895	**0.7168**	**0.7355**
末尾	**0.6011**	0.5743	0.5236	0.4890	0.6752	0.7091	0.7321	0.7802
随机	0.5993	0.5678	0.5316	0.5051	**0.6638**	0.7014	0.7304	0.7707

在较低遮挡比例下，各位置的表现随评价任务有所不同。10% 遮挡时，开头与末尾的 Macro-F1 接近，分别为 0.6010 和 0.6011，但末尾遮挡的 MAE 为 0.6752，在四种位置中最高。因此，同一位置对极性分类和强度回归的影响存在差异。30% 遮挡时，开头位置在两项指标上均表现最好，Macro-F1 为 0.5849，MAE 为 0.6870。

当遮挡比例提高至 50% 和 70% 时，中间遮挡在两项指标上均表现最好，末尾遮挡则均表现最差。以 70% 为例，中间遮挡的 Macro-F1 为 0.5253，比末尾遮挡高 3.63 个百分点，MAE 为 0.7355，比末尾遮挡低 0.0447。这说明，即使缺失模态和遮挡长度相同，剩余信息在序列中的位置分布仍会影响预测效果。

上述结果还呈现出明显的排序变化：中间遮挡在 10% 和 30% 时的 Macro-F1 最低，在 50% 和 70% 时转为最高。因此，缺失位置的影响与遮挡长度共同作用，各位置的相对优劣随遮挡范围变化。从序列结构看，中间遮挡保留首尾两部分信息，开头或末尾遮挡则仅保留另一侧的连续信息。本次较大比例遮挡下的结果表明，保留两端信息的配置更有利于当前模型完成预测。

图 4.8展示了各位置随遮挡比例增大的变化。所有位置均呈现 Macro-F1 下降、MAE 上升的趋势，说明扩大遮挡范围会持续损害预测性能，不同曲线之间的交叉则反映了位置排序的变化。图中随机位置的误差棒表示三次遮挡实现的样本标准差，用于描述随机起点变化带来的结果波动，开头、中间和末尾分别对应固定起点下的结果。

综合来看，局部缺失的影响既取决于遮挡范围，也取决于剩余信息的位置分布。尤其在较大比例遮挡下，中间与末尾遮挡之间的性能差距较为明显，表明仅报告随机位置的平均结果难以完整呈现模型对不同缺失位置的敏感程度，有必要结合确定性位置对照评价其鲁棒性。

(2) 固定随机位置条件下的形状影响

为分离总删除数量与缺失分布的影响，保持每个样本的删除词元槽位数一致，比较单

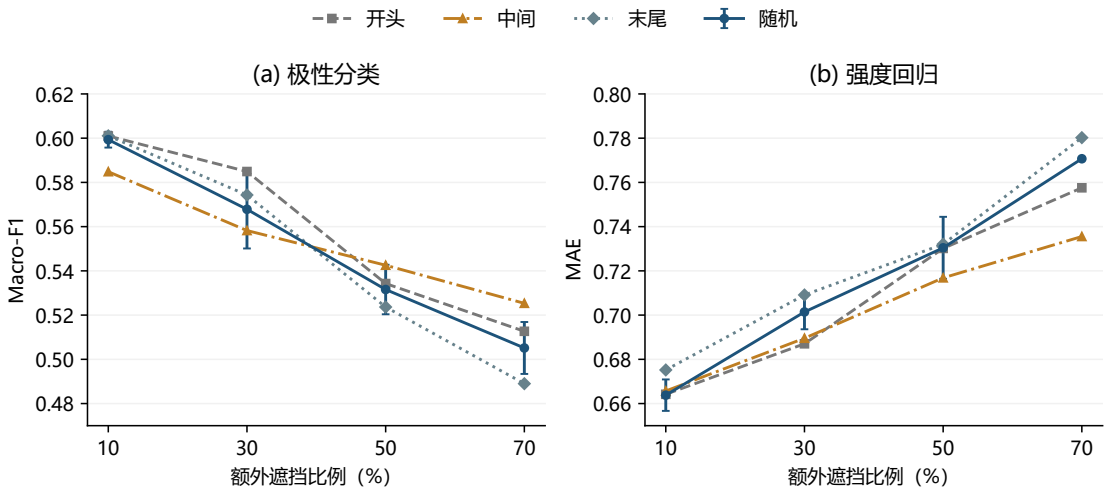


图 4.8　不同遮挡位置下预测性能随遮挡比例的变化

长段与多短段。多短段在三个互不相交的序列分区内各删除一段，有效长度不足 6 或删除数不足 3 时退化为单段，分区边界处相邻的删除段也可能连接。涉及多个模态时，各模态共享删除位置。表 4.12列出 T、A、V 和 TAV 四种组合在 30% 与 50% 遮挡下的全部比较，均取三次随机实现的均值。

表 4.12　单长段与多短段比较

缺失模态	比例	Macro-F1↑		MAE↓	
		单长段	多短段	单长段	多短段
T	30%	**0.5737**	0.5611	**0.7005**	0.7061
T	50%	0.5325	**0.5344**	**0.7294**	0.7310
A	30%	0.6021	**0.6031**	**0.6497**	0.6498
A	50%	**0.6083**	0.6059	0.6483	**0.6481**
V	30%	0.6008	**0.6049**	**0.6520**	0.6528
V	50%	**0.6037**	0.5999	**0.6517**	0.6532
TAV	30%	0.5678	**0.5687**	**0.7014**	0.7065
TAV	50%	0.5316	**0.5408**	0.7304	**0.7289**

对于 TAV 组合，30% 多短段遮挡的 Macro-F1 为 0.5687，与单长段的 0.5678 接近，但 MAE 由 0.7014 增至 0.7065；50% 时，多短段的 Macro-F1 为 0.5408，高于单长段的 0.5316，MAE 则由 0.7304 略降至 0.7289。因此，**多短段在较高比例下表现出一定优势，但同一结论并不同时适用于较低比例及两项指标**。

仅文本缺失时，30% 多短段的 Macro-F1 由单长段的 0.5737 降至 0.5611，MAE 由 0.7005 升至 0.7061；50% 时，Macro-F1 略有提高，MAE 仍略有增加。音频与视觉组合也未出现一致的优劣关系，例如 50% 视觉缺失时，多短段的 Macro-F1 低于单长段，MAE 高于单长段。这表明同等删除数量下，缺失分布确实会改变结果，但不能概括为多短段总是较易处理，或连续长段总是更困难。

进一步比较两项指标的变化方向，8 组条件中有 5 组呈现分类与回归的性能取舍；仅文本 30% 和视觉 50% 遮挡时，单长段在两项指标上均较优，而三模态 50% 遮挡时，多短段在两项指标上均较优。因此，**缺失形状的影响随模态组合、遮挡比例及预测任务而变化，相同的遮挡总量并不对应相同的预测难度**。

（3）跨模态位置关系与形状的综合比较

同步起点与独立起点均采用单连续段，区别在于不同模态的遮挡区间是否共享起点。独立起点由各模态分别抽取，允许区间重叠，不等同于强制互不重叠。表4.13给出四种多模态组合在 30% 与 50% 遮挡下的比较，从而在形状固定时考察跨模态位置关系。

表 4.13　同步与独立起点比较

缺失模态	比例	Macro-F1		MAE	
		同步起点	独立起点	同步起点	独立起点
TA	30%	0.5669	0.5712	0.7001	0.6881
TA	50%	0.5391	0.5332	0.7290	0.7204
TV	30%	0.5757	0.5826	0.7017	0.6888
TV	50%	0.5351	0.5422	0.7305	0.7207
AV	30%	0.6063	0.6105	0.6506	0.6494
AV	50%	0.6078	0.6131	0.6491	0.6495
TAV	30%	0.5678	0.5743	0.7014	0.6868
TAV	50%	0.5316	0.5237	0.7304	0.7244

30% 时，四种组合的独立起点 Macro-F1 均高于同步起点，MAE 均较低。以 TAV 为例，Macro-F1 由 0.5678 增至 0.5743，MAE 由 0.7014 降至 0.6868。50% 时，TV 和 AV 的 Macro-F1 有所提高，而 TA 和 TAV 反而降低。其中 TAV 的 Macro-F1 由 0.5316 降至 0.5237，但 MAE 仍由 0.7304 降至 0.7244。AV 在该比例下也出现分类指标提高而 MAE 略升的情况，说明**跨模态位置变化对两个任务的作用并不一致**。

图4.9将 TAV 下的单长段同步、多短段同步和单长段独立起点三种方式并列展示。各点为三次随机实现的均值，误差棒为样本标准差，连接线仅用于比较已测的 30% 与 50% 两个比例。30% 时，单长段独立起点在分类与回归上均较好；50% 时，Macro-F1 最高的是多短段同步，而 MAE 最低的是单长段独立起点。说明**缺失分布的优劣需要结合遮挡比例和预测任务判断**，不能仅凭跨模态错开或片段离散程度作统一排序。

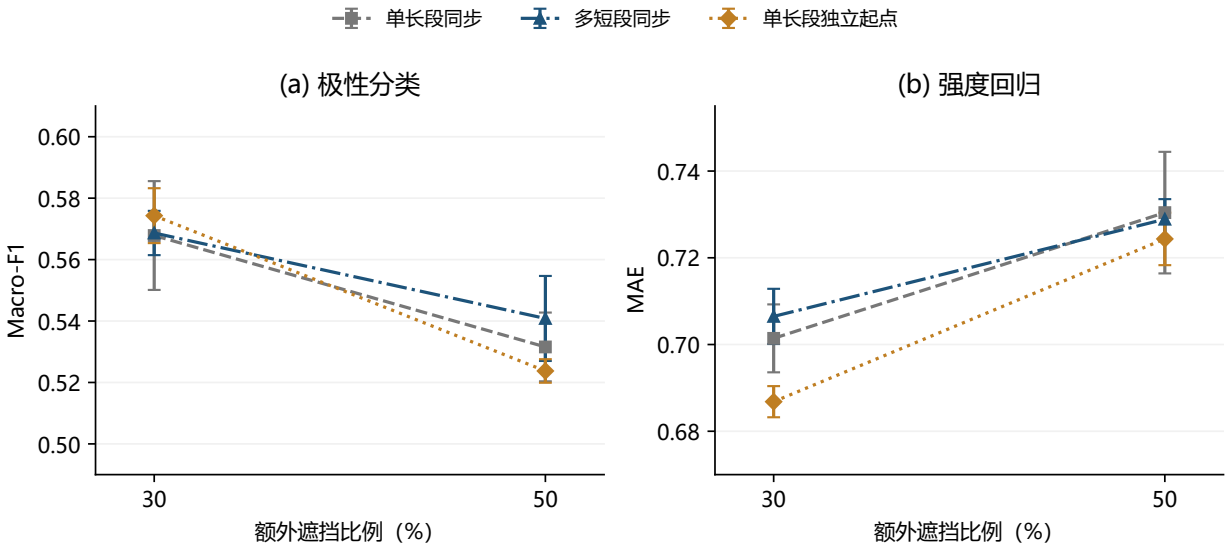


图 4.9　缺失分布方式的比较

4.5.4 类别混淆与强度偏差分析

前两小节考察缺失条件对总体指标的影响，本节进一步分析主模型的错误集中于哪些情感类别与强度区间。先分析验证集错误，再用测试集结果检查是否出现相似的误差模式，本节诊断不用于重新调整模型参数。图4.10给出主模型在 728 条验证样本完整输入下的混淆矩阵与强度预测散点图。左图为样本计数及真实类别内部的比例，右图虚线表示理想预测 $\hat{y} = y$。

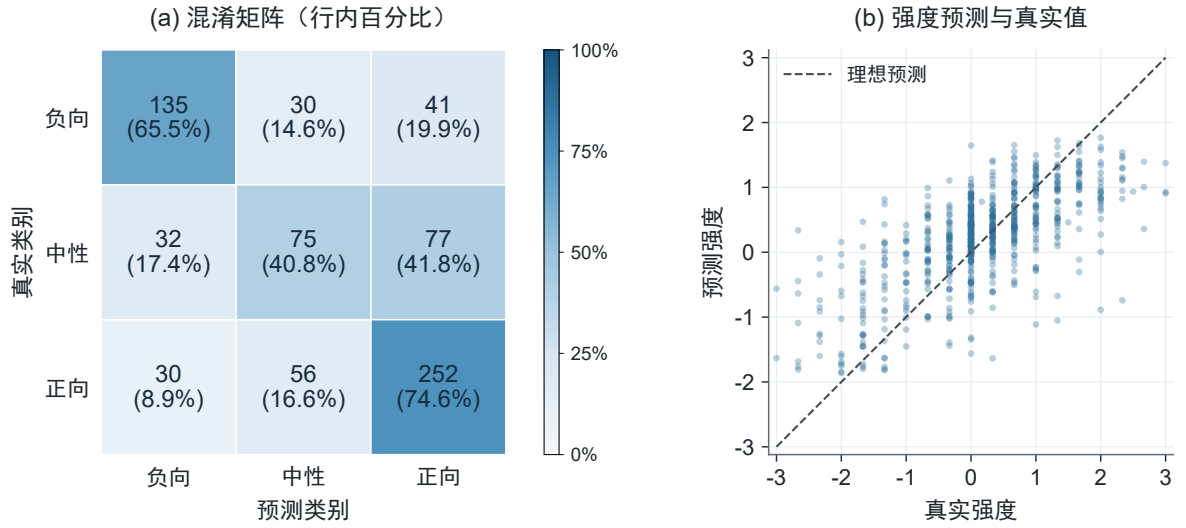


图 4.10　验证集预测误差

验证集中 206 条负向样本有 135 条被正确识别，338 条正向样本有 252 条被正确识别。184 条中性样本仅有 75 条被正确识别，召回率为 $75/184 \approx 0.4076$。另有 77 条中性样本被判为正向、32 条被判为负向，表明中性与带方向情感之间的边界是主要分类难点。强度预测还表现出向零收缩：按本节分组边界，58 条强负向样本的真实均值为 -2.0115，预测均值为 -0.9788；72 条强正向样本的真实均值为 1.9931，预测均值为 0.9739。两组 MAE 分别为 1.0426 和 1.0195，说明强情感方向能够被识别时，强度绝对值仍可能被低估。

进一步在测试集上分析类别混淆、强度分组误差，并结合典型验证样本解释可能的困难。图4.11给出主模型在完整输入测试集上的分类与回归结果。左图为 727 条样本的混淆矩阵，括号内为真实类别内部的比例；右图为真实强度与预测强度的对应关系，虚线表示理想预测 $\hat{y} = y$。

分类误差主要集中于中性类别及弱情感边界。测试集中 207 条负向样本有 141 条被正确识别，362 条正向样本有 275 条被正确识别。158 条中性样本仅有 56 条被正确识别，中性召回率为 0.3544。其中 70 条中性样本被判为正向，32 条被判为负向，说明中性样本更易被误判为正向。

为分析强度误差，将真实标签分为强负向、弱负向、中性、弱正向和强正向五组，具体边界及测试结果见表4.14。其中缺失条件采用第一次固定的 TAV 同步随机遮挡 50% 实现，以便对同一批样本进行逐项比较。

为保持与上述基础实验及误差图一致，本节沿用原分组，将 $y = 1.5$ 归入弱正向组。第4.4.4节的框架比较按其协议将该值归入强正向组。两处比较均在各自统一口径内进行，强正向样本数和分组均值不直接跨节合并。

完整输入下，强负向与强正向样本的分类准确率分别达到 0.8353 和 0.8734，但 MAE 也分别达到 1.1811 和 1.0668，高于弱情感及中性组。这说明模型往往能够判断强情感的方向，但对其强度绝对值存在低估。进一步检查组内均值，强负向样本的真实强度均值为

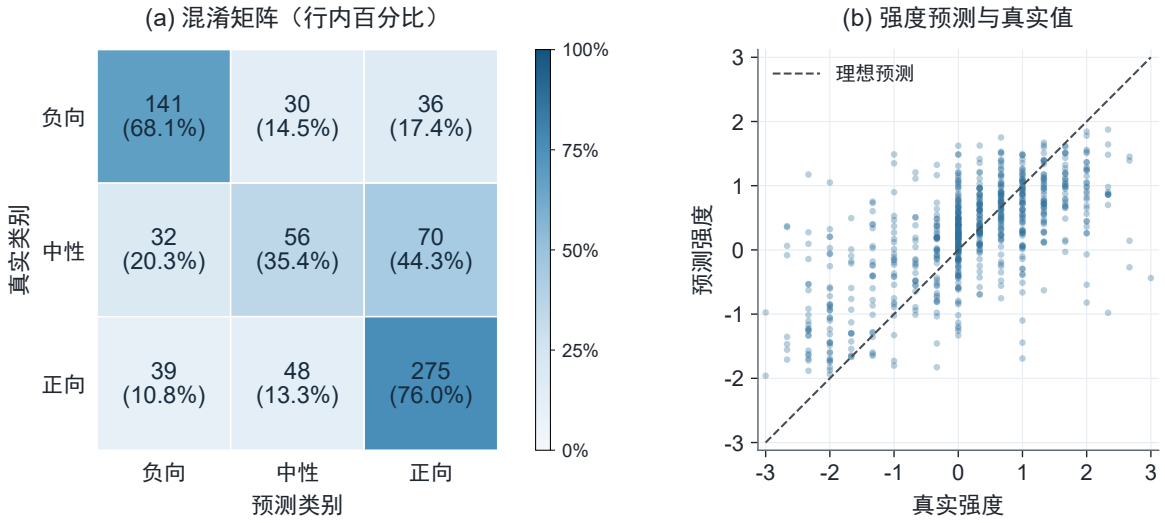


图 4.11　测试集预测误差

表 4.14　情感强度分组误差

分组	真实强度范围	n	完整输入		TAV 遮挡 50%	
			Acc	MAE	Acc	MAE
强负向	$[-3,-1.5]$	85	0.8353	1.1811	0.7176	1.5074
弱负向	$(-1.5,0)$	122	0.5738	0.7278	0.5000	0.7683
中性	$\{0\}$	158	0.3544	0.4511	0.3228	0.3717
弱正向	$(0,1.5]$	283	0.7279	0.4546	0.6466	0.4956
强正向	$(1.5,3]$	79	0.8734	1.0668	0.7468	1.2665

-2.1098，预测均值为 -0.9287。强正向样本的真实均值为 1.9578，预测均值为 0.8910，呈现明显的强度向零收缩现象。验证集上两个强情感组也具有相同的偏差方向，因此该现象并非仅见于个别测试样本。

遮挡后，强负向与强正向组的 MAE 进一步增至 1.5074 和 1.2665，对应预测均值分别向零收缩至 -0.6081 和 0.6913。相反，中性组的 MAE 由 0.4511 下降至 0.3717，但分类准确率也由 0.3544 下降至 0.3228。

双预测头之间也存在少量输出分歧。完整输入下，主模型给出 593 条非中性分类预测，其中 12 条的回归值符号与分类方向不一致。在上述固定遮挡实现中，该数目为 571 条非中性预测中的 20 条。这里的分母是被模型预测为非中性的样本数。该结果表明，共享表示能够联系两项任务，但未施加一致性约束的双头结构仍可能给出不同方向的判断。

典型验证样本提示，模型在评分表达、比较结构和情感强度估计方面仍存在预测偏差。样本 130456$_$3 的原文为 “(uhh) It’s, out of five stars, I would give it a five”。该样本的真实强度为 2.3333，模型却预测为负向，强度为 -0.7410。这一错误提示模型对评分式表达可能存在识别不足，具体成因仍需进一步验证。

样本 f_ZJ7L14oYQ$_$21 的原文为 “They just so much more convenient than stupid boots that take forever to put on and just aren’t comfortable!”。该表达通过比较突出评价对象的便利性，其真实强度为 2.0000，模型却预测为负向，强度为 -0.8871。负面措辞主要指向被比较的靴子，这一错误提示模型可能未充分区分比较对象及其评价指向。

样本 237009$_$11 的原文为 “(umm), it should be rated junk”。模型虽正确判为负向，却将真实强度 -3.0000 预测为 -0.5606，反映出极性判断正确而情感强度估计不足的情况。上述案例提供了对预测偏差的语义解释线索，但不足以单独确定模型出错的内部原因。

进一步按文本是否包含转折词进行启发式分组，测试集中包含 but、however、although、though 或 yet 的 94 条样本，在完整输入下的准确率为 0.6489，与其余 633 条样本的 0.6493 接近，但 MAE 为 0.7505，高于其余样本的 0.6364。在上述固定遮挡实现下，两组 MAE 分别为 0.8087 和 0.7028。这一结果提示复杂语义表达的强度估计值得进一步研究。

上述误差分析表明，主模型在连续缺失下的主要局限包括中性与弱情感边界、强情感幅度低估以及双任务输出分歧。结合第4.4.4节的框架对比可见，改变监督、融合或交互方式虽能改善部分平均指标，仍未稳定解决这些问题。因此，本文在既定选型结果下保留主模型，并将这些局限用于解释其预测结果。下一节据此汇总附件 3 的专项输出，不再依据专项样本调整模型。

4.6 附件 3 预测结果与置信度分析

在完成模型选择与缺失影响分析后，采用缺失感知门控融合模型对附件 3 进行最终预测。本节先说明输入情况与集成方式，再汇总全部样本的极性与强度，最后结合类别概率和种子间分歧，分析低置信度及预测分歧较大的样本。附件 3 没有真实标签，因此本节主要分析预测分布、输出置信度与模型间的一致性，不计算准确率、Macro-F1、MAE 或相关系数。

4.6.1 观测状态分析与集成预测

附件 3 共包含 30 条专项样本，本文沿用训练阶段的对齐输入版本、冻结文本编码器和标准化参数。依据第4.2节的规则识别有效位置及各模态的可观测位置，推理时保留样本已有的缺失形态，不再施加人工遮挡，也不利用其他特征版本补回不可观测信息。模型参数在推理前完成锁定，附件 3 不参与模型选择、阈值调整或标准化统计量估计。

最终采用随机种子 17、29 和 43 对应的三个主模型进行集成。对各模型的三分类概率取算术平均，以平均概率最大的类别确定情感极性，对三个强度预测取算术平均，得到最终情感强度。分类与回归分别保留原始输出，不根据回归值的符号重新划分类别，也不将中性样本的回归值强制置零。

输入核验表明，30 条样本均可由序列分隔标记确定有效范围，有效长度为 6 至 48 个词元槽位。按既定观测规则，01 号、05 号和 10 号样本的三模态在有效范围内均被判定为可用，其余 27 条样本存在不可观测位置。各样本的每种模态均保留部分可用信息，未触发全模态无观测时的训练先验回退。

表4.15汇总各模态的观测可用比例。其中，平均值先按样本计算可观测词元槽位数与有效词元槽位数之比，再对 30 条样本等权平均。该比例描述模型能够使用的剩余信息，零值或未知词元的来源无法仅凭剩余特征完全确定。

表 4.15　附件 3 观测可用情况

模态	平均可用比例	最低可用比例	最高可用比例
文本	79.33%	50.00%	100.00%
语音	79.33%	50.00%	100.00%
视觉	78.91%	50.00%	100.00%

4.6.2 情感极性与强度预测结果

表4.16列出全部 30 条样本的预测结果。表中以原文件名末尾的两位数字表示样本编号，强度保留四位小数。随附预测 CSV 保留完整样本编号与未作展示性舍入的强度数值。结果文件包括样本编号、情感极性和情感强度三列，分别对应字段 sample_id、polarity 和 intensity，其中极性以 negative、neutral 和 positive 表示。

从预测分布看，负向与中性各有 6 条，分别占 20%；正向共有 18 条，占 60%。全部强

表 4.16　附件 3 全量预测结果

编号	01	02	03	04	05	06	07	08	09	10
正向				✓		✓			✓	
中性		✓	✓							✓
负向	✓				✓		✓	✓		
强度	−1.0105	0.0739	0.2643	0.2518	−1.5768	0.9880	−0.0496	−0.5816	1.2581	0.1758
编号	11	12	13	14	15	16	17	18	19	20
正向		✓	✓		✓	✓		✓		
中性	✓						✓			✓
负向				✓					✓	
强度	0.4094	0.3458	0.4626	−0.2710	0.7719	1.3780	−0.0164	0.6303	−0.1231	0.0727
编号	21	22	23	24	25	26	27	28	29	30
正向	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓
中性										
负向										
强度	0.7213	0.3173	0.6030	0.5777	0.4601	0.8270	0.9705	0.6509	0.7529	0.5639

度预测均位于规定范围内，最小值为 05 号样本的 −1.5768，最大值为 16 号样本的 1.3780，总体均值为 0.3299。24 条非中性预测的类别方向均与回归值符号一致。6 条中性预测的强度则介于 −0.0164 与 0.4094 之间。

4.6.3 预测置信度与稳定性分析

为分析预测结果的置信程度与稳定性，本文考察三个量：以最大类别概率作为分类置信度指标，以最高与次高概率之差衡量模型对两个最可能类别的区分程度，以三个训练种子强度输出的样本标准差衡量不同训练实例之间的预测分歧。最大类别概率较低或概率差较小时，说明分类判断较为犹豫。种子标准差较大时，说明强度预测对训练随机性较为敏感。

本文将最大类别概率低于 0.5 的结果记为低置信度分类结果。本批样本中，07 号、11 号、12 号、17 号和 22 号满足这一条件。表4.17列出上述 5 条样本，并补充强度种子标准差最大的 08 号、24 号和 29 号样本，分别展示分类置信度较低和强度预测分歧较大的情况。

表 4.17　低分类置信度与较大强度预测分歧的样本

编号	极性	强度	最大类别概率	概率差	种子标准差
07	负向	−0.0496	0.4055	0.0199	0.0474
08	负向	−0.5816	0.5087	0.2215	0.9263
11	中性	0.4094	0.4657	0.0274	0.0765
12	正向	0.3458	0.4445	0.0314	0.3372
17	中性	−0.0164	0.3939	0.0619	0.3351
22	正向	0.3173	0.4382	0.0716	0.1840
24	正向	0.5777	0.6108	0.4053	0.4834
29	正向	0.7529	0.6826	0.5099	0.4441

以 07 号样本为例，其负向与中性概率分别为 0.4055 和 0.3856，二者仅相差 0.0199，且回归值接近零，说明模型对两种极性的区分较弱，分类置信度较低。11 号样本的中性与正

向概率分别为 0.4657 和 0.4383，同样表现出较小的类别概率差。其分类头选择中性，而回归头输出正值 0.4094，反映两项任务在情感边界附近的判断差异。

08 号样本的强度种子标准差为 0.9263，为本批最大值；24 号和 29 号分别为 0.4834 和 0.4441。这些样本在不同训练实例下的强度预测差异较大，其集成均值不能单独反映这种分歧。因此，结合类别概率与种子标准差，能够同时呈现分类判断的置信程度和强度预测的稳定性。

4.7 本问小结

针对局部连续模态缺失下的情感预测，本文首先完成数据分布与观测情况分析，统一输入接口、训练集标准化及有效位置与观测掩码，并通过连续区间遮挡构造增强样本。在此基础上，建立由时序编码、掩码池化、缺失状态表征和质量感知门控组成的主模型，以分类与回归双头联合预测情感极性和强度。

递进消融表明，连续遮挡增强带来本组比较中主要的缺失性能改善，缺失感知处理与门控在此基础上进一步调整分类和回归表现，完整结构取得综合验证指标 J。随后，训练调整与辅助学习、任务专属融合、注意力交互三类框架的比较表明，候选的复杂框架无明显性能优势，均未达到既定的缺失分类增益与回归不退化条件，因此最终采用缺失感知门控模型。

固定主模型后的鲁棒性实验显示，性能变化取决于缺失模态、比例、位置及跨模态起点关系，不能仅用缺失数量概括。文本相关缺失与较高遮挡比例同时出现时退化更明显，不同位置和形状的优劣随比例及预测任务而变化。误差分析还表明，中性与弱情感边界、强情感幅度低估及双头输出分歧仍构成当前方法的局限。

最后，采用三个训练种子的集成模型及统一推理接口，完成附件 3 全部 30 条样本的极性与强度预测，并保留类别概率、预测置信度与不同随机种子训练所得模型的预测差异。

5 问题三　可解释性多模态情感预测

5.1 问题分析与总体思路

问题三要求利用文本、语音和视觉信息预测情感极性与强度，并进一步说明各模态对预测结果的作用及关键证据所在的位置。相较于问题二，本问的研究重点由缺失条件下的预测转向完整输入下的预测解释。机器学习可解释性研究旨在帮助使用者理解模型的预测依据及内部工作机制 [16]。因此，本问在评价预测性能的同时，进一步分析各模态及局部输入对预测结果的作用。为此，本节继承问题二的特征处理方式与质量感知融合网络，在获得情感预测结果后，分析输入信息改变时模型输出的变化。解释结果既需要给出三种模态的贡献及主要参考模态，也需要将重要片段对应到原始文本、语音区间和视频帧，从而使数值结果能够结合具体素材进行理解。

实现上述目标需要解决三个问题。其一，多模态网络的非线性融合使各模态的作用相互关联，同一模态对预测结果的影响取决于其他模态是否参与。因此，模态贡献的量化需要综合考虑不同模态组合下的输出变化。其二，文本特征包含上下文信息，表示层中归因较高的位置未必对应原始文本中对预测影响最大的片段，需要通过删除候选片段、重新编码并预测，检验其实际作用。其三，对齐特征中的序列位置与原始音视频的时间位置并不直接对应，需要借助文本与语音对齐，将重要片段映射至相应的语音区间和视频帧，并检验时间定位的可靠性。

本节按照预测建模、贡献量化与证据定位三个环节开展研究。首先，通过模态组合增强训练，使预测模型接触完整输入及部分模态缺失的情形，为后续模态移除分析提供基础。随后，固定模型参数，利用 Shapley 值分配三模态贡献，以积分梯度筛选局部候选，并通过删除和保留实验评价证据与预测的关联。最后，依据分词位置、原文字符和语音对齐结果完成素材映射。在验证集上分别检验预测性能、解释忠实性与稳定性，基于所设计的方案对附件 4 数据进行分析，给出全量预测、关键证据及时间定位状态。

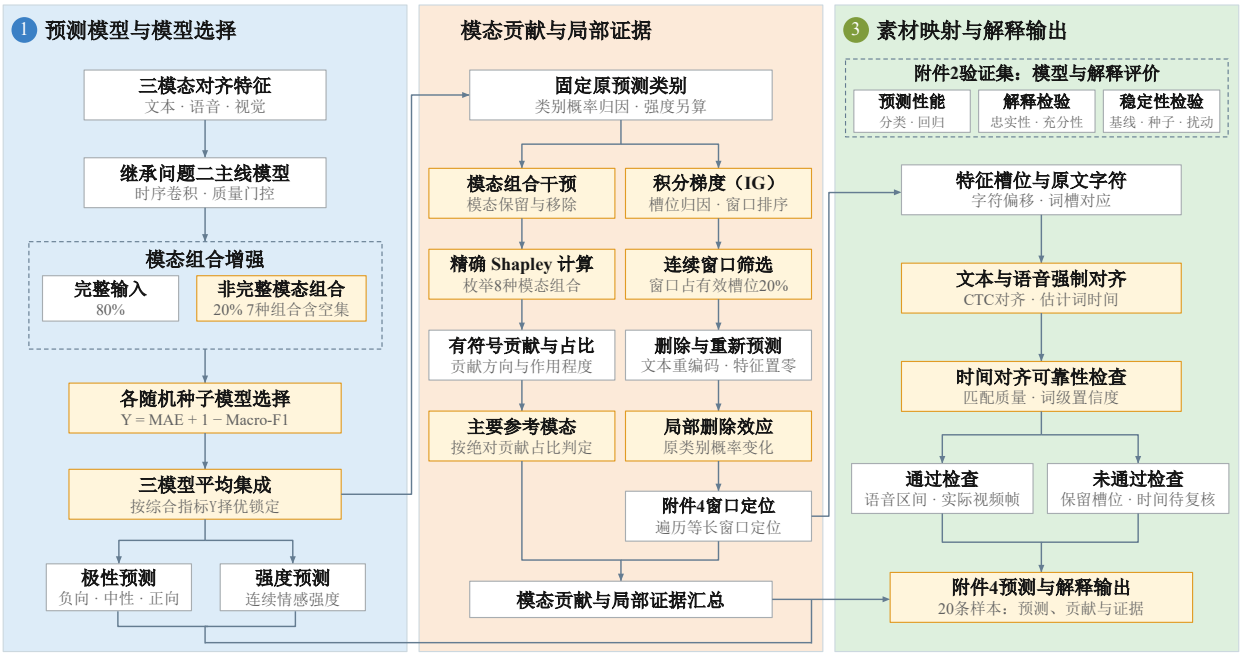


图 5.1　可解释性多模态情感预测总体思路图

5.2 模型建立与求解

5.2.1 情感预测模型与训练策略

本节沿用问题二建立的质量感知多模态情感预测模型，并在此基础上引入模态组合增强训练。模型由三路时序编码网络、质量感知门控融合模块以及分类与回归双输出分支组成。三路编码网络分别提取文本、语音和视觉序列中的情感特征，门控模块结合模态表示与观测状态分配融合权重，两个输出分支则根据共享情感表示分别预测情感类别和强度。该模型能够处理不同模态组合，为后续通过输入干预分析模态作用提供统一的预测基础。

模型采用附件 2 中的对齐序列作为输入，训练集和验证集分别包含 3395 条和 728 条样本，序列长度上限为 50。文本经参数冻结的 DistilBERT 编码为 768 维表示，读取附件中的 text_bert 词元编号与注意力掩码，不直接使用附件预计算的 text 表示。语音和视觉特征的维度分别为 74 和 35。将对齐序列中的一个位置称为特征槽位，并设置有效位置掩码 P 与观测掩码 O：前者标识有效文本位置，后者记录各模态在相应位置是否具有可用特征。人工移除输入时，有效位置掩码 P 保持不变，观测掩码 O 随可用信息更新。特征标准化所需的均值和标准差仅由训练集中的可观测位置计算, 缺失位置置零，同时保留掩码信息，以区分缺失状态与正常观测值。

在特征提取阶段，各模态分支先将输入映射至 64 维隐藏空间，再通过两层残差时序卷积提取序列中的局部关联。两层卷积的卷积核大小均为 3，膨胀率分别为 1 和 2，以覆盖不同范围的相邻位置。随后，各分支在可观测位置上分别进行注意力池化与均值池化，将两种池化结果拼接并映射为模态级表示。注意力池化用于突出与预测相关的位置，均值池化用于保留序列的整体信息，完全缺失的模态不参与后续融合。

为使融合过程反映各模态的可用程度，质量感知门控引入观测比例、最长连续缺失长度占比和归一化有效序列长度等质量指标。模型将质量信息映射后加入模态表示，并结合质量指标计算各模态的门控得分。得分在可用模态之间归一化后形成融合权重。各模态表示经加权求和及共享非线性映射，得到样本 i 的情感表示 h_i。门控权重描述网络内部的信息融合比例，其大小并不直接等同于模态对最终预测的贡献，后续仍需通过不同模态组合下的输出变化量化模态作用。

分类分支与回归分支以 h_i 为共同输入，分别输出情感类别概率和连续情感强度：

$$p_i = \mathrm{softmax}(W_c h_i + b_c), \qquad \widehat{y}_i = 3\tanh(w_r^{\top} h_i + b_r). \tag{5.1}$$

式 (5.1) 中，p_i 为负向、中性和正向三类情感的概率向量，$\widehat{y}_i$ 为情感强度预测值，W_c、w_r 及相应偏置为待学习参数。分类结果取概率最大的类别，回归结果通过双曲正切函数限制在 $[-3, 3]$ 范围内。训练时，真实强度为零的样本标记为中性，其余样本按强度的正负号划分类别。两个分支分别学习离散类别与连续强度，因此预测为中性的样本仍可能具有非零的强度预测值。

为兼顾类别识别与强度估计，并减轻类别数量不均衡的影响，模型采用类别加权交叉熵与 Smooth L1 损失之和作为训练目标：

$$\begin{aligned} \mathcal{L} &= -\frac{\sum_{i\in B} w_{c_i} \log p_{i,c_i}}{\sum_{i\in B} w_{c_i}} + \frac{1}{|B|}\sum_{i\in B} \ell(\widehat{y}_i - y_i), \\ w_c &\propto \sqrt{\frac{N}{3n_c}}. \end{aligned} \tag{5.2}$$

式 (5.2) 中，B 为一个训练批次，c_i 和 y_i 分别为样本 i 的真实情感类别与强度，p_{i,c_i} 为真实类别对应的预测概率，N 为训练样本总数，n_c 为第 c 类样本数。类别权重归一化至均值为 1，ℓ 取转折参数为 1 的 Smooth L1 函数。损失函数的前一项约束分类误差，后一项约束强度偏差，两项系数均为 1。

后续模态贡献分析需要主动移除部分模态，并比较模型输出的变化。为使模型在训练阶段接触此类输入，本节以问题二主线门控模型的权重为初始参数，采用模态组合增强继续训练。每条样本以 80% 的概率保留全部模态，以 20% 的概率从 7 个非完整模态集合中等概率选择一个，包括 3 种单模态组合、3 种双模态组合和空集合。对于被移除的模态，将其特征置零、观测掩码设为不可用，并重新计算质量指标，同时保留有效位置掩码。空集合输入对应零融合表示，再由共享映射和输出分支产生预测。该策略旨在减小常规训练输入与模态干预输入之间的差异，其实际作用由验证结果评价。

训练采用 AdamW 优化器，并通过余弦退火调整学习率，最低学习率设为 3×10^{-5}。训练过程中保持 DistilBERT 参数冻结，更新其余预测网络参数，同时采用梯度裁剪和早停控制训练过程。模型训练及后续解释计算的主要参数统一列于表 5.1，其中解释参数的具体用途将在相应小节说明。

模型选择同时考虑分类与回归表现。各候选模型均在不施加人工模态移除的完整验证输入上进行评价，并采用综合指标

$$Y = \mathrm{MAE}_{\mathrm{valid}} + 1 - \mathrm{MacroF1}_{\mathrm{valid}} \tag{5.3}$$

选择模型。式 (5.3) 中，$\mathrm{MAE}_{\mathrm{valid}}$ 衡量强度预测误差，$\mathrm{MacroF1}_{\mathrm{valid}}$ 衡量各情感类别的综合识别表现，Y 越小表示两项指标的综合结果越好。

训练分别采用 17、29 和 43 三个随机种子，并将增强训练前的参数作为第 0 轮候选保留，使模型选择同时涵盖增强训练前后的验证表现。后续训练根据 Y 更新最优参数，连续 5 轮未改善时提前停止。三个随机种子对应模型的最佳轮次分别为第 1、2 和 0 轮，其中第 0 轮表示保留问题二的原有权重，说明增强训练并非对所有随机种子均带来更优的验证结果。

对于每种候选方案，分别对三个随机种子对应模型的类别概率和强度预测取算术平均，再由平均概率确定最终类别。在相同验证条件下，将模态组合增强集成方案与问题二保留的候选集成方案比较，最终依据 Y 选用模态组合增强集成模型。模型确定后固定参数，用于后续模态贡献计算、局部证据分析及附件 4 分析预测。

表 5.1　模型训练与解释计算参数

环节	设置
参数优化	AdamW；初始学习率 0.0003；权重衰减 0.001；批量大小 64
网络与训练停止	隐藏维度 64；Dropout 比例 0.2；最多训练 20 轮；连续 5 轮未改善时早停；梯度范数裁剪阈值 5
集成与数据增强	随机种子 17、29、43；完整输入概率 80%；非完整模态组合概率 20%
模态贡献计算	精确枚举 8 种模态组合；固定原预测类别；情感强度单独归因
局部证据筛选	窗口长度约占有效槽位数的 20%；每个候选窗口设置 5 个等长随机窗口作为对照
数值与扰动设置	积分节点数依次为 32、64、128、256；积分完备性残差容差 0.001；特征扰动噪声标准差 0.02

5.2.2 基于 Shapley 的模态贡献分析

本节需要回答两个问题：文本、语音和视觉分别在多大程度上影响模型预测，以及哪一种模态是该预测的主要依据。由于不同模态之间存在交互，同一模态在单独输入和与其他模态共同输入时，可能产生不同的作用。因此，本节采用 Shapley 值 [17]，比较某一模态加入不同模态组合前后的预测变化，再对这些变化加权平均，得到该模态的贡献。

计算贡献前，需要先确定比较哪一个输出。对于情感分类，始终考察完整输入所预测类别的概率，避免因输入变化后预测类别发生改变而失去比较依据。对于情感强度，则直

接考察回归预测值。令 $\mathcal{M}=\{T,A,V\}$ 为模态集合，其中 T、A 和 V 分别表示文本、语音和视觉，X_i 为样本 i 的完整输入，X_i' 为移除或替换部分信息后的输入。分类与强度的解释目标分别定义为

$$\begin{aligned} c_i^* &= \arg\max_k \bar{p}_k(X_i), \\ F_c(X_i') &= \bar{p}_{c_i^*}(X_i'), \\ F_y(X_i') &= \overline{\widehat{y}}(X_i'). \end{aligned} \tag{5.4}$$

式 (5.4) 中，横线表示三个模型输出的平均值，c_i^* 为完整输入下的预测类别，F_c 为该类别的预测概率，F_y 为情感强度预测值。例如，若完整输入被预测为负向，则移除任何模态后，仍比较负向类别的概率，而不改为比较新的最高类别概率。分类贡献与强度贡献分别计算，二者对应不同的解释目标。

随后，构造不同的模态组合。对于任意保留模态集合 $S\subseteq\mathcal{M}$，保留集合内的原始特征，将集合外的模态特征置零、观测掩码设为不可用，并更新质量统计量，得到输入 $X_{i,S}$。这一处理表示相应模态不再向模型提供观测信息。记 $v_i(S)=F(X_{i,S})$，其中 F 可分别取 F_c 和 F_y，则模态 m 的 Shapley 贡献为

$$\phi_{im}=\sum_{S\subseteq\mathcal{M}\setminus\{m\}}\frac{|S|!(2-|S|)!}{3!}\left[v_i(S\cup\{m\})-v_i(S)\right]. \tag{5.5}$$

式 (5.5) 中，方括号内表示在已有模态组合 S 的基础上，加入模态 m 所引起的输出变化，即该模态在这一组合下的边际贡献。前面的系数用于对不同组合进行加权。三个模态共有 8 种组合，包含空集合、3 种单模态组合、3 种双模态组合和完整组合，因此可以逐一计算模型输出，精确求得上述贡献。

以文本模态为例，需要比较加入文本前后的四组变化：空集合与仅文本、仅语音与文本–语音、仅视觉与文本–视觉，以及语音–视觉与完整输入，对应权重依次为 $1/3$、$1/6$、$1/6$ 和 $1/3$。这样，文本贡献既考虑了文本单独提供的信息，也考虑了其他模态存在时文本带来的补充作用。

Shapley 值同时保留贡献的方向和大小。为进一步比较三种模态的相对作用，定义绝对贡献占比：

$$\begin{aligned} \sum_{m\in\mathcal{M}}\phi_{im} &= F(X_i)-F(X_{i,\varnothing}), \\ a_{im} &= \frac{|\phi_{im}|}{\max\left(10^{-12},\sum_{j\in\mathcal{M}}|\phi_{ij}|\right)}. \end{aligned} \tag{5.6}$$

第一式说明，三种模态的贡献之和等于完整输入相对于空模态输入的输出变化，空模态输入对应的模型输出构成比较基准。第二式用某一模态贡献的绝对值除以总绝对贡献，衡量其相对影响大小，分母中的微小常数用于避免零除。

对于分类目标，正贡献表示该模态提高了原预测类别的概率，负贡献表示该模态降低了这一概率。因此，负贡献不等于作用较小，而是作用方向与原预测相反；绝对贡献占比则不区分方向，仅比较影响大小。对于强度目标，正贡献表示使预测强度向正方向变化，负贡献表示使其向负方向变化。

本节依据分类贡献确定主要参考模态。若三种模态的总绝对贡献小于 0.001，则记为弱作用，表示相对于空模态基准的整体影响较小；其余样本中，若最大绝对贡献占比小于 0.45，则记为混合作用，表示没有单一模态占据较高比例；否则，将绝对贡献最大的模态记为主要参考模态。因此，主要参考模态表示对预测影响最大的模态，其作用可能是支持，也可能是抑制，需结合贡献符号判断。

上述结果以模态缺失作为比较基准。为考察结论是否依赖这一设置，另在标准化并截断后的模型输入空间中，利用训练集可观测位置计算各维特征的中位数，以其替换相应模

态的可观测特征，同时保留原观测掩码与质量统计量。前一种处理回答“缺少该模态时预测如何变化”，后一种处理回答“该模态取训练集参考值时预测如何变化”。比较两种设置下的贡献分配，可以评估解释结果对参考基线的敏感程度 [18]。

5.2.3 基于积分梯度的局部证据定位与原始素材映射

上一节利用 Shapley 贡献确定各模态对预测的整体作用，但尚不能说明同一模态内部哪些词语或局部特征位置构成了判断依据。为进一步定位这些信息，本节采用积分梯度建立位置层面的归因，将模态整体作用分析扩展至局部证据分析。其核心任务是为输入特征赋予与原预测类别相关的有符号归因分数，再将逐维分数汇总为槽位分数，据此筛选连续证据窗口。

积分梯度（Integrated Gradients，IG）用于刻画各维特征相对于参考表示对指定输出的贡献 [19]。其基本做法是从参考表示出发，逐步过渡到实际输入，并累积模型输出在这一过程中的变化敏感程度。设 x 为标准化后的输入表示，x' 为零参考表示，仍以完整输入所预测类别的概率 F_c 为解释目标，则第 j 维特征的归因为

$$\mathrm{IG}_j(x) = (x_j - x'_j) \int_0^1 \frac{\partial F_c\big(x' + \alpha(x - x')\big)}{\partial x_j}\, \mathrm{d}\alpha. \tag{5.7}$$

式 (5.7) 中，α 控制从参考表示到实际输入的过渡位置。IG 值为正，表示该维特征相对于参考表示支持原预测类别；IG 值为负，则表示其作用方向相反。

积分过程中，仅改变连续特征表示，保持有效位置掩码、观测掩码和质量统计量不变。因此，这里的零参考表示是“观测状态不变、特征取零值”，与上一节中将观测掩码关闭的模态移除操作不同。数值计算采用 Gauss–Legendre 求积，从 32 个积分节点开始。若各维归因之和与实际输入、参考输入之间的输出差仍相差超过 0.001，则依次增加至 64、128 和 256 个节点。

为将逐维归因整理为连续片段，对每个模态，将同一特征槽位内各维 IG 值相加，得到槽位分数 g_{imt}，其中 i、m 和 t 分别表示样本、模态和槽位。随后，设置长度约为有效槽位数 20% 的窗口，依次比较各个等长连续窗口的分数之和，并选择得分最高的窗口作为候选：

$$\begin{aligned} k_i &= \min\left(L_i, \max\left(1, \lfloor 0.2 L_i + 0.5 \rfloor\right)\right), \\ I^*_{im} &= \arg\max_{I \in \mathcal{W}_i(k_i)} \sum_{t \in I} g_{imt}. \end{aligned} \tag{5.8}$$

式 (5.8) 中，L_i 为有效槽位数，k_i 为四舍五入并限制在有效范围内的窗口长度，$\mathcal{W}_i(k_i)$ 为所有长度为 k_i 的连续窗口。筛选时保留 IG 分数的正负号，使候选窗口优先覆盖对原预测具有支持作用的位置。IG 窗口与随机对照采用相同的槽位长度，以控制删除长度对比较结果的影响，不同窗口所包含的语义信息与有效观测量仍可能不同。

IG 筛选得到的是特征表示中的高分区域，其作用还需要通过实际输入干预检验，尤其是文本表示包含上下文信息，某一槽位得分较高并不意味着对应词语被删除后一定产生同等影响。因此，本节删除候选窗口并重新预测：对于文本，修改窗口内的分词标记与注意力掩码，再重新编码文本；对于语音和视觉，将窗口内的特征行置零，并更新观测信息。窗口删除效应定义为

$$\Delta_{imI} = F_c(X_i) - F_c\left(X_i^{(-m,I)}\right). \tag{5.9}$$

式 (5.9) 中，$X_i^{(-m,I)}$ 表示删除样本 i 的模态 m 中窗口 I 后的输入。若 $\Delta_{imI} > 0$，说明删除该片段后原预测类别的概率降低，该片段在此次干预下表现为支持作用，数值越大，删除造成的概率下降越明显。若 $\Delta_{imI} < 0$，则说明删除后原类别概率反而上升。语音和视觉的删除操作在特征层进行，因此这一结果反映的是特征片段对模型输出的影响。

验证集与附件 4 采用不同的窗口选择方式，以分别满足方法检验和样本展示的需要。在验证集上，先依据 IG 确定候选窗口，再比较该窗口与 5 个等长随机窗口的删除效应，用于检验 IG 是否能筛选出更有影响的片段。在附件 4 上，为定位每条样本中影响较大的具体位置，进一步计算所有等长窗口的删除效应，选择具有最大正效应的窗口；若不存在超过 0.001 的正效应，则报告绝对影响最大的窗口，并同时保留 IG 候选。附件 4 的全窗口搜索用于展示样本证据，其选出的最大效应不能作为 IG 有效性的独立证明。

完成特征层定位后，还需将候选窗口对应到可直接查看的原始素材。特征槽位记录的是模型中的序列位置，不能直接作为音视频时间，因此采用“槽位对应文字、文字对齐语音、时间定位画面”的映射过程。首先，利用分词器记录的字符偏移，找到各槽位对应的原文片段；随后，使用冻结的 Wav2Vec2 模型计算各声学帧的字符概率，并通过连接时序分类（CTC）强制对齐，将已知文本与语音匹配，估计各词的起止时间；最后，合并证据片段内的词时间，得到语音区间，并根据视频帧的实际显示时间戳（PTS）选取对应画面。

由于一个自然词可能被分为多个子词，同一个词可能对应多个特征槽位，槽位与词并非一一对应。因此，解释结果同时保留字符位置、特征槽位和估计时间：字符位置说明原文内容，槽位说明模型中被分析的位置，时间则用于查找原始语音和视频。

为避免将不可靠的对齐结果作为精确时间，本节设置整段与局部两级质量检查。当平均 CTC 分数低于 0.2、低于 0.1 的词分数占比超过 0.5，或辅助语音识别结果与原文之间的词错误率超过 0.8 时，将该片段标为待复核。其中，CTC 分数用于衡量文本与语音的匹配程度，词错误率用于检查语音识别内容与原文的差异，局部证据中的词分数还须达到 0.1。

未通过检查的证据窗口仍保留原文片段与特征槽位，但不填写正式时间位置。这表示模型中的影响片段已经找到，而它在原始音视频中的准确时间尚不能可靠确定。通过检查的时间也属于文本与语音对齐得到的估计值，不等同于特征提取时的精确时间标注。当视觉证据区间不能可靠定位时，仅提供标记为“非已定位证据”的视频浏览帧，不将其作为该局部窗口的已定位关键帧。

5.3 模型验证与结果分析

5.3.1 预测性能与错误分析

最终模型采用三个随机种子的预测集成，在验证集上的 Accuracy 为 0.6291、Macro-F1 为 0.6046、MAE 为 0.5651、Pearson 相关系数为 0.6904。表 5.2比较了五种候选集成模型的预测性能与综合指标，各方案均在相同完整输入条件下评价。

表 5.2　完整验证集的候选集成模型性能与综合指标

候选模型	Accuracy ↑	Macro-F1 ↑	MAE ↓	Pearson ↑	Y ↓
完整固定融合	**0.6346**	**0.6139**	0.5880	0.6637	0.9741
连续缺失增强固定融合	0.6332	0.6050	0.5911	0.6573	0.9861
掩码与质量增强	0.6305	0.6021	0.5852	0.6531	0.9831
掩码与门控增强	**0.6346**	0.6055	0.5784	0.6827	0.9729
模态组合增强	0.6291	0.6046	**0.5651**	**0.6904**	**0.9605**

由表 5.2可知，各模型的分类指标较为接近，模态组合增强模型取得最低 MAE 与最高 Pearson 相关系数。相较问题二的掩码与门控增强模型，其 MAE 由 0.5784 降至 0.5651，按未舍入数值计算约降低 2.31%，Pearson 相关系数由 0.6827 提高至 0.6904，而 Accuracy 和 Macro-F1 分别由 0.6346、0.6055 略降至 0.6291、0.6046。对应的综合指标 Y 由 0.9729 降至 0.9605，为五种候选方案中的最小值。因此，组合增强后的改善主要体现在连续强度预测，最终模型依据综合指标选定，并非所有单项指标均最优。

图 5.2展示了验证集分类的混淆矩阵 (a) 与情感强度散点分布 (b)，用于分析预测的不足。可以看到，184 条中性样本中，仅 78 条被正确识别，74 条被判为正向、32 条被判为负向，中性召回率为 42.39%。这一结果表明模型对中性类别的辨别能力不足，且中性误判更多流向正向类别。

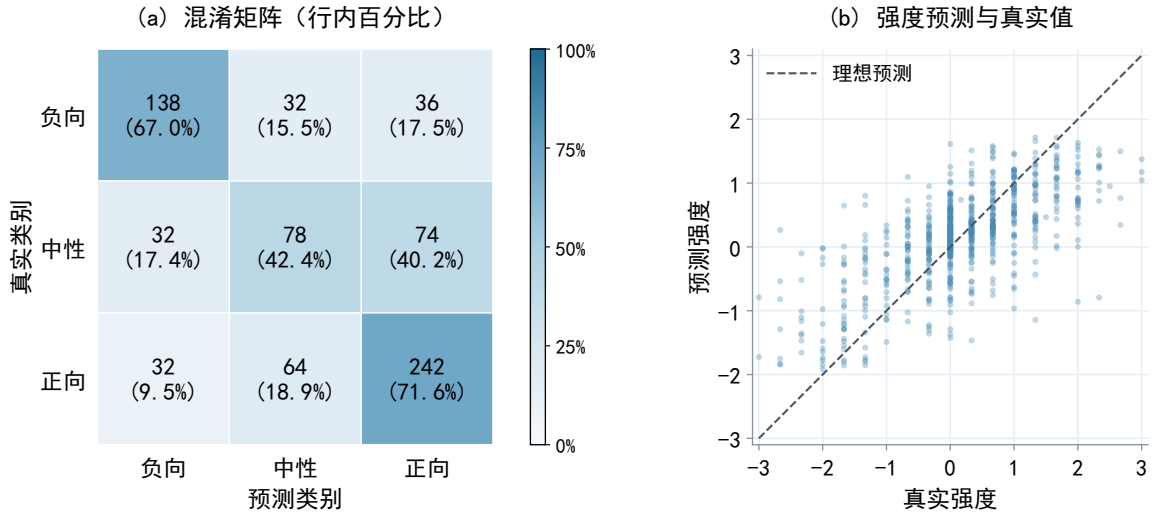


图 5.2　验证集分类混淆矩阵与情感强度预测散点

图 5.2(b) 以虚线表示预测值与真实值相等的位置。强负向区域的预测值总体偏高，强正向区域总体偏低，呈现强度估计向中间收缩的现象。表 5.3进一步按真实强度分组，其中平均偏差定义为预测强度减去真实强度。

表 5.3　不同真实情感强度组的预测误差

分组	样本数	Accuracy	MAE	平均偏差
强负向	58	0.9310	0.9882	+0.9733
弱负向	148	0.5676	0.6085	+0.4569
中性	184	0.4239	0.3591	+0.1481
弱正向	266	0.6579	0.4563	−0.2789
强正向	72	0.9306	1.0631	−1.0618

注：强负向为 $y \le -1.5$，弱负向为 $-1.5 < y < 0$，中性为 $y = 0$，弱正向为 $0 < y \le 1.5$，强正向为 $y > 1.5$。

强负向、强正向组的分类准确率均约为 93.1%，但 MAE 分别达到 0.9882、1.0631，对应的正、负平均偏差与散点图中的收缩方向一致。模型能够较好地识别这些样本的情感方向，但对表达幅度估计不足，弱情感与中性样本则更容易发生类别混淆。分类判断与强度估计因而需要分别评价。

5.3.2 解释忠实性与充分性检验

首先分析三模态在当前模型中的作用分布。如图 5.3左图所示，文本的平均绝对 Shapley 贡献占比远超音频和视觉，大约在 60% 左右，音频和视觉大约占比为 18% 和 20%，可见模型总体上更依赖文本信息。此处平均绝对 Shapley 贡献是先计算每条样本的绝对贡献占比再求平均。

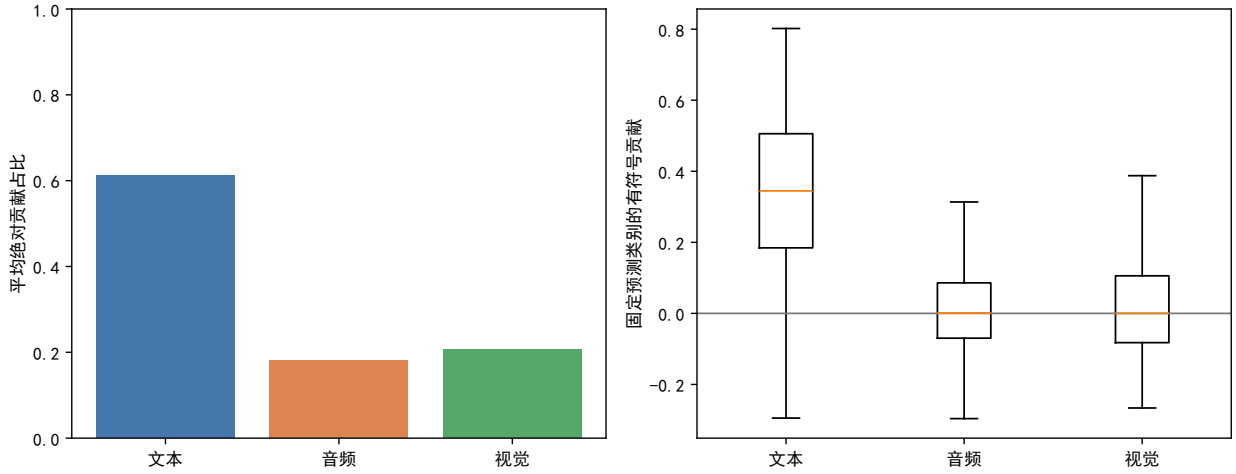


图 5.3　验证集三模态 Shapley 贡献占比与有符号贡献分布

图 5.3右图中，文本有符号贡献的中位数约为 0.3447，整体偏向支持原预测；语音与视觉的贡献分布跨越零值，表明其在不同样本中可能产生支持或抑制作用。正贡献表示支持完整输入原先预测的类别，不等同于支持正向情感。上述结果描述的是当前模型与替代机制下的作用差异，不能据此认为文本对所有样本均最重要，或其余模态可以省略。

为检验积分梯度能否有效筛选模型所依赖的局部信息，本节将积分梯度的筛选证据窗口与相应长度的随机窗口效果进行对比分析。积分梯度证据筛选窗口固定完整输入下的原预测类别，在各模态中依据 IG 分数选取长度约占有效位置数 20% 的连续窗口，随机窗口长度与之保持一致。进行窗口的删除与保留对比实验，比较移除窗口后原预测类别概率的下降程度，以及保留相应证据时原判断的维持程度，结果如图5.4所示。

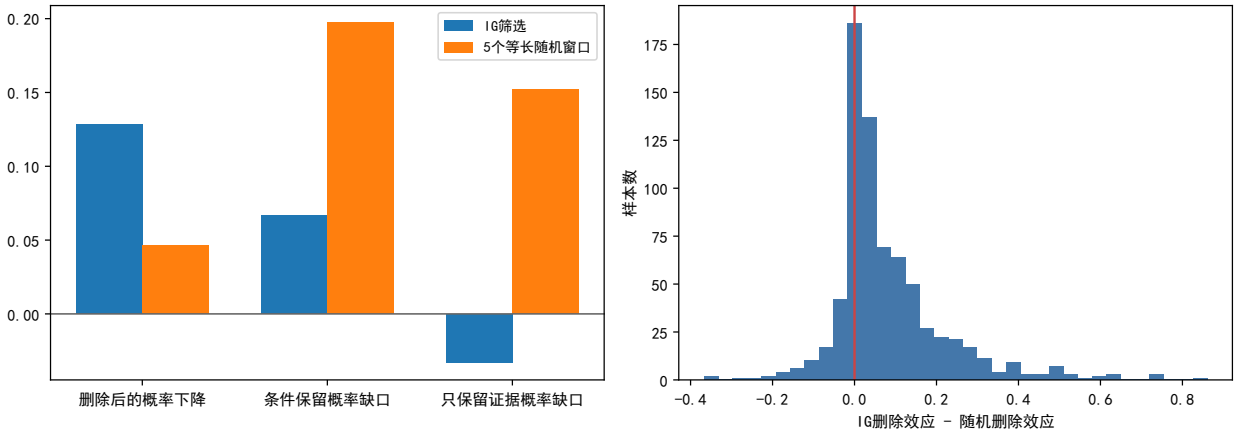


图 5.4　IG 证据窗口与随机窗口的删除、保留检验及删除优势分布

图5.4左图第一列柱状图体现了两种不同窗口删除造成的预测概率下降情况。可以看到，移除 IG 窗口后，原预测类别概率的平均下降幅度大于随机窗口，说明 IG 筛选的片段对模型原判断具有更大的支持作用。图 5.4右图展示了各样本中 IG 窗口与随机窗口删除效应之差的分布，可以看到，绝大部分样本遵循上述删除对比实验的结论，但仍有少部分样本不符合上述结论。

保留实验分别设置条件保留与仅保留证据两种情形：前者仅缩减指定模态，其他模态完整；后者仅保留该模态的证据窗口，其余模态全部移除。同时通过概率缺口进行保留效果分析，定义概率缺口 $G = F_c(X) - F_c(X^{\text{keep}})$，并统计干预后仍输出原类别的比例。

表 5.4　两种保留条件下的原预测类别保持率

保留条件	IG 证据窗口	随机窗口
指定模态保留证据，其他模态完整	84.89%	63.76%
仅保留指定模态证据，其余模态移除	85.16%	61.84%

从图 5.4左图第二、三列中可见，条件保留时，IG 窗口与随机窗口的平均概率缺口均为正，且 IG 窗口的缺口较小；仅保留证据时，IG 窗口的平均概率缺口为负，表明该干预下模型对原预测类别的平均概率有所上升。概率缺口负值的出现，推测可能是与样本中，模态信息冲突等因素相关。

结合表 5.4，条件保留时，IG 窗口与随机窗口的类别保持率分别为 84.89% 和 63.76%；仅保留证据时，两者分别为 85.16% 和 61.84%。在两种设置下，IG 窗口均对应更高的类别保持率。即使移除其他模态，仅保留所选局部证据，模型仍能在多数样本中维持原预测类别。

综合上述分析，基于积分梯度的筛选方法能够更有助于获取解释模型判断的局部证据，但鉴于上述实验均体现的是平均情况，在逐样本分析上仍存在一些不符合主要结论的样本情况。因此，可以认为积分梯度在局部证据定位上具备总体有效性，在实际情况中，仍需要根据样本差异情况进行相应调整。

5.3.3 解释稳定性与敏感性分析

为检验解释结果在不同条件下是否保持一致，本文分别考察主影响模态与局部证据窗口的变化。主影响模态取绝对贡献最大的模态，以其是否发生改变衡量模态层面的稳定性。局部窗口采用 Jaccard 系数衡量位置重合程度，即 $\text{Jaccard}(I_1, I_2) = |I_1 \cap I_2| / |I_1 \cup I_2|$，取值越接近 1，表示两次解释选中的证据位置越一致。结果如图 5.5所示。

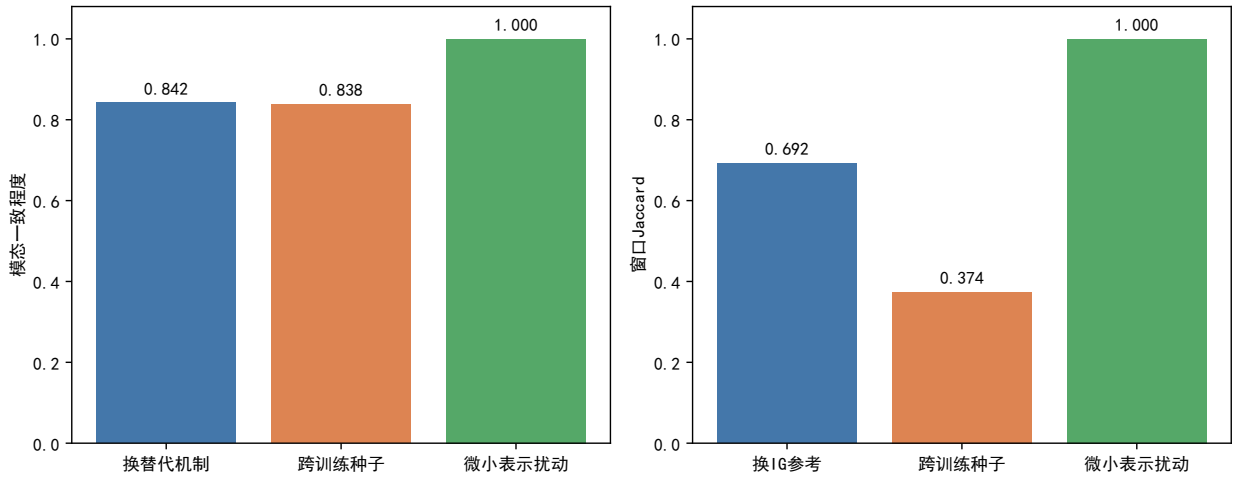


图 5.5　不同参考方式、训练种子与微小扰动下的解释稳定性

图 5.5左图反映了主影响模态的一致程度。在 728 条验证样本上，将“模态不可用”改为“训练集特征中位数替换且保留观测掩码”后，主影响模态一致率为 84.20%。三个训练种子对应的模型分别与集成模型比较，平均一致率为 83.80%。这表明，更换替代机制或训练种子后，多数样本仍由同一模态发挥主要作用，但约 16% 的不一致也说明，主影响模态的判定会受到解释设置和模型训练差异的影响。

图 5.5右图进一步考察具体证据位置，实验使用三类各 32 条、共 96 条验证样本。更换

IG 参考表示后的平均窗口 Jaccard 为 0.692，说明证据位置保留了较多重合，但并非完全一致。跨训练种子的平均 Jaccard 降至 0.374，表明不同模型选中的局部片段存在较大差异。结合左图可以看出，模型对“主要参考哪种模态”的判断相对一致，对“具体参考哪一段内容”的选择则更敏感，即主影响模态相同并不意味着局部证据相同。此外，在同一 96 条样本上向标准化表示加入标准差为 0.02 的高斯噪声后，主影响模态一致率与窗口 Jaccard 均为 1.000，说明所测微小扰动未改变主影响模态及窗口选择。

除解释结果本身的变化外，还需检验 IG 计算的数值误差。理论上，各位置的归因总和应等于固定掩码下输入从参考表示变为实际表示时的目标类别概率变化量，二者差值的绝对值即为完备性绝对残差。图 5.6展示了积分加密前后的残差分布及最终节点数。

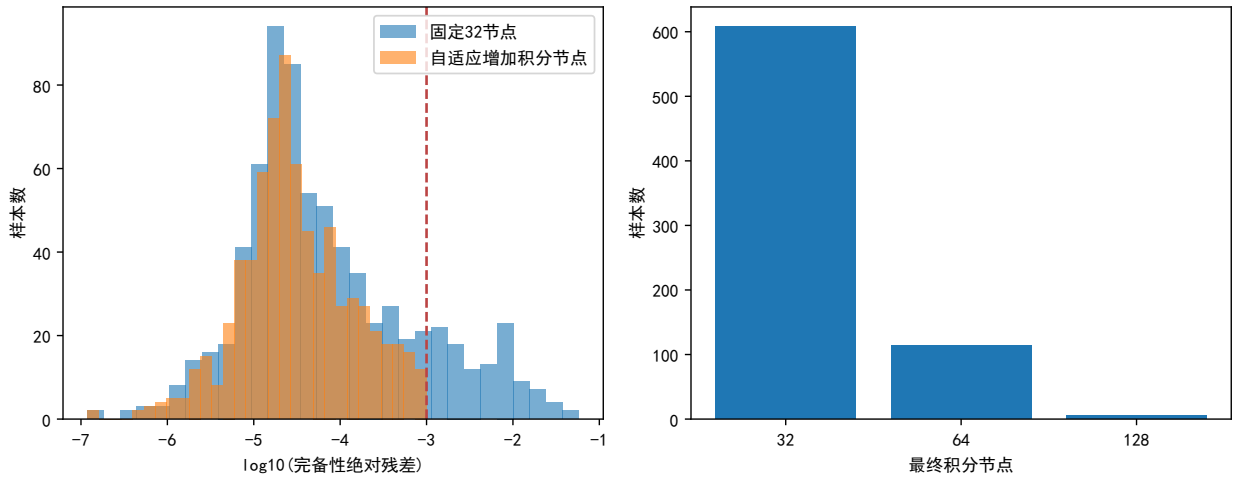


图 5.6　积分梯度自适应加密前后的完备性残差与节点分布

图 5.6左图横轴为完备性绝对残差的十进制对数，位置越靠左表示误差越小，红色虚线对应 0.001 容差。固定 32 节点时，蓝色分布在虚线右侧仍有明显延伸，说明部分样本的积分精度不足。自适应增加积分节点后，橙色分布的右尾收缩，超过容差的情况得到消除。对应数据统计表明，最大残差由 0.05773 降至 0.000994，最终残差的 95% 分位数为 0.000467，全部 728 条样本均满足既定容差。这说明，自适应增加积分节点能够控制归因总和与目标概率变化之间的数值偏差。

图 5.6右图说明了达到上述精度所需的积分节点数。绝大部分样本在 32 节点时已满足容差，约 100 条样本需要增加至 64 节点，极少部分样本需要 128 节点。说明多数样本在初始积分精度下就满足了容差要求，少数样本还需要进一步增加积分节点数来满足容差要求，自适应增加积分节点主要针对这部分样本进行，根据样本误差情况进行计算积分精度调整。

综合两组结果，当前解释在主影响模态层面具有一定一致性，在所测微小扰动下保持稳定，且 IG 归因总和的数值误差已控制在既定容差内。但局部窗口对训练种子较敏感，仍是解释结果的主要限制。因此，后续样本分析应将选中窗口作为当前模型下的局部证据，结合上下文与实际删除效应进行判断。

5.4 附件 4 预测与解释结果

在完成验证集上的模型评价后，将选定模型应用于附件 4 的 20 条无标签样本，输出情感极性、连续强度、三模态贡献与局部证据，并结合原始材料检查其定位情况。本节依次展示全量预测和典型解释，重点分析模型判断依据及其可追溯性。由于缺少真实标签，不对专项样本计算准确率或判定预测是否正确。此外，针对附件 4 的样本数据，本文构建了相应的典型样本解释卡，解释卡示意图可见附录 A 中的图 A.1。

5.4.1 全量结果汇总

20 条样本均完成预测与解释，其中正向 10 条、负向 6 条、中性 4 条。以绝对 Shapley 贡献最大的模态作为主要参考模态，文本主导的样本有 17 条，视觉主导的有 3 条，分别为 04、05、14 号。在这些样本中，语音虽未成为主要参考模态，但仍可能通过支持或抑制作用参与模型决策，表 5.5汇总预测结果及主要参考模态的证据位置。

表 5.5　附件 4 全量预测与主要模态证据定位结果

样本编号	预测极性	预测强度	主要参考模态	主要模态证据窗口	估计时间/s
01	中性	0.3991	文本	$[4, 8)$	1.48—2.68
02	正向	0.3385	文本	$[10, 14)$	1.44—2.04
03	中性	-0.0117	文本	$[1, 8)$	0.50—1.60
04	正向	0.3809	视觉	$[1, 6)$	0.50—1.14
05	正向	0.7098	视觉	$[1, 4)$	1.26—2.06
06	正向	0.1969	文本	$[18, 25)$	3.22—5.68
07	正向	0.8406	文本	$[14, 24)$	3.00—7.66
08	正向	0.8637	文本	$[2, 4)$	0.86—1.20
09	负向	-1.9973	文本	$[8, 12)$	1.48—2.32
10	负向	-0.8015	文本	$[25, 31)$	待复核
11	负向	-1.5917	文本	$[4, 7)$	0.92—3.46
12	负向	-0.6376	文本	$[34, 42)$	9.94—12.26
13	中性	0.1479	文本	$[9, 15)$	1.62—4.36
14	正向	0.5526	视觉	$[1, 8)$	0.50—1.44
15	正向	0.7544	文本	$[5, 9)$	待复核
16	负向	-1.8128	文本	$[10, 12)$	待复核
17	正向	1.2345	文本	$[19, 24)$	7.84—9.02
18	中性	-0.3897	文本	$[7, 17)$	1.72—5.08
19	负向	-0.4397	文本	$[12, 20)$	3.90—6.92
20	正向	0.8572	文本	$[18, 27)$	4.56—6.78

注：证据窗口采用从 0 开始的半开区间，包含起点、不包含终点。时间为依据原文 CTC 强制对齐得到的估计值，并非官方特征时间戳，序列位置不能直接等同于视频秒数。“待复核”表示正式时间尚不可用，未以候选时间代替。

分类与回归由两个输出头分别预测，因此表中中性类别可能对应非零强度，如 01 号为中性、强度 0.3991。为体现原始数据，此处我们并未强制将强度修改为 0，而是保留两个任务各自的预测结果，如实呈现模型输出。

为进一步比较各样本的模态作用，图 5.7展示三模态有符号 Shapley 贡献。多数样本的文本贡献为较大的正值。04、14 号的文本贡献分别为 -0.391、-0.223，而视觉贡献分别为 0.428、0.341，显示不同模态对同一次判断可能产生相反作用。因此，专项预测虽整体上以文本为主要依据，个别样本仍需要结合其他模态解释。

图5.7中正值表示支持，负值表示抑制。例如，09 号样本被预测为负向，其正文本贡献表明文本为负向判断提供了支持。因此，热图主要用于比较各样本内部三种模态的作用方向与贡献大小，具体含义需结合该行的预测类别理解。

在证据定位方面，20 条样本均保存了三模态证据，共 60 条记录，其中文本、语音和视觉分别有 17、15、16 条获得通过既定检查的估计时间。15、16 号样本仍需复核整段匹配关系，10 号样本的主要文本证据则需进一步确认局部时间。上述结果表明，证据定位已覆盖全部样本，时间映射的完成程度仍存在样本与模态差异，后续复核应重点关注整段匹

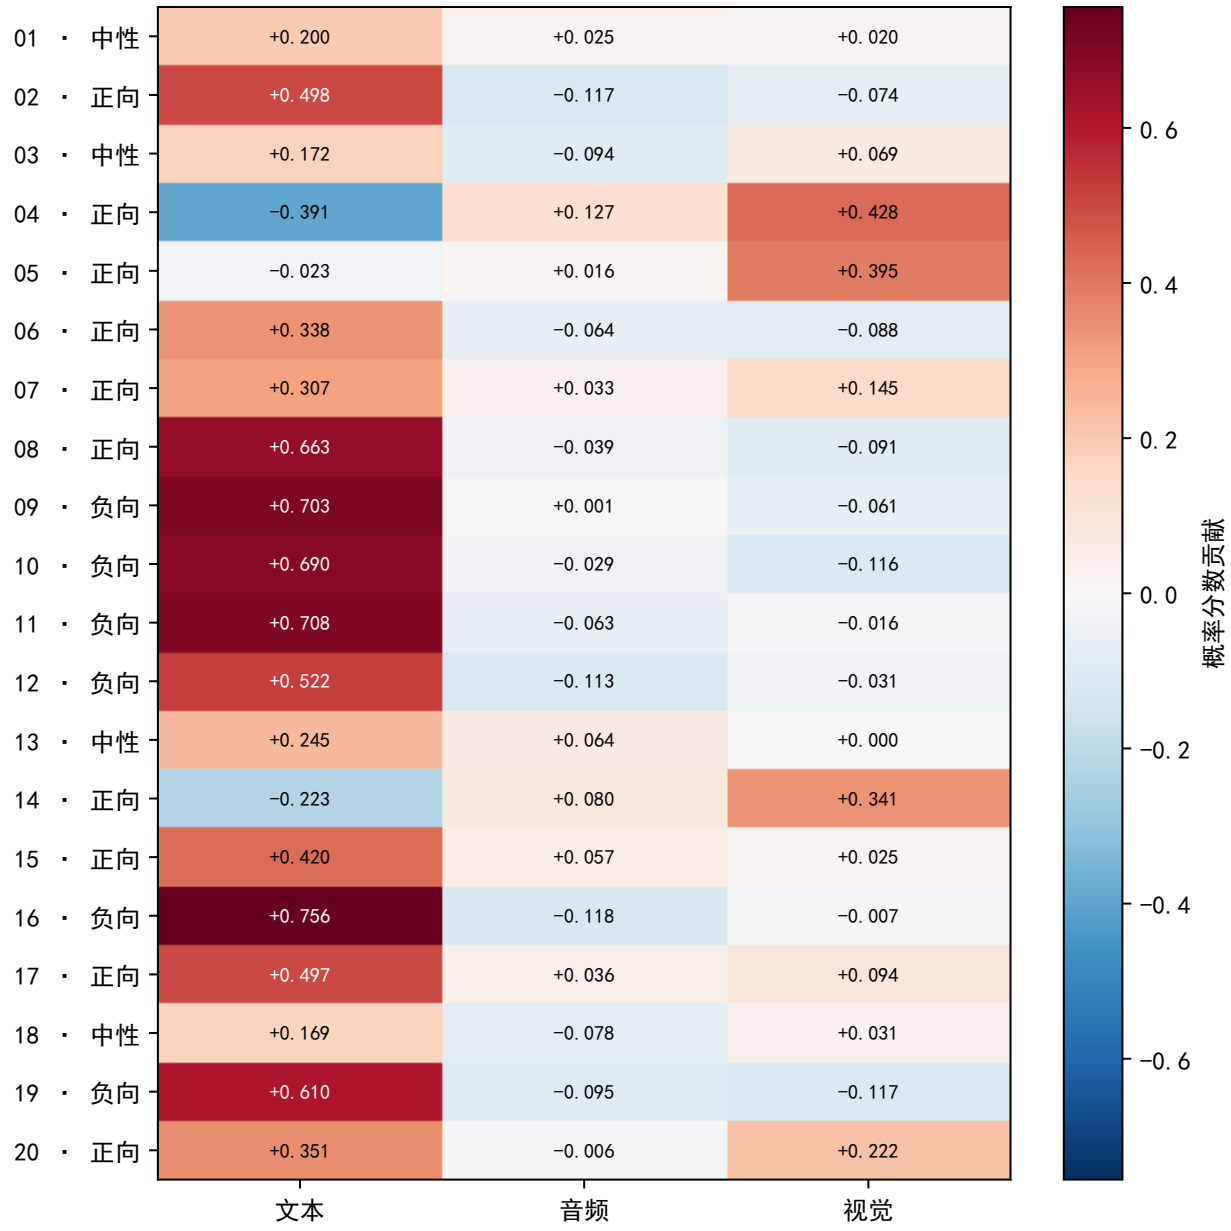


图 5.7　附件 4 样本的三模态有符号 Shapley 贡献

配异常及局部低置信窗口。此外，07、18 号原文超过模型输入上限，其解释范围限定于截断后实际参与预测的内容。

5.4.2 典型样本解释与证据展示

本节选取了 04、09、15 号，分别展示模态作用方向差异、文本局部证据以及时间映射限制。图 5.8按上述顺序排列三个案例，左列给出主要模态的等长窗口删除效应，右列展示对应样本的视觉证据帧或浏览帧。04、09、15 号样本的窗口长度分别为 5、4、4 个槽位，同一样本的确认窗口与 IG 候选窗口长度一致，图中红色实线和绿色虚线分别标记两类窗口的起点。

（1）04 号：视觉主导下的模态作用差异。该样本预测为正向，强度 0.3809。文本、语音、视觉贡献分别为 −0.391、0.127、0.428，视觉绝对贡献占比约 45.20%，略高于文本的 41.37%。因此，认为该样本中，“视觉主导”表示视觉在本样本中的绝对影响最大。

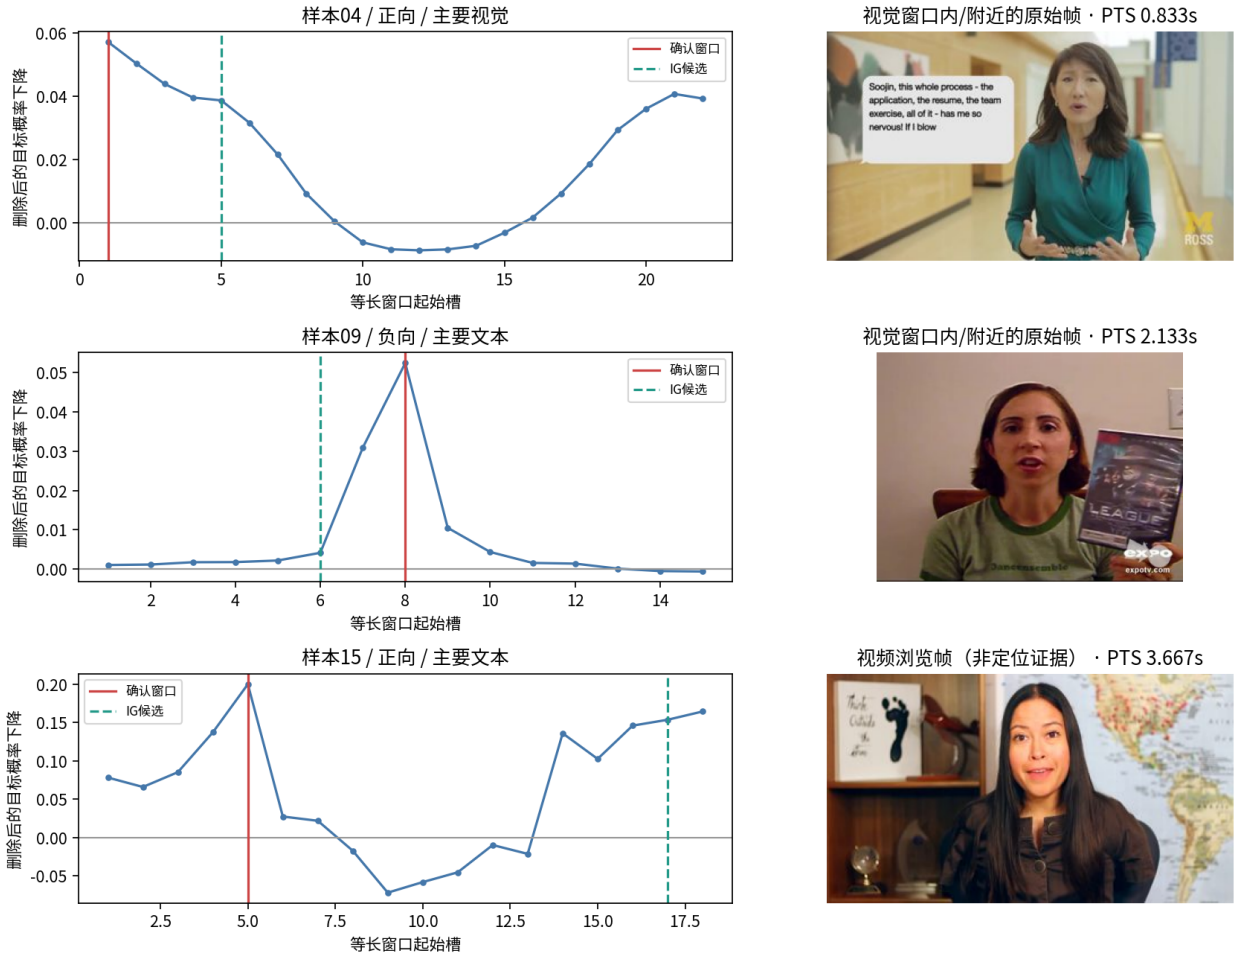


图 5.8　典型样本的局部删除效应与原始视频帧

第一行曲线中，视觉确认窗口为 $[1,6)$，估计对应 0.50—1.14 秒，删除使原正向类别概率下降约 5.71 个百分点。IG 候选 $[5,10)$ 的下降约为 3.86 个百分点。右侧原始帧时间为 0.833 秒，处于视觉证据估计区间内。这一案例展示了模型在支持与抑制信息共同存在时形成正向输出的情况。

（2）09 号：否定语境中的文本证据。该样本预测为负向，强度 -1.9973，文本贡献 0.703，绝对贡献占比约 91.86%。完整转写包含“I did not like this movie at all”及不推荐该影片的表述，需要在这一否定语境下理解局部证据。

确认窗口 $[8,12)$ 对应“like this movie at”，估计时间为 1.48—2.32 秒，删除使原负向类别概率下降约 5.23 个百分点，IG 候选 $[6,10)$ 的下降约为 0.42 个百分点。两者差异说明表示层 IG 候选与实际删除影响最大的片段并不总是一致，输入干预补充了局部定位信息。窗口中的“like”不能脱离原句解释为正向情感。右侧 2.133 秒的帧来自该样本的视觉证据区间，用于回看视觉材料，不能作为文本判断正确性的直接证明。

（3）15 号：保留可追溯证据及时间不确定性。该样本预测为正向，强度 0.7544，文本贡献 0.420。确认窗口 $[5,9)$ 对应“poverty, the family”，删除使原正向类别概率下降约 19.99 个百分点。其作用需结合整句关于家庭重视教育及其改变生活力量的表述理解，而不是单纯关注孤立词语的语义信息。

该样本的给定转写与诊断识别结果存在明显不一致信号，CTC 平均置信分数约 0.006，未能提供通过检查的正式时间。因此保留特征窗口与原文字符对应，将时间标为待复核。图中 3.667 秒画面仅为浏览帧，不可作为已定位关键证据。此例说明，特征层面的影响可

以复算，并不代表原始音视频时间已可靠确认，现有记录也不足以断言预测错误或视频必然配错。

上述专项窗口通过穷举删除效应确定，适用于展示与复核具体样本的关键位置，其较大效应不作为独立忠实性证明。解释方法的检验仍以前节验证集上的随机对照为依据，从而区分具体案例展示与方法有效性评价。

5.5 本问小结

本问在问题二模型基础上，引入模态组合增强，实现情感极性与强度预测，并进一步量化模态贡献、定位局部证据，将解释结果关联至原始文本与音视频材料，形成从预测到证据回溯的完整流程。

在参与模型选择的验证集上，最终模型的综合指标 Y 由问题二掩码与门控增强模型的 0.9729 降至 0.9605，为五种候选方案中的最小值。MAE 由 0.5784 降至 0.5651，表明该方案在兼顾分类与回归表现的基础上，主要优化了情感强度预测。通过 Shapley 分析发现，当前模型总体更依赖文本，同时揭示了语音与视觉对不同样本原预测类别的支持或抑制作用。局部证据检验表明，IG 窗口较等长随机窗口具有更大的平均删除效应，保留时也更有利于维持原预测。稳定性实验进一步表明，主影响模态多数保持一致，且在所测微小扰动下，模态选择与局部窗口均保持稳定。

针对附件 4，完成全部 20 条样本的预测与解释，保存 60 条三模态证据记录，并明确标注估计时间及待复核状态，实现了预测结果、模态作用与原始材料之间的对应。上述成果为理解和复核模型判断提供了可追溯依据。考虑到局部证据对训练差异的敏感性及部分时间定位的不确定性，具体解释仍需结合上下文使用。

6 模型评价与推广

6.1 模型的优点

(1) 特征组织完整，时序对应可追溯。问题一以原文词为共同单位，通过 CTC 强制对齐与时间交叠加权聚合，建立三模态特征对应关系，保存字符位置、候选词界、原生记录与聚合权重。全部 100 条样本均保留原始信息，分别标记模态观测状态与对齐质量，并结合人工内容审核，为异常定位与素材回看提供依据。
(2) 缺失处理与训练增强相结合。问题二区分有效位置与可观测位置，结合模态质量指标、掩码池化和门控融合处理局部缺失。文本遮挡在编码前实施，避免被删除内容通过上下文传播。递进消融表明，连续遮挡增强带来了主要的缺失性能改善，缺失感知处理与门控进一步调整了分类和回归表现。
(3) 模型选型兼顾多项指标。本文比较了动态缺失增强与辅助学习、任务专属融合、注意力交互三类扩展框架，考察完整输入、连续缺失及强情感分组表现。各扩展方案均未满足缺失平均 Macro-F1 至少提高 1 个百分点且 MAE 不增加的必要条件，因此保留原缺失感知门控模型，避免仅凭单项指标改善更换方案。
(4) 解释目标明确，证据作用可复核。问题三固定原预测类别，枚举八种模态组合计算 Shapley 贡献，区分支持与抑制作用；利用积分梯度筛选局部窗口，通过删除、保留及等长随机对照检验其作用。同时保存原文、槽位与估计时间，分别检查积分误差和时间映射质量，形成从预测到原始素材的分层解释。

6.2 模型的局限性

(1) 文本依赖与情感边界误差仍较突出。模型对文本缺失较敏感，声学与视觉尚未稳定提供互补收益。完整验证结果中，问题二与问题三的中性召回率分别为 40.76% 和 42.39%，弱情感与中性仍易混淆。强情感预测存在幅度向零收缩的偏差，分类与回归输出也可能出现方向分歧。
(2) 局部解释存在训练敏感性与时间不确定性。在 96 条稳定性验证样本上，跨训练种子的证据窗口平均 Jaccard 为 0.374，具体证据位置对训练差异较敏感。贡献与删除效应依赖解释目标和替代机制，特征行删除也不等价于原始素材剪辑，不能直接解释为真实情绪成因。部分证据仅能定位到原文与槽位，音视频时间仍需复核。

6.3 改进方向与应用推广

时序对齐方面，可补充人工词界标注，评价边界误差与筛选规则，并引入说话人与人脸的对应关系，提高视觉特征的关联可靠性。

情感预测方面，可加强否定、评分与比较结构的语义建模，针对中性混淆、强情感低估及双头分歧改进训练目标。改进效果应同时在完整输入、缺失场景和关键情感分组上检验。

可解释性方面，可汇总不同种子与参考方式下反复出现的证据，结合原始素材开展人工复核。时间受限的样本继续保留原文与槽位解释，经核验后再提供音视频证据区间。

本文方法可为服务对话、在线访谈和教学互动等视频分析提供参考，辅助定位待人工审阅的片段。推广前需检验跨语言、说话人与录制条件的适应性，并评估计算耗时。由于问题一自提特征与问题二、三所用特征的定义和维度不同，构建端到端应用仍需统一特征接口，重新训练并验证预测模型。

7 总结

本文围绕复杂场景下的多模态情感预测，完成特征提取与时序对齐、局部缺失下的鲁棒预测以及预测依据解释三项任务。问题一建立原始素材与词级特征的对应关系，问题二、三基于附件 2 的统一输入接口开展学习与评价，分别面向局部缺失和完整模态场景。

针对问题一，采用 DistilBERT、openSMILE 和 MediaPipe 提取三模态特征，通过 CTC 强制对齐与时间交叠加权聚合，形成覆盖 100 条样本、1932 个原文词位置的变长序列。其中，1545 个词通过对齐质量筛选，占 79.97%；1387 个词同时满足筛选与三模态可观测条件，占 71.79%。结合对 21 条异常样本的人工内容审核，保留全部样本及原始词位置，并明确候选时间对应的使用范围，为特征复算和素材核查提供依据。

针对问题二，构建由时序编码、掩码池化、缺失质量表征和门控融合组成的双任务模型，并采用连续遮挡增强与三种子集成。在 728 条验证样本的完整输入下，Macro-F1 和 MAE 分别为 0.6055、0.5784；在 727 条测试样本的三模态同步随机连续遮挡 50% 有效词元槽位条件下，三次遮挡的平均 Macro-F1 由完整输入训练的固定融合基线的 0.4328 提高至 0.5316。消融与扩展框架比较支持保留缺失感知门控方案，同时表明文本相关缺失和较高遮挡比例是当前模型性能退化的重要条件。最终完成附件 3 全部 30 条样本的情感极性与强度预测。

针对问题三，在门控模型基础上引入模态组合增强，结合精确 Shapley 贡献、积分梯度筛选及删除和保留检验，实现模态作用量化与局部证据定位。在参与模型选择的 728 条完整验证样本上，最终模型的 Macro-F1 为 0.6046、MAE 为 0.5651。固定原预测类别后，主影响模态中积分梯度窗口相对等长随机窗口的平均删除优势为 8.20 个百分点，源视频聚类 Bootstrap 的 95% 区间为 $[7.15, 9.22]$ 个百分点，支持所选片段在当前检验条件下具有更强的预测支持作用。最终完成附件 4 全部 20 条样本的预测与解释，保存 60 条模态证据记录，并标记时间定位待复核的片段。

上述结果表明，显式记录时序对应与缺失状态，并对模态贡献及局部证据开展检验，有助于提高多模态情感预测过程的可追溯性。现有方法在所考察缺失条件下取得了整体性能改善，但对齐准确性、情感边界辨别、强度估计及局部解释稳定性仍有改进空间，其应用价值需结合具体场景进一步验证。

参考文献

[1] Wang L, Ma C, Feng X, et al., A survey on large language model based autonomous agents, Frontiers of computer science, 18(6):186345, 2024.

[2] Poria S, Cambria E, Bajpai R, et al., A review of affective computing: From unimodal analysis to multimodal fusion, Information fusion, 37:98-125, 2017.

[3] Zadeh A B, Liang P P, Poria S, et al., Multimodal language analysis in the wild: Cmu-mosei dataset and interpretable dynamic fusion graph, Proceedings of the 56th annual meeting of the association for computational linguistics (volume 1: Long papers), 2236-2246, 2018.

[4] Jain S, Wallace B C, Attention is not explanation, Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers), 3543-3556, 2019.

[5] 何俊, 张彩庆, 李小珍, 等, 面向深度学习的多模态融合技术研究综述, 计算机工程, 46(5):1-11, 2020.

[6] 陶建华, 范存航, 连政, 等, 多模态情感识别与理解发展现状及趋势, 中国图象图形学报, 29(6):1607-1627, 2024.

[7] Sanh V, Debut L, Chaumond J, et al., DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter, arXiv preprint arXiv:1910.01108, 2019.

[8] Baevski A, Zhou Y, Mohamed A, et al., wav2vec 2.0: A framework for self-supervised learning of speech representations, Advances in neural information processing systems, 33: 12449-12460, 2020.

[9] Graves A, Fernández S, Gomez F, et al., Connectionist temporal classification: labelling unsegmented sequence data with recurrent neural networks, Proceedings of the 23rd international conference on Machine learning, 369-376, 2006.

[10] 杨杨, 詹德川, 姜远, 等, 可靠多模态学习综述, 软件学报, 32(4):1067-1081, 2021.

[11] He K, Ding Y, Wang X, et al., Enhance-then-Balance Modality Collaboration for Robust Multimodal Sentiment Analysis, arXiv preprint arXiv:2604.12518, 2026.

[12] Ma J, Zhao Z, Yi X, et al., Modeling task relationships in multi-task learning with multi-gate mixture-of-experts, Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining, 1930-1939, 2018.

[13] Baltrušaitis T, Ahuja C, Morency L P, Multimodal Machine Learning: A Survey and Taxonomy, IEEE Transactions on Pattern Analysis and Machine Intelligence, 41(2):423-443, 2019.

[14] Vaswani A, Shazeer N, Parmar N, et al., Attention is all you need, Advances in neural information processing systems, 30, 2017.

[15] Tsai Y H H, Bai S, Liang P P, et al., Multimodal transformer for unaligned multimodal language sequences, Proceedings of the 57th annual meeting of the association for computational linguistics, 6558-6569, 2019.

[16] 纪守领, 李进锋, 杜天宇, 等, 机器学习模型可解释性方法, 应用与安全研究综述, 计算机研究与发展, 56(10):2071-2096, 2019.

[17] Lundberg S M, Lee S I, A unified approach to interpreting model predictions, Advances in neural information processing systems, 30, 2017.

[18] Sturmfels P, Lundberg S, Lee S I, Visualizing the impact of feature attribution baselines, Distill, 5(1):e22, 2020.

[19] Sundararajan M, Taly A, Yan Q, Axiomatic attribution for deep networks, International conference on machine learning, PMLR, 3319-3328, 2017.

附录 A　附件说明

本文的程序、模型参数、特征文件及完整计算结果随电子附件提交，按问题一、问题二和问题三分别组织，见表A.1。各目录均附有文件说明与复现说明，便于查阅结果和复核计算过程。

表 A.1　附件说明

序号	附件目录	主要内容
1	问题一提交附件	100 条样本的多模态特征、词级时间对应记录、质量标记、结果汇总表、处理程序、统计图及复现实验说明。
2	问题二提交附件	赛题附件 3 的 30 条情感预测结果、三种子集成模型参数、训练与推理程序、参数配置、运行环境及实验记录。
3	问题三提交附件	赛题附件 4 的 20 条预测与解释结果、60 条模态局部证据、时间映射与关键帧、模型参数、解释程序及验证记录。

主要结果文件及查阅方式如下：

1. 问题一：在“问题一提交附件”的 step1/results/目录中，“全部样本特征交付清单.csv”汇总 100 条样本的特征提取结果，samples 子目录保存逐样本特征、时间对应及质量记录。
2. 问题二：“问题二提交附件”中的“附件 3_ 问题二预测.csv”给出全部 30 条专项测试样本的情感极性与强度预测，“模型”“配置”“代码”及“实验记录”目录分别保存对应的参数、配置、程序与实验结果。
3. 问题三：在“问题三提交附件”的 step3/results/目录中，“附件 4_ 问题三预测与解释.csv”给出全部 20 条专项测试样本的预测与解释结果。该附件根目录下的“解释结果查看.html”可用于离线查阅模态贡献、原文证据及图像。

总附件根目录中的“总说明.md”提供文件导航，“总文件校验清单.json”和“核验总附件.py”用于文件完整性核验。各问的运行步骤、数据处理规则与环境配置分别见“复现实验说明.md”“代码与复现说明.md”和“复现说明.md”。原始赛题数据及公开预训练权重不重复打包，其准备方式见上述说明。问题一输出的自生成特征与问题二、问题三使用的赛题对齐特征分别组织。

逐样本解释结果展示

图 A.1为电子附件中 01 号样本展开后的完整解释卡。其余 19 条样本可在“问题三提交附件”中的“解释结果查看.html”中查阅。



图 A.1　01 号样本的完整解释卡：情感预测、模态贡献与三模态局部证据

附录 B　人工智能软件辅助答题说明

在本论文的研究与撰写过程中，我们使用了人工智能（AI）工具进行辅助。具体信息如下：

1. **AI 软件平台**
   名称：ChatGPT；
   版本 / 型号：gpt-6-astra；
   开发机构：OpenAI；
   模型版本发布日期：2026 年 9 月 3 日。
2. **AI 使用方式**
   AI 工具用于辅助本文相关 Python 程序的编写与修改，涉及问题一的多模态特征提取与时序对齐、问题二的模态局部缺失条件下的情感预测，以及问题三的模态贡献计算与局部证据解释等程序实现。作者对所采用的程序逻辑及计算结果进行了检查和核验。此外，AI 工具用于辅助整理附件清单、拟写本附录的说明文字及生成相应的 Latex 排版代码。论文中的实验结果以实际运行程序所得的输出记录为依据。
3. **作者责任确认**
   本论文全体作者已对所采用的 AI 辅助内容进行了审查与核验，并对论文中的程序、推导、数据结果及文字表述进行了检查。论文最终采用的方法、结果和结论由作者审定，手稿及提交材料的准确性、完整性由全体作者承担责任。AI 工具仅作为研究和写作的辅助手段，不作为研究成果的责任主体。