多模态情感特征提取与时序对齐

1 原始数据与预处理

100条
原始视频

标签表
转写与标签

样本编号与完整性核对

文本预处理
原始转写 · 字符位置

音频预处理
16 kHz单声道 · 时间信息

视频预处理
约5 Hz抽样 · 真实PTS

2 三模态特征提取

文本 / 语音 / 视觉
三条并行支路

冻结DistilBERT
子词编码 → 词级平均
文本特征 $L \times 768$

openSMILE · eGeMAPSv02
音高 · 响度 · 音质
声学窗口特征 $N_a \times 25$

MediaPipe人脸检测
52维面部blendshape
抽样帧特征 $N_v \times 52$

3 词级时序对齐

给定英文转写

解码音频

Wav2Vec2 + CTC强制对齐
估计词级时间边界

词级候选时间区间
起止时间 · 对齐置信度

原生声学特征
窗口时间 · 有效掩码

原生视觉特征
帧时间 · 有效掩码

时间交叠加权聚合
词级音频25维 · 视觉52维

词级文本768维

统一词位置的三模态特征
$L \times 768$ / $L \times 25$ / $L \times 52$

4 质量控制与结果输出

三模态特征与映射记录

样本完整性
编号与覆盖
原文与标签

观测有效性
有效音频
可用人脸

对齐时间质量
CTC置信度
ASR转写一致性

汇总特征与质量记录
观测掩码 · 时间掩码 · 异常标记

计算与记录核验
复算权重与聚合
核对时间映射

人工审核
回看原文与声画
记录审核结论

可追溯结果交付
特征文件 · 全量汇总 · 验证图
处理日志与复现说明

L：词数　N_a：声学窗口数　N_v：抽样帧数　|　通过自动质控不等于人工确认词界准确