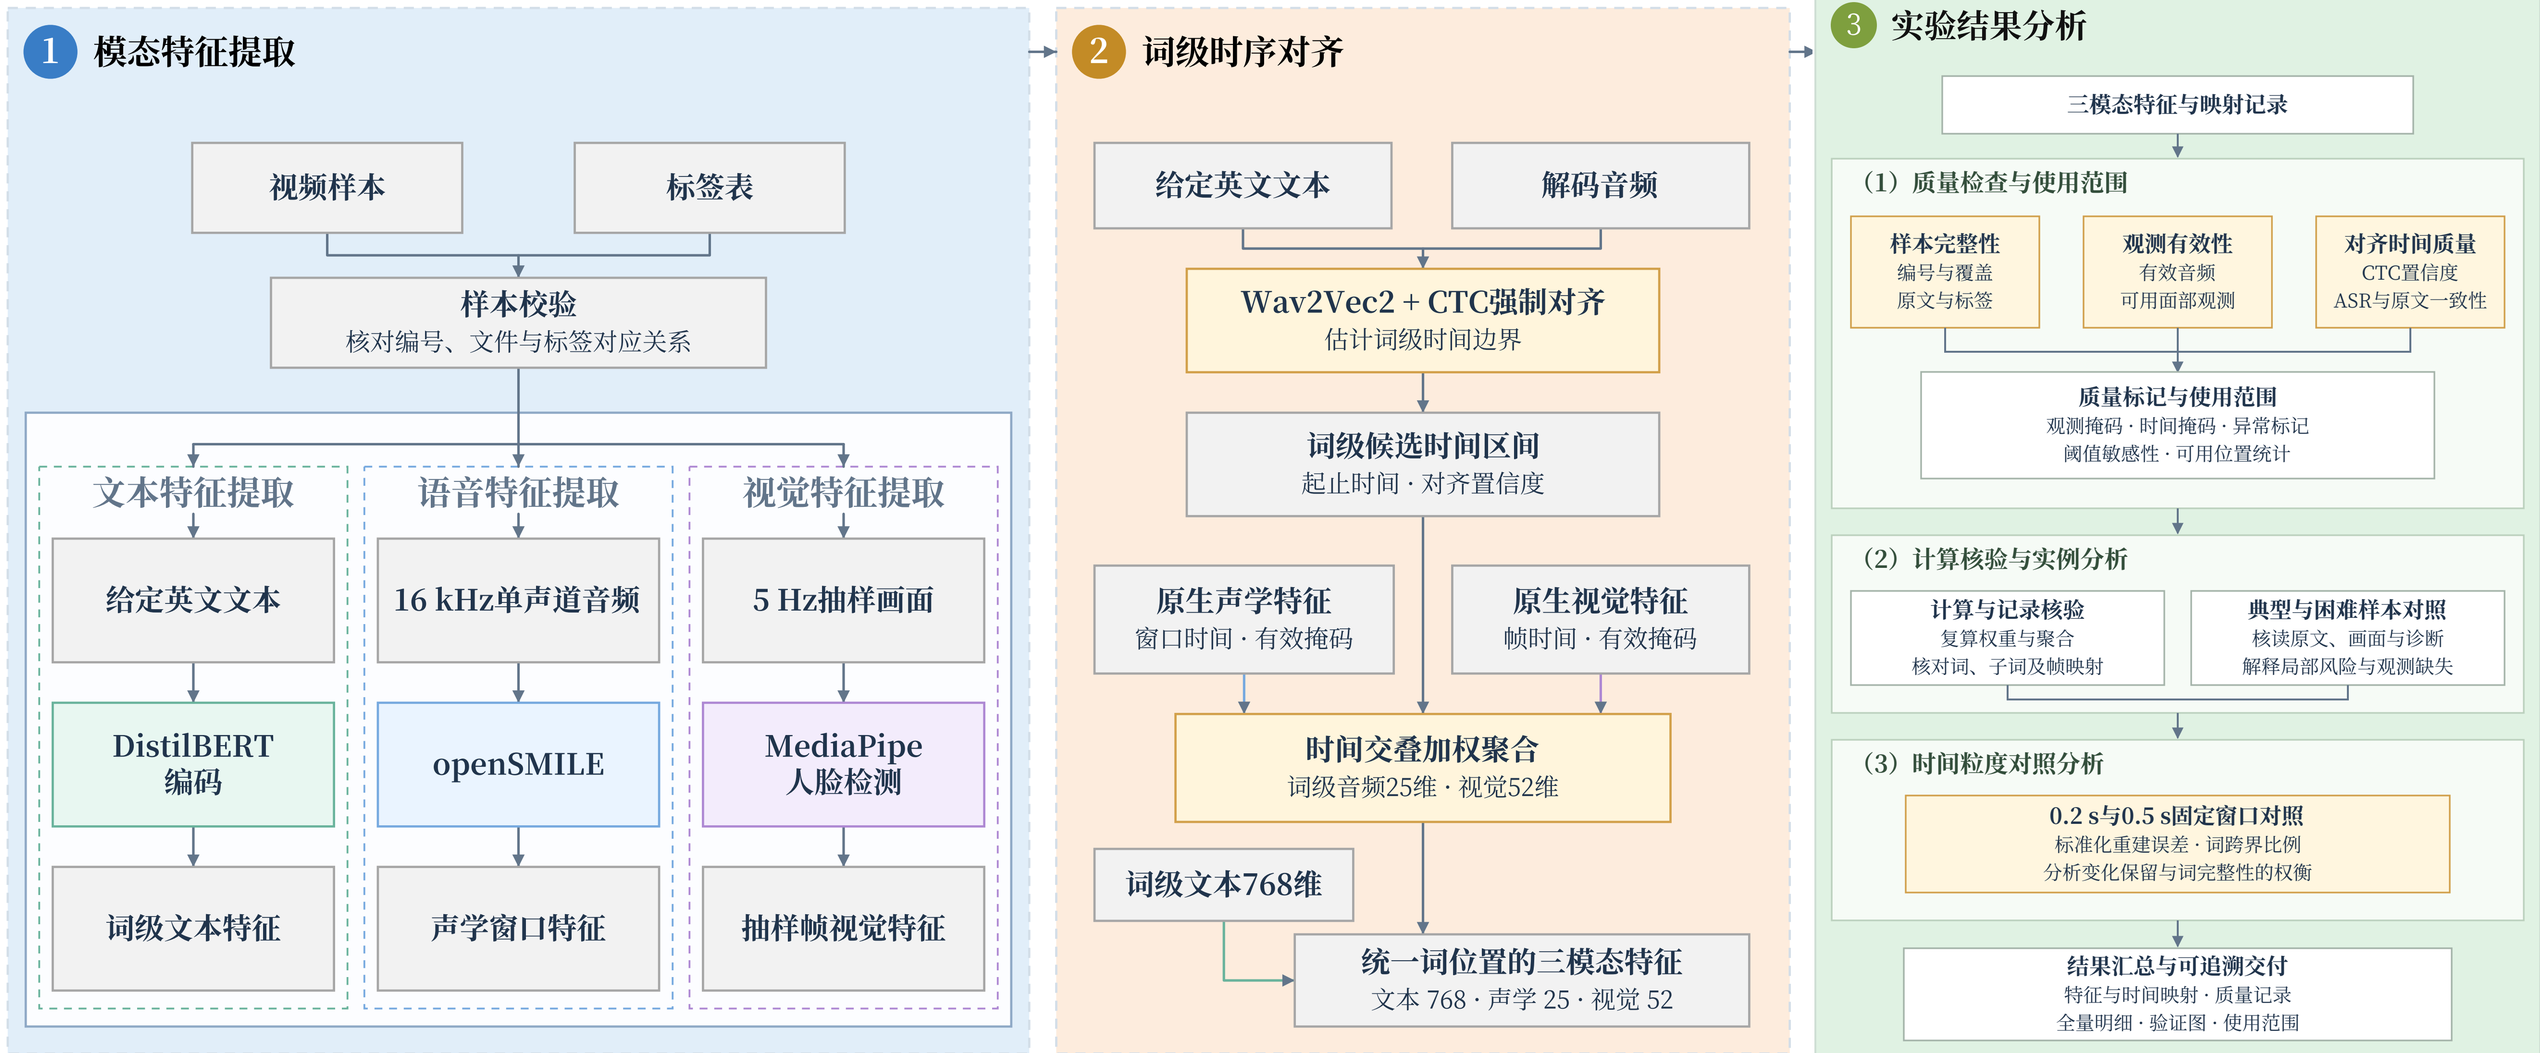

1 模态特征提取
视频样本
标签表
样本校验
核对编号、文件与标签对应关系
文本特征提取
给定英文文本
DistilBERT
编码
词级文本特征
语音特征提取
16 kHz单声道音频
openSMILE
声学窗口特征
视觉特征提取
5 Hz抽样画面
MediaPipe
人脸检测
抽样帧视觉特征
2 词级时序对齐
给定英文文本
解码音频
Wav2Vec2 + CTC强制对齐
估计词级时间边界
词级候选时间区间
起止时间 · 对齐置信度
原生声学特征
窗口时间 · 有效掩码
原生视觉特征
帧时间 · 有效掩码
时间交叠加权聚合
词级音频25维 · 视觉52维
词级文本768维
统一词位置的三模态特征
文本 768 · 声学 25 · 视觉 52
3 实验结果分析
三模态特征与映射记录
（1）质量检查与使用范围
样本完整性
编号与覆盖
原文与标签
观测有效性
有效音频
可用面部观测
对齐时间质量
CTC置信度
ASR与原文一致性
质量标记与使用范围
观测掩码 · 时间掩码 · 异常标记
阈值敏感性 · 可用位置统计
（2）计算核验与实例分析
计算与记录核验
复算权重与聚合
核对词、子词及帧映射
典型与困难样本对照
核读原文、画面与诊断
解释局部风险与观测缺失
（3）时间粒度对照分析
0.2 s与0.5 s固定窗口对照
标准化重建误差 · 词跨界比例
分析变化保留与词完整性的权衡
结果汇总与可追溯交付
特征与时间映射 · 质量记录
全量明细 · 验证图 · 使用范围