（a）三模态原生单元的时间粒度不同

物理时间

0 T

文本
词／子词单元

I | really | like | this | film

虚线词界仅作示意，需由转写与声画建立时间对应

语音
短时分析窗口

连续滑动，窗口之间可重叠

视觉
离散视频帧

各帧对应独立的采样时刻

（b）固定窗口可能切开词

局部时间区间示意

固定窗口 j | 固定窗口 j+1

really（一个完整词）

窗口边界穿过词内部

同一词的声画观测
可能分散到相邻窗口

相同序列位置 ≠ 相同时间区间；固定时间窗口也不保证词的完整性。

注：英文词、区间长度与采样密度均为概念示意，非实测结果；本图不表示原视频音画不同步。