1 问题一：多模态特征提取与时序对齐

1.1 实验结果分析

前文已通过三模态特征提取、CTC 强制对齐与时间交叠加权，将原始视频及给定转写转化为具有统一词位置的特征序列。本节进一步检验这些输出能否回应赛题提出的原始样本覆盖完整性、时序组织可核验性，以及方法合理性与可复现性要求。具体而言，先核对样本及模态观测的覆盖范围，再依次通过自动诊断、固定窗口对照与人工审核，考察候选对应的筛选范围、时间划分的影响及输入异常的来源；随后以典型样本验证特征与原始素材之间的映射，最后给出全部 100 条样本的结果汇总、文件读取方式和复现流程。由此，将前文的方法定义落实为能够逐样本查阅、按记录复算的特征输出。

1.1.1 样本覆盖完整性与特征有效性

为检查原始样本覆盖完整性，本文以视频编号和片段编号组成的唯一标识，核对原始视频、给定转写、标签记录与输出目录。已有全量核验结果表明，附件 1 的 100 条样本均具有对应输出，原文及标签与输入记录一致，源视频哈希核对通过。各样本分别生成 768 维文本、25 维声学和 52 维视觉词级特征，三种矩阵的行数均等于该样本的原文词数，共保留 1932 个词位置，未发生长度截断。表 1在样本覆盖的基础上进一步统计各模态的观测状态，其中样本比例以 100 为分母，词比例以 1932 为分母。

表 1: 样本处理与三种模态的观测覆盖情况

统计项目	数量	占比
已处理样本	100	100.00%
与原文对应的输出词位置	1932	100.00%
文本模态可观测的词	1932	100.00%
声学模态可观测的词	1932	100.00%
视觉模态可观测的词	1595	82.56%

在核对全部样本的输出后，进一步统计各词位置的模态观测覆盖情况。前文原始画面观察已显示，部分时刻难以获得可用人脸；图 1进一步给出这一现象在全量数据中的范围。3973 帧抽样画面中，3253 帧获得面部特征，720 帧未获得可用结果；按候选词区间聚合后，1595 个词具有有效面部记录，337 个词缺少相应记录。由于一帧可以参与多个词的聚合，一个词也可以关联多帧，帧级与词级覆盖率分别以各自记录总数为分母。本文通过逐位置有效标记记录上述视觉缺失情况，使特征矩阵与观测状态能够对应查询。

声学模态则呈现不同的情况：所有词位置均有可计算记录，但原生声学序列的幅度状态存在明显差异。以数字音频满幅 1 为基准，将短时均方根幅度（RMS）低于 0.0031623 的记录标记为低能量，77261 条记录中共有 9918 条满足该条件，占 12.84%，如图 2所示。低

能量标记用于描述声学记录的幅度状态，并与观测有效标记分别保存。相关记录保留在原时间位置，供后续聚合与质量分析使用。

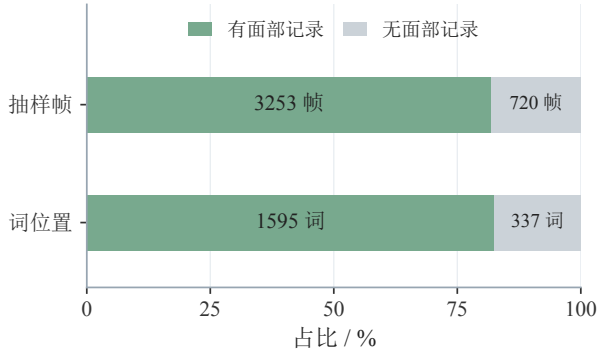


图 1: 面部特征的帧级与词级覆盖

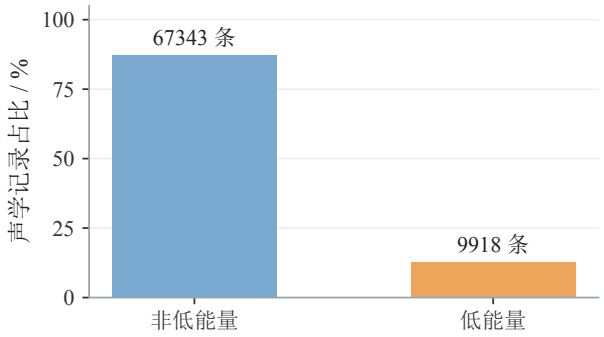


图 2: 声学记录的低能量占比

图 3与图 4以样本-iRBcNs9oI8$_$9 说明上述标记的时间分布。该样本 333 条 RMS 记录中有 147 条低于阈值；完整幅度图显示若干较强峰值，保持相同横轴的低幅值放大图则呈现峰值之间及片段末端的低能量区间。橙色虚线为阈值，橙点为低于阈值的记录。两图表明，声学输入状态随时间变化，采用逐记录标记能够保留整段平均统计无法呈现的局部差异。

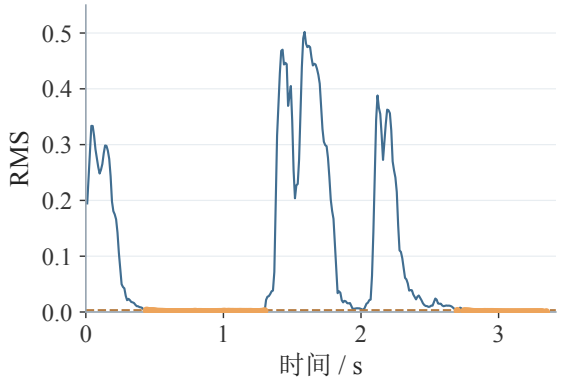


图 3: 实例音频的短时 RMS

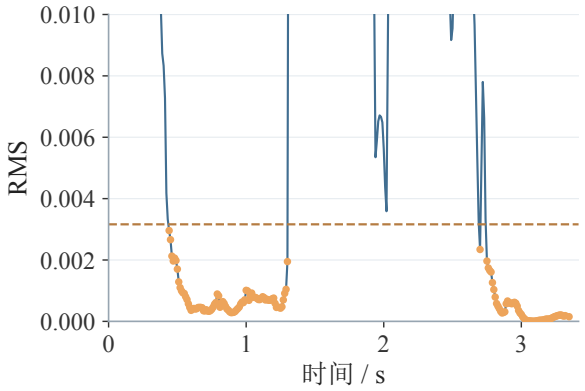


图 4: 同一时间范围的低幅值放大

另有两条样本的解码音频波形全为零，其声学特征各维均不随时间变化。结合视觉缺失与声学低能量结果可知，样本覆盖、模态观测和转写对应关系需要分别检查。本文保留全部样本及原始词位置，对视觉缺失采用零向量占位和无效标记，对低能量记录保留幅度状态；这种处理既维持了输入与输出的一一对应，也使异常位置能够被单独识别。在此基础上，下一步需要判断候选词时间区间是否得到实际音频的支持。

1.1.2　时序对齐质量评估与人工审核

前文的词级聚合以候选时间区间为依据，其时间位置决定了参与聚合的声学与视觉记录。本次 CTC 强制对齐为 1932 个词均生成了候选区间。为进一步检查这些区间与实际语

音的匹配程度，本文分别从局部词匹配和整段文本差异两个层次进行诊断，并通过人工审核分析整段异常的来源。

词级置信度取最优 CTC 路径中属于该词的文字字符帧概率的几何平均，不含空白符和词界符，用于描述模型对局部匹配的支持程度。片段级诊断词错误率（Word Error Rate，WER）则将无转写约束的贪心识别文本与规范化转写比较，以最少词编辑数除以参考词数，反映整段文本的差异。二者分别考察局部与整体：某些词即使得分较高，也可能处于整段内容不对应的片段中。两项指标均来自同一声学模型，分别作为局部与整体匹配的诊断依据。WER 的编辑数包含插入操作，取值可以超过 1。

图 5与图 6显示，词级置信度与片段级 WER 均存在需要关注的异常区域。1932 个词的置信度中位数为 0.9585，1034 个词不低于 0.95，但仍有 350 个词低于 0.1；100 条片段的诊断 WER 均值为 0.4689，其中 21 条超过 0.8，9 条超过 1。图中的虚线和阴影分别标示对应阈值与关注区域。上述分布呈现了局部低置信度词与整段高 WER 样本，本文据此结合词级与片段级状态确定候选区间的使用范围。

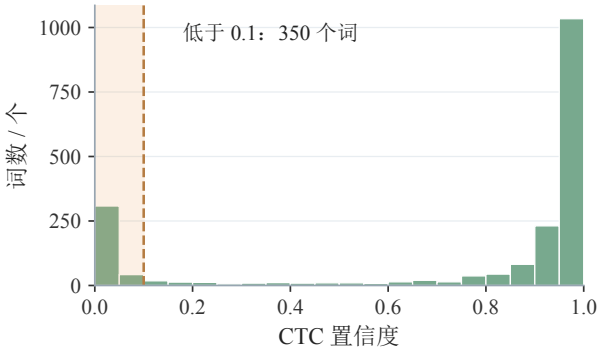


图 5: 词级 CTC 置信度分布

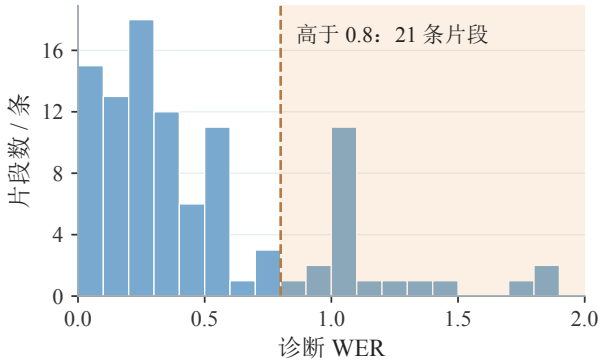


图 6: 片段级诊断 WER 分布

本文采用片段级与逐词两层筛选，将上述诊断落实为可随特征文件保存的质量标记。首先，平均词置信度低于 0.2、置信度低于 0.1 的词超过一半、诊断 WER 大于 0.8，或无法形成完整 CTC 路径的样本均列入整段复核，并将其词级时间对应标记为受限。其次，在其余样本中，仅将成功获得候选起止时间且置信度不低于 0.1 的词计为通过筛选。上述阈值为结合异常检查设置的经验条件，其对筛选范围的影响通过后续敏感性分析考察。筛选结果以质量标记保存，全部样本、原始词位置及特征记录均予保留。

图 7将两层筛选与模态观测检查串联起来。在 100 条样本中，19 条的平均词置信度低于 0.2，20 条有超过一半的词置信度低于 0.1，21 条的诊断 WER 大于 0.8，没有样本因无法形成完整 CTC 路径而被标记。这四项条件分别检查，每条样本只要满足其中任一项就进入整段复核；同一样本可能同时满足多项条件，最终复核数量按各条件标记集合的并集统计。本次前两项标记的样本均已包含在 WER 大于 0.8 的 21 条样本中，去除重复计数后，需整段复核的仍为 21 条，共涉及 317 个词。其余 79 条样本包含 1615 个词，其中 70 个因置信度不足未通过逐词筛选，剩余 1545 个通过筛选，占全部词的 79.97%。这 1545 个词中，158 个缺少有效面部记录，1387 个同时满足对齐筛选和三模态可观测条件，占全部词的 71.79%。

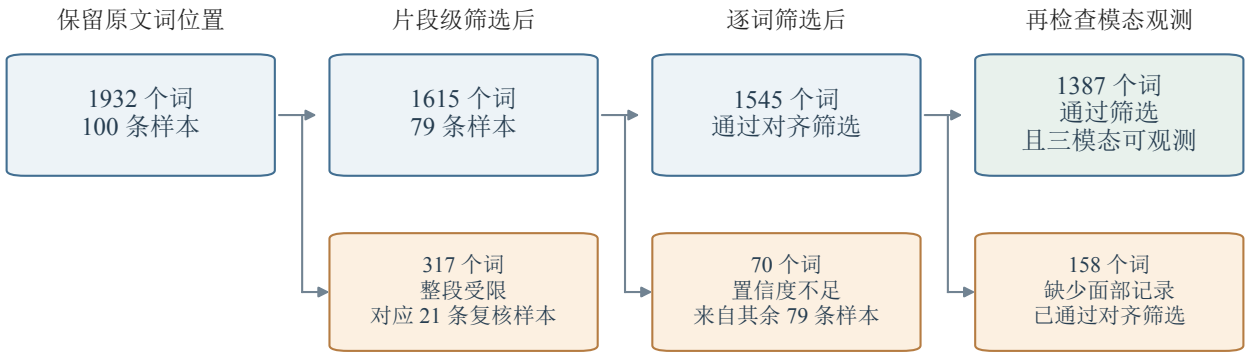


图 7: 从全部词位置到满足不同使用条件的词位置：各分支数量可逐项核对

图中各分支对应不同的词级使用条件。317 个整段受限词中包含 37 个局部置信度达到阈值的词，因而未通过筛选的 387 个词多于低置信度词的 350 个。另一方面，通过时间筛选但缺少面部记录的 158 个词仍保有文本与声学信息，其视觉状态由无效标记单独记录。因此，后续读取词级输出时需要分别使用对齐质量标记与模态观测标记，区分“存在可计算记录”和“满足当前对齐筛选条件”这两种状态。

进一步将片段平均置信度阈值取 0.1、0.2、0.3，诊断 WER 阈值取 0.6、0.8、1.0，其余条件保持不变。在三种平均置信度阈值下，待复核样本数均随 WER 阈值变化依次为 25、21、20 条，表明在本次考察范围内，复核样本数量主要随 WER 阈值变化，而对平均词置信度阈值的变化保持稳定。

在明确候选时间对应的筛选范围后，本文进一步考察时间聚合粒度对特征表示的影响。前文采用原文词作为共同组织单位，本节则在相同原生特征上构造 0.2 s 和 0.5 s 固定窗口进行补充对照。窗口均从零时刻开始，末窗截取至片段终点，并沿用有效时间交叠加权规则。该实验比较两种窗口对局部特征变化的保留程度，以及固定边界切分候选词区间的频率。

固定窗口对照包含聚合与重建两个步骤：首先分别聚合两种窗口内的原生特征，再根据时间交叠关系将窗口特征映回原生记录位置，以便与原序列比较。图 8以响度展示重建结果，灰线为原生记录，蓝线与橙线分别对应短窗和长窗。窗口平均削弱了原曲线的局部峰谷，较长窗口的平滑范围更大，说明统一时间汇总在压缩序列的同时会改变局部特征变化。重建结果在原生特征的时间位置上进行比较。

图 9检查同一样本中的词区间是否被固定窗口切分。绿色线为 `successful` 的候选区间 $[1.84247, 2.40247]$ s，上、下两排分别为 0.2 s 和 0.5 s 窗口。该词分别与 4 个短窗和 2 个长窗交叠，在两种划分下均计为一个跨界词。第四个短窗的交叠仅约 0.00247 s，在图示尺度下较难辨认；统计时将大于 10^{-8} s 的交叠视为有效交叠。跨界指标只判断是否与至少两个窗口交叠，不区分交叠窗口数量及切分幅度。

上述图示采用样本-egA8-b7-3M$_$1。其选取条件为未触发整段复核、面部观测帧占比不低于 80%，且时长最接近 10 s。该样本实际时长 10.266 s，包含 20 个词，其中 18 个通过对齐筛选。

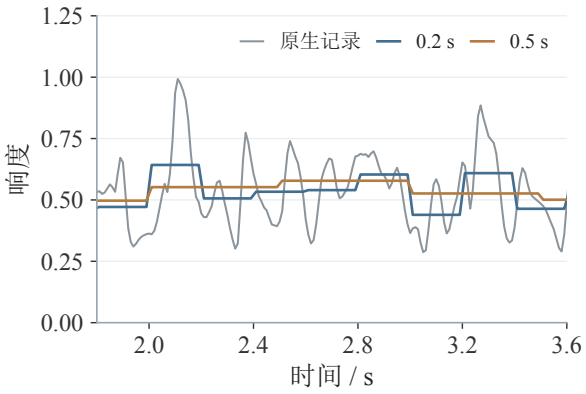


图 8: 响度的固定窗口聚合与重建

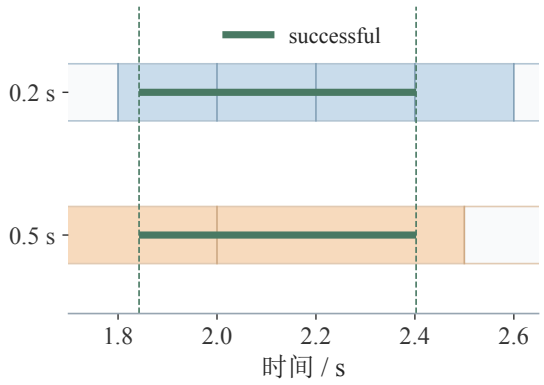


图 9: 候选词区间与固定窗口交叠

为判断上述现象是否仅出现在个别片段，本文对全量样本分别计算标准化重建均方误差与词跨界比例。重建误差将重建特征与原生特征之差按各维原生标准差归一化，再对有效记录和维度的平方误差取平均，数值越低表示越接近原生特征；仅纳入标准差大于 10^{-6} 的维度，有记录但全部维度恒定时记 0，无有效记录时不计入模态均值。词跨界比例则在每条样本通过对齐筛选的词中，统计与至少两个窗口交叠的词所占比例，数值越高表示被切分的词越多。两类指标均先在样本内计算，再对相应有效样本等权平均，以区分特征变化的保留程度和词区间的完整性。

图 10至图 12汇总全量对照。声学与视觉重建误差图中的短窗箱体整体低于长窗箱体，声学平均重建误差由 0.7467 降至 0.5449，视觉由 0.4373 降至 0.2357，相对降幅分别为 27.02% 和 46.10%。图 12则呈相反方向，平均词跨界比例由 39.50% 升至 71.33%，增加 31.83 个百分点。三幅图分别基于 100 条声学样本、87 条具有有效面部记录的样本和 79 条未触发整段复核的样本。图中菱形标出均值，箱内横线标出中位数，箱体覆盖第 25 至第 75 百分位数，须线延伸至 1.5 倍四分位距内的最远观测；箱外圆点仍参与统计。

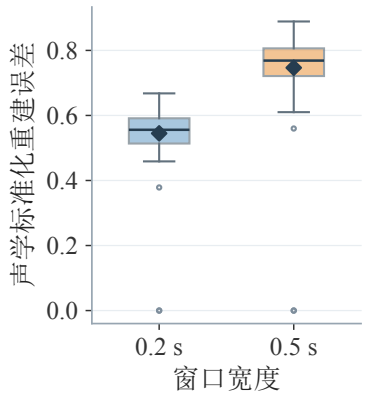


图 10: 声学重建误差对照

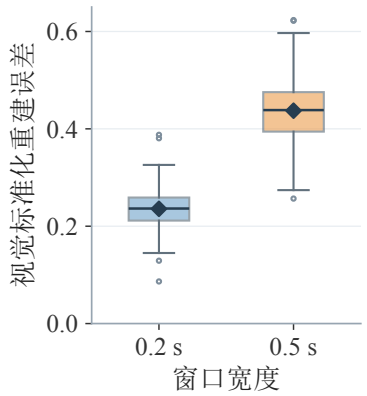


图 11: 视觉重建误差对照

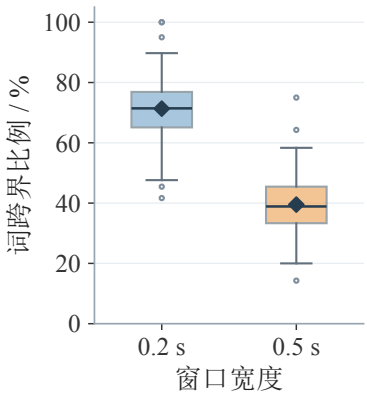


图 12: 词跨界比例对照

逐样本比较进一步表明，98 条样本的短窗声学误差更低，另 2 条相同；87 条样本的短窗视觉误差均更低；77 条样本的短窗词跨界比例更高，另 2 条相同。两条声学误差相同的样本

即前述全零音频样本，其特征不随时间变化，两种窗口的误差均按规则记 0。将这两条样本单独列出后，其余 98 条样本的短窗、长窗平均声学误差分别为 0.5560 和 0.7619，差异方向保持一致。两种窗口的 200 条逐样本指标详见问题一提交附件中的step1/validation/audited_window_comparison.csv，剔除恒定声学样本后的统计及相对变化量见同目录下的analysis_statistics.json。

上述对照表明，在本次数据与窗口设置下，0.2 s 窗口较好地保留了原生特征的局部变化，0.5 s 窗口则具有较低的词跨界比例，体现了特征变化保留与词区间完整性之间的权衡。该实验评价的是两种固定窗口的聚合效果。本文采用词级组织，是为了建立原文词与相应视听记录的逐词映射；其时间对应质量由对齐诊断与人工审核另行考察。

固定窗口对照考察了特征聚合粒度的影响，下面回到自动诊断筛出的 21 条整段复核样本，检查其异常来源。本文逐条对照实际音频与给定英文转写，核查语音内容是否对应，并按主要问题划分为表 2所列五类。各类互不重叠，共涉及 317 个原文词。

表 2: 21 条复核样本的人工审核结果

审核发现	样本数	原文词数	主要表现
音轨与文本不对应	11	120	实际语音内容与给定转写不对应
无对应朗读	5	64	未听到对应朗读，其中 1 条为音乐
非英语语音	3	93	实际语音并非英语
分段内容不对应	1	18	前半段无朗读，后半段语音与转写不对应
音频卡顿、局部对应	1	22	音频存在卡顿，部分词语与文本一致，但未形成完整对应
合计	21	317	

审核发现，音轨与文本不对应、缺少对应朗读等情况使给定转写缺少相应的语音依据；非英语语音则与所用英语声学模型及英文对齐目标不匹配。其中，3 条非英语样本均来自视频-yRb-Jum7EQ，两条全零音频样本归入“无对应朗读”。审核结果将这些样本的异常进一步定位到语音内容、语言及音频状态等输入层面。

样本-HwX2H8Z4hY$_$9 还说明了片段级检查的必要性。其平均词置信度为 0.7238，仅 9.09% 的词低于 0.1，但诊断 WER 达到 0.8636。人工审核发现音频存在卡顿，部分词语与转写一致，却没有形成完整逐词对应，说明局部得分较高不足以确认整段对应关系。

人工审核确认了这 21 条样本中的内容对应异常，本文据此维持其整体词级对应受限的标记，并保存原文、标签、原生特征、候选时间及审核说明。此次审核针对片段内容的一致性，未重新标注词级时间边界，因此前述词级筛选结果保持不变；其余 79 条样本仍依据自动诊断结果标记。由此，本节确定的是当前筛选规则下的词级对应使用范围，筛选通过率不等同于真实词界准确率。词界精度的进一步评价需要补充人工时间标注。逐样本的问题分类与审核说明详见问题一提交附件中的step1/results/ 人工审核 _21 条样本.csv。

1.1.3　典型样本的跨模态时序对齐验证

全量统计明确了输出的使用范围，典型样本则进一步检验具体记录能否回溯到原始素材。本文继续采用样本-egA8-b7-3M$_$1，展示文本片段、语音时段、视频帧及三类特征之间的对应。该样本给定转写包含“I started a successful Legal Nurse Consulting Business in 1989.”，图 13选取其中 1.80–3.60 s 的局部时段，自上而下排列实际画面、候选词区间、响度及面部系数。通过共同时间轴，可以从一个原文词定位其对应的声学记录与视频帧；图中绿色矩形标示各词的候选区间，其中 `successful` 区间内约 2.11 s 处出现响度峰值。图片按标注时刻定位，图片宽度不代表持续时间，面部曲线连线仅辅助观察。

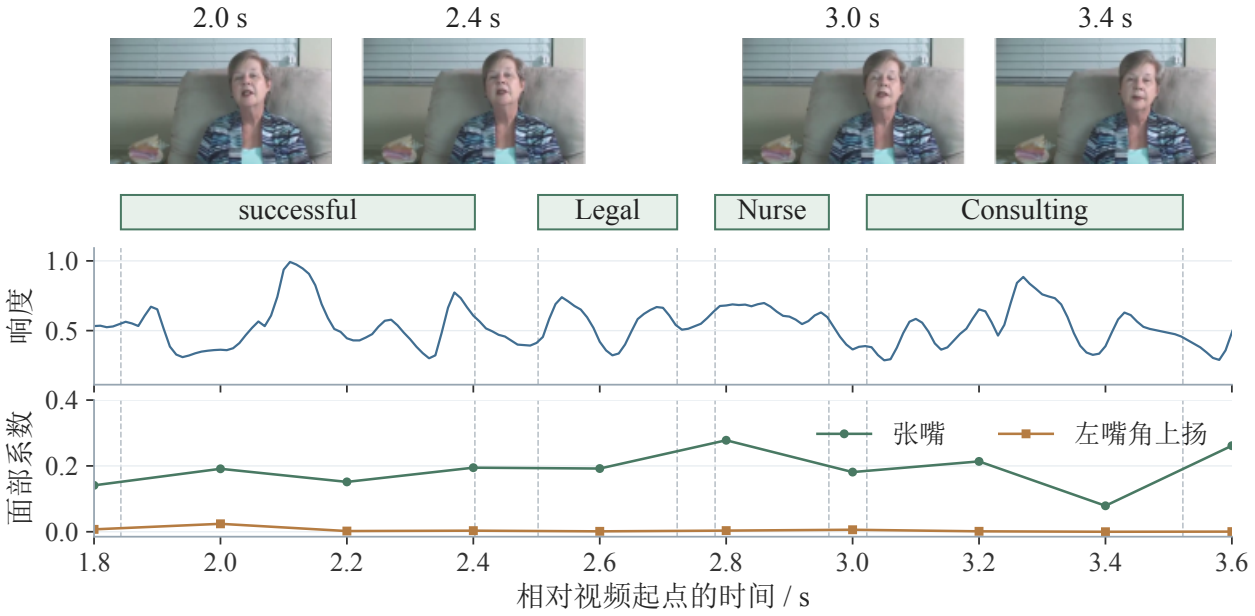


图 13: 词级映射的回溯示例：从候选词区间定位同一时段的声音与画面

表 3列出部分映射记录。词 *successful* 的候选区间为 $[1.8425, 2.4025]$ s，文本表示由子词索引 3 对应的隐藏向量获得，声学表示由 183–240 号共 58 条原生记录聚合，视觉表示由 1.8、2.0、2.2、2.4 s 四帧聚合。由此，该词的 768 维文本、25 维声学与 52 维视觉向量均可回溯到各自来源。索引从 0 开始；声学索引指特征记录而非波形采样点，视觉帧依据时间支持区间参与聚合，因此帧中心可以位于词区间之外，边界帧的权重由实际交叠时长决定。该样本全部词的映射明细见问题一提交附件中的step1/results/typical_feature_mapping.csv；完整向量和聚合权重保存在该样本目录的features.npz 中。

表 3: 典型样本的部分词级映射记录

原文词	子词索引	候选区间/s	声学记录索引	视觉帧时刻/s
started	1	$[1.2825, 1.6425]$	127–164	1.2, 1.4, 1.6
successful	3	$[1.8425, 2.4025]$	183–240	1.8, 2.0, 2.2, 2.4
Consulting	6	$[3.0225, 3.5225]$	301–352	3.0, 3.2, 3.4, 3.6

注：索引从 0 开始；声学索引指具有正聚合权重的原生特征记录，不是波形采样点。视觉帧按其时间支持区间与候选词区间的交叠关系参与聚合，帧中心不必位于词区间内部。

典型样本图与映射表共同展示了从原文词到模型子词、声学记录和视频帧的可追溯链条，使前文的聚合规则能够在具体输出上核验。进一步对全部 100 条样本独立复算交叠权重、视听聚合值和 CTC 置信度，重新计算诊断 WER，并解码音视频核对时间记录与低能量标记，结果均在既定数值容差内与保存记录一致。这一检查验证了实现与既定计算规则的一致性。典型样本中的 `in` 和 `1989` 仍标记为低置信度词，实例中的质量状态与全量筛选结果一致。全量路径与聚合核验记录见问题一提交附件中的step1/results/verification.json，媒体解码及各项统计的独立复算记录见step1/validation/data_audit.json。

1.1.4 三模态特征文件说明与 100 条样本结果汇总

以上统计与典型样本展示说明了输出的覆盖范围、质量状态和回溯方式。为进一步满足题目对自生成特征文件规范及全部 100 条样本结果汇总的要求，本文采用“统一模态规格＋逐样本明细”的组织方式：表 4列出每条样本共有的模态类型、特征维数、矩阵形状与对齐粒度，表 5列出全部样本的编号、原始媒体时长及有效位置统计。两表结合，可确定任一样本三种模态的输出规格及使用范围；具体高维数值由相应样本目录中的特征文件提供。

表 4: 三种模态的词级特征规格

模态	特征维数	样本矩阵形状	对齐粒度
文本	768	$L \times 768$	原文词
声学	25	$L \times 25$	原文词
视觉（面部）	52	$L \times 52$	原文词

注：L 为对应样本的原文词数。各样本按实际词数存储，填充数与截断词数均为 0；视觉模态不可观测的词位置采用零向量占位，并附无效标记。

在时序组织上，每条样本按实际原文词数 L 保存变长序列，完整保留原始词位置。L 表示序列长度，各模态的观测有效位置和通过对齐筛选的位置分别由掩码记录。有效位置可能分散于序列中，因此同时保存长度信息与逐位置标记。视觉缺失位置采用零向量占位，统一长度填充数与截断词数均为 0。

全量表中，“原文词数”对应三个矩阵的行数，“视觉可观测词数”统计能聚合有效面部记录的位置，“通过对齐筛选词数”依据前述两层筛选条件，最后一列为通过筛选且三种模态均可观测的词数。由于文本与声学在全部词位置均有可计算记录，最后一列等于对齐筛选与视觉可观测两个条件的交集。片段时长与音频时长均按前文的实际解码口径记录，用于定位原始媒体的时间范围。

例如，样本-s9qJ7ATP7w$_$7 共有 28 个词，其中 14 个视觉可观测，24 个通过对齐筛选，同时满足两项条件的有 12 个。交集数量通过逐词联合检查两项标记得到。

按上述口径，32 条样本的全部词通过筛选且三种模态均可观测，46 条样本仅部分词满足两项条件，1 条样本的全部词通过对齐筛选但视觉模态不可观测，另 21 条样本经人工审核后整体词级对应仍受限。全量表按这四类依次排列，已审核的 21 条样本统一归入最后一

类，各组互不重叠。与表 5对应的电子清单见问题一提交附件中的step1/results/ 全部样本特征交付清单.csv，可按样本编号检索和核对各项统计。

表 5: 附件 1 全部样本的特征输出与有效位置统计

样本编号	片段时长/s	音频时长/s	原文词数	视觉可观测词数	通过对齐筛选词数	其中三种模态都可观测词数
1. 全部词通过筛选且三种模态都可观测（32 条）						
-3g5yACwYnA$_$3	14.389	14.328	29	29	29	29
-3nNcZdcdvU$_$5	7.868	7.789	18	18	18	18
-6rXp3zJ3kc$_$8	12.805	12.738	34	34	34	34
-I_e4mIh0yE$_$1	7.622	7.444	18	18	18	18
-I_e4mIh0yE$_$3	9.163	8.994	22	22	22	22
-MeTTeMJBNc$_$0	9.333	9.218	21	21	21	21
-MeTTeMJBNc$_$13	5.430	5.255	14	14	14	14
-RfYyzHpjk4$_$11	5.239	5.075	17	17	17	17
-RfYyzHpjk4$_$8	4.589	4.532	17	17	17	17
-UUCSKoHeMA$_$0	7.867	7.732	18	18	18	18
-UacrmKiTn4$_$10	7.362	7.242	18	18	18	18
-UacrmKiTn4$_$4	4.741	4.682	14	14	14	14
-aNfi7CP8vM$_$7	8.695	8.538	18	18	18	18
-aqamKhZ1Ec$_$0	11.000	10.890	14	14	14	14
-dxfTGcXJoc$_$1	16.161	16.018	37	37	37	37
-egA8-b7-3M$_$16	5.538	5.483	11	11	11	11
-egA8-b7-3M$_$17	7.271	7.095	16	16	16	16
-egA8-b7-3M$_$18	8.386	8.266	22	22	22	22
-egA8-b7-3M$_$20	6.645	6.474	20	20	20	20
-egA8-b7-3M$_$26	6.031	5.921	15	15	15	15
-egA8-b7-3M$_$6	6.265	6.183	12	12	12	12
-egA8-b7-3M$_$9	5.090	4.936	10	10	10	10
-mqbVkbCndg$_$0	6.500	6.386	14	14	14	14
-s9qJ7ATP7w$_$6	2.475	2.315	5	5	5	5
-s9qJ7ATP7w$_$8	3.295	3.184	12	12	12	12
-t217m2on-s$_$7	17.183	17.026	45	45	45	45
-tPCytz4rww$_$10	4.789	4.679	12	12	12	12
-tPCytz4rww$_$11	5.467	5.379	17	17	17	17
-tPCytz4rww$_$18	6.645	6.569	16	16	16	16
-uywlfIYOS8$_$4	6.045	5.881	18	18	18	18

续下页

表 5　特征输出与有效位置统计（续）

样本编号	片段时长/s	音频时长/s	原文词数	视觉可观测词数	通过对齐筛选词数	其中三种模态都可观测词数
-wny0OAz3g8$_$0	3.333	3.274	9	9	9	9
-wny0OAz3g8$_$2	6.687	6.523	23	23	23	23
2. 部分词通过筛选且三种模态都可观测（46 条）						
-3g5yACwYnA$_$13	5.514	5.399	15	15	14	14
-3g5yACwYnA$_$2	9.394	9.231	14	14	13	13
-3g5yACwYnA$_$9	8.817	8.696	23	23	21	21
-571d8cVauQ$_$0	5.167	4.992	12	12	10	10
-571d8cVauQ$_$5	15.273	15.115	43	43	42	42
-9y-fZ3swSY$_$0	6.900	6.757	22	22	19	19
-9y-fZ3swSY$_$4	2.821	2.665	9	9	6	6
-9y-fZ3swSY$_$8	4.989	4.917	12	3	11	2
-AUZQgSxyPQ$_$2	22.511	22.405	41	41	39	39
-HeZS2-Prhc$_$2	8.262	8.151	16	16	15	15
-HwX2H8Z4hY$_$2	3.982	3.916	7	1	4	1
-HwX2H8Z4hY$_$5	5.653	5.544	9	2	8	2
-HwX2H8Z4hY$_$6	3.358	3.256	7	5	6	5
-MeTTeMJBNc$_$7	10.517	10.411	31	31	29	29
-RfYyzHpjk4$_$2	5.516	5.392	25	24	21	21
-THoVjtIkeU$_$12	14.896	14.806	39	39	38	38
-THoVjtIkeU$_$2	4.292	4.231	10	10	9	9
-THoVjtIkeU$_$6	8.097	7.983	30	30	27	27
-UuX1xuaiiE$_$0	3.700	3.576	9	6	8	5
-UuX1xuaiiE$_$1	10.350	10.268	27	1	27	1
-UuX1xuaiiE$_$3	4.130	4.038	9	9	8	8
-UuX1xuaiiE$_$6	8.114	7.944	22	22	20	20
-a55Q6RWvTA$_$3	22.154	22.083	65	60	63	58
-dxfTGcXJoc$_$0	20.533	20.410	40	33	39	32
-dxfTGcXJoc$_$2	16.698	16.633	34	34	33	33
-dxfTGcXJoc$_$6	12.735	12.628	28	28	27	27
-egA8-b7-3M$_$1	10.266	10.156	20	20	18	18
-egA8-b7-3M$_$13	4.184	4.024	11	11	10	10
-lzEya4AM_4$_$5	7.675	7.570	19	19	18	18
-lzEya4AM_4$_$6	14.792	14.740	43	43	42	42
-qDkUB0GgYY$_$6	4.678	4.615	16	16	12	12

续下页

表 5　特征输出与有效位置统计（续）

样本编号	片段时长/s	音频时长/s	原文词数	视觉可观测词数	通过对齐筛选词数	其中三种模态都可观测词数
-s9qJ7ATP7w$_$0	6.867	6.711	24	24	23	23
-s9qJ7ATP7w$_$1	4.792	4.644	11	11	10	10
-s9qJ7ATP7w$_$4	4.427	4.247	9	6	8	5
-s9qJ7ATP7w$_$5	8.561	8.398	19	19	18	18
-s9qJ7ATP7w$_$7	6.966	6.839	28	14	24	12
-t217m2on-s$_$2	5.686	5.630	12	12	11	11
-tANM6ETl_M$_$3	6.758	6.604	22	22	21	21
-tPCytz4rww$_$12	11.864	11.736	26	26	24	24
-tPCytz4rww$_$16	7.206	7.139	16	16	14	14
-vxjVxOeScU$_$4	9.127	9.037	21	21	18	18
-wMB_hJL-3o$_$7	6.044	5.976	22	22	21	21
-wny0OAz3g8$_$3	6.146	6.100	20	1	20	1
-wny0OAz3g8$_$5	6.912	6.741	20	1	20	1
-wny0OAz3g8$_$7	8.068	7.910	29	6	29	6
-wny0OAz3g8$_$9	6.213	6.043	20	20	19	19
3. 全部词通过对齐筛选，但视觉模态不可观测（1 条）						
-wny0OAz3g8$_$1	6.844	6.777	22	0	22	0
4. 整段对齐受限（已完成人工审核）（21 条）						
-HwX2H8Z4hY$_$9	7.734	7.636	22	0	0	0
-NFrJFQijFE$_$1	5.746	5.659	16	0	0	0
-NFrJFQijFE$_$2	6.856	6.698	18	0	0	0
-hnBHBN8p5A$_$6	6.401	6.333	13	0	0	0
-hnBHBN8p5A$_$7	7.372	7.309	13	0	0	0
-iRBcNs9oI8$_$3	5.621	5.538	8	0	0	0
-iRBcNs9oI8$_$6	2.903	2.820	5	0	0	0
-iRBcNs9oI8$_$7	4.104	4.006	9	0	0	0
-iRBcNs9oI8$_$8	8.093	8.026	21	0	0	0
-iRBcNs9oI8$_$9	3.416	3.374	5	0	0	0
-mJ2ud6oKI8$_$1	6.103	6.054	13	0	0	0
-mJ2ud6oKI8$_$2	5.731	5.702	11	0	0	0
-mJ2ud6oKI8$_$6	2.257	2.228	5	5	0	0
-mJ2ud6oKI8$_$8	4.192	4.171	11	11	0	0
-mJ2ud6oKI8$_$9	7.033	6.909	22	22	0	0
-ri04Z7vwnc$_$0	2.807	2.763	8	0	0	0

续下页

表 5 特征输出与有效位置统计（续）

样本编号	片段时长/s	音频时长/s	原文词数	视觉可观测词数	通过对齐筛选词数	其中三种模态都可观测词数
-ri04Z7vwnc$_$2	6.027	5.913	16	8	0	0
-ri04Z7vwnc$_$5	3.545	3.440	8	8	0	0
-yRb-Jum7EQ$_$1	29.288	29.110	49	48	0	0
-yRb-Jum7EQ$_$5	13.169	13.045	25	25	0	0
-yRb-Jum7EQ$_$6	11.243	11.243	19	19	0	0

为使全量汇总能够落实到具体文件，本文按样本编号建立目录，采用 NPZ 保存数值数组，采用 JSON 保存原文、标签、特征定义和处理信息，并以 CSV 分别汇总样本、模态及词级记录。各文件内容见表 6。这种组织方式将高维特征与其解释信息共同保存，使查询某条样本时能够同时取得特征值、原始来源和质量状态。

全部 100 条样本的完整特征位于问题一提交附件的step1/results/samples/ 下，每个以样本编号命名的子目录均保存features.npz、metadata.json、quality.json、quality_masks.npz 及两种固定窗口结果；汇总 CSV 文件位于step1/results/ 目录。

表 6: 特征结果文件及其内容

文件	内容
features.npz	词级三模态矩阵、候选词区间、观测标记，以及原生视听特征和聚合权重。
metadata.json	原文、标签、词与子词位置、各维特征名称及处理参数。
quality_masks.npz、 quality.json	对齐质量筛选结果、结合观测状态的有效位置标记及自动筛选原因。
windows_0.2s.npz、windows_0.5s.npz	固定窗口边界、视听特征及文本聚合权重。
人工审核 _21 条样本.csv	21 条样本的人工审核状态、问题分类与原始说明。
三份 CSV 汇总表	sample_summary.csv、modality_summary.csv 和word_alignment.csv 分别对应 100 条样本、300 条样本–模态记录及 1932 个词的明细。

读取时，先通过样本编号定位目录，从features.npz 载入text、audio 和vision 数组，相同行均对应同一原文词；再读取word_bounds 中的候选起止时间，并结合metadata.json 中的原文、词与子词记录解释该位置。用于词级视听分析时，还需读取quality_masks.npz 中的模态有效位置标记，例如vision_aligned_usable 取 1 表示该词通过对齐筛选且视觉可观测。保存的原生记录索引和聚合权重可用于复算词级向量，固定窗口的文本表示则由词权重与词级文本矩阵相乘获得。由此，样本编号、特征行、候选时间和原始素材之间形成可逐级核验的对应关系。完整字段释义、掩码使用规则及可执行读取示例详见问题一提交附件中的特征字段与读取.md。

1.1.5 方案可复现性说明

为使前述处理结果能够复现，本文同时记录工具与模型版本、关键参数、配置文件、模型文件哈希及处理日志。实验环境和主要参数见表 7；词级与片段级质量筛选条件已在时序对齐评估中明确列出。复现流程沿用前文的冻结模型与声学特征配置，覆盖输入处理、特征生成、时间映射与质量标记。实际环境记录、提取参数和冻结模型版本分别见问题一提交附件中的step1/results/environment.json、step1/config.json 与step1/assets_manifest.json。

表 7: 实验环境与主要参数

项目	版本或参数
运行环境	Python 3.10.13；PyTorch 2.5.1；CUDA 12.1。
音视频读取	PyAV 17.0.1；音频 16 kHz、单声道；视频目标抽样频率 5 Hz。
文本编码	Transformers 4.48.3；distilbert/distilbert-base-uncased；每块最多 510 个子词，另加首尾标记。
声学对齐	facebook/wav2vec2-base-960h；CTC 最大概率路径。
声学特征	openSMILE 2.6.0；eGeMAPSv02 的 25 维低层描述量。
面部特征	MediaPipe 0.10.21；Face Landmarker float16 版本 1；52 维表情系数；检测与存在阈值均为 0.5，最多两张脸，选择面积最大者。
数值计算	NumPy 1.26.4；SciPy 1.15.3；特征采用 32 位浮点数；num2words 0.5.14；随机种子 20260923。

完整运行流程如下：首先依据环境清单和模型哈希准备相同的工具与权重，核对视频、转写和标签的样本标识，并进行媒体解码检查；随后完成文本规范化、音频重采样和带实际时间戳的视频抽样，分别提取三模态特征，估计 CTC 候选词区间，并按时间交叠聚合视听记录；最后生成质量标记、固定窗口对照和全量汇总，再独立复算时间映射与聚合结果。具体输入目录、运行顺序和执行命令详见问题一提交附件中的复现实验说明.md，核心实现位于step1/ 目录；逐样本处理日志及失败清单分别见step1/results/processing_log.jsonl 与同目录下的failures.json。21 条样本的人工审核说明单独保留，以区分程序计算结果与人工内容核查。

复现检查分别覆盖输入与实现的一致性、计算结果的一致性和重复提取的一致性。已有全量核验确认 100 条样本的源视频、处理代码、配置及模型文件哈希一致，候选路径与聚合结果符合既定规则；此外，将两条独立试跑样本与正式提取结果逐字段比较，特征的最大绝对差为 0。全量核验覆盖 100 条样本的结构与计算一致性，重复提取检查覆盖上述两条样本，运行环境与正式提取保持一致。上述记录与特征文件共同构成可复核、可复现的交付材料。两条样本的逐字段对照记录详见问题一提交附件中的step1/results/reproducibility.json；附件文件的完整性可依据根目录下的文件校验清单.json，通过核验附件.py 进行离线检查。